

ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ
ΥΠΟΛΟΓΙΣΤΩΝ



Επιτάχυνση επιλογής top-k σε ετερογενή συστήματα CPU, GPU και NPU

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ιωάννης Μιχάλαϊνας

ioannisam@ece.auth.gr

Επιβλέπων: Νικόλαος Πιτσιάνης

Αναπληρωτής Καθηγητής, Τμήμα Ηλεκτρολόγων Μηχανικών και
Μηχανικών Υπολογιστών

Θεσσαλονίκη, Σεπτέμβριος 2026

Περίληψη

Η επιλογή top-k, δηλαδή ο εντοπισμός των k μεγαλύτερων στοιχείων ενός συνόλου, εμφανίζεται σε πλήθος εφαρμογών και επαναλαμβάνεται αρκετά συχνά ώστε το κόστος της να είναι αισθητό. Η πρόσφατη ενσωμάτωση μονάδων νευρωνικής επεξεργασίας στην ίδια ψηφίδα με τον επεξεργαστή καθιστά πρακτικό το ερώτημα αν συμφέρει η ανάθεση τέτοιων υπολογισμών σε επιταχυντή.

Η εργασία υλοποιεί δύο αλγορίθμους με θεμελιωδώς διαφορετική συμπεριφορά, την περικυκλωμένη διτονική ταξινόμηση που είναι ανεξάρτητη από τα δεδομένα και την επιλογή με τοπικούς σωρούς που εξαρτάται από αυτά, σε τρεις αρχιτεκτονικές: επεξεργαστή με διανυσματικές επεκτάσεις AVX-512, μονάδα γραφικών με CUDA και μονάδα νευρωνικής επεξεργασίας AMD XDNA. Και οι έξι υλοποιήσεις μετρήθηκαν στον ίδιο παραμετρικό χώρο, σε δύο ρητά διακριτά πεδία μέτρησης, με καταγραφή χρόνου, ενέργειας και όγκου διακινούμενων δεδομένων και με τοποθέτηση κάθε εκτέλεσης σε οροφή μετρημένη στο ίδιο μηχάνημα.

Τα αποτελέσματα δείχνουν ότι το πρόβλημα περιορίζεται από την κίνηση δεδομένων σε κάθε αρχιτεκτονική, ότι η κατάταξη των δύο αλγορίθμων ανατρέπεται με τον λόγο n/k και όχι με την αρχιτεκτονική και ότι η επιλογή του ορίου μέτρησης ανατρέπει πλήρως την κατάταξη των αρχιτεκτονικών. Ενεργειακά, η μονάδα νευρωνικής επεξεργασίας εμφανίζει τη χαμηλότερη ισχύ και ταυτόχρονα την υψηλότερη κατανάλωση, καθώς η διάρκεια κυριαρχεί του γινομένου. Καμία εκτέλεση σε επιταχυντή δεν είναι βέλτιστη κατά Pareto: για μικρό k η ανάθεση είναι μετρήσιμα χειρότερη από τον υπολογισμό στον επεξεργαστή.

Λέξεις-κλειδιά: επιλογή top-k, δίκτυα διτονικής ταξινόμησης, ετερογενής υπολογισμός, μονάδα νευρωνικής επεξεργασίας, MLIR-AIE, διανυσματοποίηση SIMD, ενεργειακή αποτίμηση, μοντέλο roofline

Abstract

Top-k selection, the task of identifying the k largest elements of a set, appears across a wide range of applications and is repeated often enough that its cost is noticeable. The recent integration of neural processing units into the same die as the processor makes the question of whether offloading such computations to an accelerator is worthwhile a practical one.

This work implements two algorithms with fundamentally different behaviour, truncated bitonic sorting which is data-oblivious and map-reduce selection with local heaps which is data-dependent, on three architectures: a processor with AVX-512 vector extensions, a GPU programmed in CUDA, and an AMD XDNA neural processing unit. All six implementations were measured over the same parameter space, under two explicitly distinct measurement scopes, recording time, energy and the volume of data moved and placing every run against a roofline measured on the same machine.

The results show that the problem is limited by data movement on every architecture, that the ranking of the two algorithms is overturned by the ratio n/k rather than by the architecture and that the choice of measurement boundary completely overturns the ranking of the architectures. In energy terms the neural processing unit exhibits the lowest power draw and simultaneously the highest consumption, since duration dominates the product. No accelerator run is Pareto-optimal: for small k , offloading is measurably worse than computing on the processor.

Keywords: top-k selection, bitonic sorting networks, heterogeneous computing, neural processing unit, MLIR-AIE, SIMD vectorisation, energy efficiency, roofline model

Ευχαριστίες

Η εργασία αυτή αποτελεί το μεγαλύτερο προγραμματιστικό έργο που έχω αναλάβει μέχρι σήμερα. Θα ήθελα να ευχαριστήσω τον επιβλέποντα καθηγητή μου, κ. Νικόλαο Πιτσιάνη, στα μαθήματα του οποίου ανακάλυψα το ενδιαφέρον μου για το High Performance Computing και το low-level programming.

Επίσης, θα ήθελα να ευχαριστήσω την οικογένειά μου για την αμέριστη υποστήριξη που μου παρείχε καθ' όλη τη διάρκεια των σπουδών μου· ιδιαίτερα τον αδελφό μου, Μανώλη, ο οποίος, ως συνάδελφος, με βοήθησε με πολύτιμες συμβουλές και καθοδήγηση.

Ιωάννης Μιχάλαινας

Περιεχόμενα

Περίληψη	2
Abstract	3
Ευχαριστίες	4
1 Εισαγωγή	10
1.1 Αντικείμενο της εργασίας	10
1.2 Κίνητρο	10
1.3 Συνεισφορά	11
1.4 Δομή της εργασίας	12
2 Υπόβαθρο και σχετική εργασία	13
2.1 Το πρόβλημα της επιλογής top-k	13
2.2 Αλγόριθμοι επιλογής	14
2.2.1 Δίκτυα διτονικής ταξινόμησης	15
2.2.2 Περικομμένη διτονική ταξινόμηση	15
2.2.3 Επιλογή με σωρούς και map-reduce	17
2.2.4 Επιλογή με βάση την αναπαράσταση	18
2.3 Αρχιτεκτονικές επεξεργασίας	19
2.3.1 Διανυσματικές επεκτάσεις CPU	19
2.3.2 Μοντέλο SIMT και ιεραρχία μνήμης GPU	20
2.3.3 Αρχιτεκτονική ροής δεδομένων AIE	20
2.4 Υπάρχουσες υλοποιήσεις και βιβλιοθήκες	21
3 Μεθοδολογία και πειραματική διάταξη	23
3.1 Σύστημα αναφοράς	23
3.2 Δομή της υποδομής μετρήσεων	24
3.3 Μετρούμενα μεγέθη	25
3.3.1 Πεδία μέτρησης: algo και end-to-end	25
3.3.2 Μέτρηση χρόνου	26
3.3.3 Μέτρηση ενέργειας	27
3.3.4 Μέτρηση κίνησης δεδομένων	28
3.4 Μοντέλο roofline	29
3.5 Βιβλιοθήκες σύγκρισης	31
3.6 Έλεγχος ορθότητας	31
3.7 Παραμετρικός χώρος	32
3.7.1 Τύποι δεδομένων	32

3.7.2 Κατανομές εισόδου	33
3.8 Συνθήκες μέτρησης και επαναληψιμότητα	34
4 Υλοποίηση σε CPU	36
4.1 Σχεδιαστικές επιλογές	36
4.1.1 Διανυσματοποίηση	36
4.1.2 Αφαίρεση διανυσματικών τύπων	37
4.1.3 Υποστήριξη αριθμών κινητής υποδιαστολής μισής ακρίβειας	38
4.1.4 Παραλληλοποίηση σε πολλαπλά νήματα	39
4.2 Διτονική ταξινόμηση	39
4.3 Map-reduce με τοπικούς σωρούς	41
4.4 Διαχείριση μνήμης και κίνηση δεδομένων	43
4.5 Υλοποίηση αναφοράς	44
4.6 Περιοριστικοί παράγοντες	44
5 Υλοποίηση σε GPU	46
5.1 Σχεδιαστικές επιλογές	46
5.1.1 Αντιστοίχιση σε πλέγμα και ομάδες νημάτων	46
5.2 Διτονική ταξινόμηση	47
5.2.1 Οργάνωση σε πλακίδια και κοινή μνήμη	48
5.3 Map-reduce με τοπικούς σωρούς	49
5.3.1 Όριο παραλληλίας για μεγάλα k	50
5.4 Διαχείριση μνήμης και κίνηση δεδομένων	51
5.5 Υλοποίηση αναφοράς	52
5.5.1 Επιλογή με βάση την αναπαράσταση στη CUB	53
5.6 Περιοριστικοί παράγοντες	53
6 Υλοποίηση σε NPU	55
6.1 Σχεδιαστικές επιλογές	55
6.1.1 Ροή ανάπτυξης με MLIR-AIE	55
6.1.2 Τοπολογία πλακιδίων και object_fifo	56
6.2 Διτονική ταξινόμηση	57
6.2.1 Πυρήνας υπολογιστικού πλακιδίου	57
6.2.2 Κλιμάκωση σε πολλαπλά πλακίδια	57
6.3 Map-reduce με τοπικούς σωρούς	58
6.4 Διαχείριση μνήμης και κίνηση δεδομένων	58
6.4.1 Διοχέτευση και ρόλος του host	59
6.4.2 Κωδικοποίηση δεδομένων και τύποι	60
6.4.3 Τελική διόρθωση στον host	60
6.5 Υλοποίηση αναφοράς	61
6.6 Περιοριστικοί παράγοντες	61
7 Αποτελέσματα και αξιολόγηση	63
7.1 Ορθότητα	63
7.2 Χρόνος εκτέλεσης	64
7.2.1 Εξάρτηση από το μέγεθος εισόδου	64
7.2.2 Εξάρτηση από την παράμετρο k	66
7.3 Σύγκριση αρχιτεκτονικών	68
7.4 Ανάλυση με το μοντέλο roofline	70

7.4.1 Αξιοποίηση εύρους ζώνης μνήμης	72
7.5 Ενεργειακή αποτίμηση	73
7.5.1 Γινόμενο ενέργειας-καθυστερήσης	76
7.6 Επίδραση του τύπου δεδομένων	77
7.7 Ευαισθησία στην κατανομή της εισόδου	78
8 Συμπεράσματα και μελλοντική εργασία	80
8.1 Συμπεράσματα	80
8.2 Περιορισμοί	81
8.3 Μελλοντική εργασία	82
Α΄ Ακρωνύμια	84
Β΄ Γλωσσάρι όρων	85
Γ΄ Αναπαγωγή των μετρήσεων	86
Γ.1 Απαιτήσεις λογισμικού	86
Γ.2 Μεταγλώττιση	87
Γ.3 Εκτέλεση των πειραμάτων	87
Γ.3.1 Εκτέλεση επιμέρους βημάτων	88
Γ.3.2 Παράμετροι εκτέλεσης	88
Γ.4 Παραγωγή των διαγραμμάτων	90

Κατάλογος Σχημάτων

2.1	Επιλογή έναντι ταξινόμησης	14
2.2	Το πλήρες διτονικό δίκτυο και η περικοπή του	17
2.3	Επιλογή με σωρούς και σχήμα map-reduce	18
2.4	Επιλογή με βάση την αναπαράσταση	19
3.1	Τα τέσσερα επίπεδα της υποδομής μετρήσεων	25
3.2	Τα δύο πεδία μέτρησης ανά αρχιτεκτονική	26
3.3	Η ανάγνωση του μοντέλου roofline	30
3.4	Οι πέντε κατανομές εισόδου	33
4.1	Το θεμελιώδες μοτίβο σύγκρισης-ανταλλαγής	37
4.2	Η διαδρομή της μισής ακρίβειας	38
4.3	Συγχώνευση διαδοχικών επιπέδων σε ένα πέρασμα	40
4.4	Η μαζική απόρριψη του map-reduce	42
5.1	Ταξινομημένο μπλοκ και πλακίδιο κοινής μνήμης	49
5.2	Το όριο παραλληλίας του map-reduce	51
6.1	Τοπολογία πλακιδίων και ουρές object_fifo	56
6.2	Η διοχέτευση τριών σταδίων της εκφόρτωσης	60
7.1	Χρόνος συναρτήσεων του μεγέθους, στα δύο πεδία μέτρησης	64
7.2	Κάθε αλγόριθμος στις τρεις αρχιτεκτονικές	65
7.3	Χρόνος συναρτήσεων του μεγέθους, ανά τιμή του k	66
7.4	Οι τρεις αλγόριθμοι στη μονάδα γραφικών για k ίσο με 131072.	67
7.5	Επιτάχυνση έναντι της υλοποίησης αναφοράς	68
7.6	Τοποθέτηση των εκτελέσεων στα μετρημένα ταβάνια	70
7.7	Μετρημένο εύρος ζώνης ανάγνωσης συναρτήσεων του μεγέθους του συνόλου εργασίας, για τις τρεις αρχιτεκτονικές.	71
7.8	Επιτευχθέν εύρος ζώνης ανά αρχιτεκτονική	72
7.9	Αλγοριθμικός και συνολικός χρόνος στη μονάδα γραφικών	73
7.10	Καθαρή ενέργεια και ισχύς ανά αρχιτεκτονική και αλγόριθμο	74
7.11	Συνολικός χρόνος και ενέργεια ανά μετρημένη περίπτωση	75
7.12	Γινόμενο ενέργειας-καθυστέρησης συναρτήσεων του μεγέθους εισόδου. . .	76
7.13	Ευαισθησία του χρόνου στην κατανομή της εισόδου	78

Κατάλογος Πινάκων

3.1	Το σύστημα αναφοράς στο οποίο εκτελέστηκαν όλες οι μετρήσεις.	23
3.2	Το περιεχόμενο των δύο πεδίων μέτρησης ανά αρχιτεκτονική.	25
3.3	Οι τύποι δεδομένων που σαρώνονται.	33
3.4	Οι κατανομές εισόδου που σαρώνονται.	33
3.5	Οι συνθήκες στις οποίες καθλώνεται το σύστημα πριν από κάθε σάρωση.	34
6.1	Κατανομή του χρόνου της περιοχής εκφόρτωσης ανά στάδιο.	59
7.1	Αλγοριθμικός χρόνος για τα δύο άκρα του k	66
7.2	Αλγοριθμικός χρόνος ανά τύπο δεδομένων	77
Β'.1	Αντιστοίχιση ελληνικών και αγγλικών όρων.	85
Γ'.1	Οι παράμετροι εκτέλεσης και οι προεπιλογές τους.	89

Κεφάλαιο 1

Εισαγωγή

1.1 Αντικείμενο της εργασίας

Η εργασία εξετάζει την επιτάχυνση της επιλογής top-k, δηλαδή του εντοπισμού των k μεγαλύτερων στοιχείων ενός συνόλου n τιμών, σε τρεις διαφορετικές αρχιτεκτονικές: έναν επεξεργαστή γενικού σκοπού, μια μονάδα γραφικών και μια μονάδα νευρωνικής επεξεργασίας ενσωματωμένη στην ίδια ψηφίδα με τον επεξεργαστή.

Για κάθε αρχιτεκτονική υλοποιούνται δύο αλγόριθμοι με θεμελιωδώς διαφορετική συμπεριφορά: η περικομμένη διτονική ταξινόμηση, η οποία εκτελεί σταθερή ακολουθία συγκρίσεων ανεξάρτητη από τα δεδομένα, και η επιλογή με τοπικούς σωρούς κατά το σχήμα map-reduce, της οποίας η εργασία προσαρμόζεται στις τιμές της εισόδου. Και οι έξι υλοποιήσεις μετρώνται στον ίδιο παραμετρικό χώρο, με κοινή υποδομή, κοινό έλεγχο ορθότητας και κοινή σημασιολογία μέτρησης, ώστε οι διαφορές που προκύπτουν να αποδίδονται στους αλγορίθμους και στο υλικό, μα όχι στον τρόπο μέτρησης.

Το ερώτημα που τίθεται δεν είναι απλώς ποια αρχιτεκτονική είναι ταχύτερη, αλλά αν και υπό ποιες συνθήκες συμφέρει η ανάθεση του υπολογισμού σε επιταχυντή, όταν προσμετρηθεί ολόκληρο το κόστος της ανάθεσης και όχι μόνο ο χρόνος του πυρήνα. Όπως θα φανεί, οι δύο διατυπώσεις του ερωτήματος δίνουν διαφορετικές απαντήσεις.

1.2 Κίνητρο

Οι μονάδες νευρωνικής επεξεργασίας έπαψαν πρόσφατα να αποτελούν εξοπλισμό κέντρων δεδομένων. Πλέον ενσωματώνονται στην ίδια ψηφίδα με τον επεξεργαστή φορητών υπολογιστών ευρείας κατανάλωσης, μοιράζονται την ίδια κύρια μνήμη και είναι διαθέσιμες σε κάθε εφαρμογή που θα μπορούσε να τις αξιοποιήσει. Το ερώτημα «αξίζει να ανατεθεί αυτός ο υπολογισμός στη μονάδα;» μετατοπίστηκε έτσι από τον σχεδιασμό υποδομών στην καθημερινή πρακτική του προγραμματιστή.

Η απάντηση δεν είναι προφανής, διότι οι μονάδες αυτές σχεδιάστηκαν για συγκεκριμένο σκοπό: το οικοσύστημα λογισμικού τους είναι οργανωμένο γύρω από τελεστές νευρωνικών δικτύων και η αρχιτεκτονική τους βασίζεται στην παραδοχή ότι κάθε δεδομένο που μεταφέρεται θα χρησιμοποιηθεί πολλές φορές. Τι συμβαίνει όταν το φορτίο δεν έχει αυτή τη μορφή παραμένει σε μεγάλο βαθμό ανεξερεύνητο.

Η επιλογή top-k αποτελεί κατάλληλο μέσο για να τεθεί το ερώτημα. Είναι πρόβλημα απλό στη διατύπωση και διαδεδομένο στην πράξη, καθώς εμφανίζεται στην αναζήτηση πλησιέστερων γειτόνων, στα συστήματα ανάκτησης και συστάσεων και στη δειγματοληψία των γλωσσικών μοντέλων. Ταυτόχρονα βρίσκεται στο αντίθετο άκρο του φάσματος από τα φορτία για τα οποία σχεδιάστηκαν οι επιταχυντές: εκτελεί ελάχιστες πράξεις ανά στοιχείο και δεν επαναχρησιμοποιεί σχεδόν τίποτα. Αν η ανάθεση συμφέρει ακόμη και εδώ, θα συμφέρει σχεδόν παντού· αν δεν συμφέρει, έχουμε σαφή ένδειξη για τα όρια της χρησιμότητας των μονάδων αυτών.

Το δεύτερο, και ανεξάρτητο, κίνητρο είναι μεθοδολογικό. Οι συγκρίσεις επιταχυντών αναφέρουν συνήθως τον χρόνο εκτέλεσης του πυρήνα, αποκρύπτοντας το κόστος μεταφοράς των δεδομένων από και προς τη συσκευή - το κόστος που όμως κρίνει αν η ανάθεση συμφέρει. Η εργασία μετρά συστηματικά και τα δύο, και δείχνει ότι η επιλογή του ορίου μέτρησης δεν μεταβάλλει απλώς τα νούμερα, αλλά ανατρέπει πλήρως την κατάταξη των αρχιτεκτονικών.

1.3 Συνεισφορά

Η συνεισφορά της εργασίας είναι τετραπλή.

Υλοποιήσεις. Κατασκευάστηκαν έξι υλοποιήσεις, δύο αλγόριθμοι επί τριών αρχιτεκτονικών, με υποστήριξη πέντε τύπων δεδομένων. Η υλοποίηση στον επεξεργαστή αξιοποιεί τις διανυσματικές επεκτάσεις AVX-512 και πολλαπλά νήματα, εκείνη της μονάδας γραφικών χρησιμοποιεί οργάνωση σε πλακίδια με κοινή μνήμη, ενώ εκείνη της μονάδας νευρωνικής επεξεργασίας κατασκευάστηκε εξ ολοκλήρου στο επίπεδο του πλαισίου MLIR-AIE. Η ορθότητα κάθε συνδυασμού επαληθεύτηκε σε 2700 περιπτώσεις, όλες επιτυχείς.

Υποδομή μέτρησης. Αναπτύχθηκε υποδομή που μετρά κάθε περίπτωση σε δύο ρητά διακριτά πεδία, το αλγοριθμικό και το end-to-end. Καταγράφει ενέργεια με κοινή σημασιολογία και στις τρεις αρχιτεκτονικές, καταμετρά τον όγκο των δεδομένων που διακινούνται και τοποθετεί κάθε εκτέλεση σε οροφή που έχει μετρηθεί στο ίδιο μηχάνημα. Η υποδομή είναι ανεξάρτητη από το συγκεκριμένο πρόβλημα και εφαρμόσιμη σε οποιοδήποτε φορτίο εξετάζεται για ανάθεση σε επιταχυντή.

Ευρήματα. Η πειραματική αποτίμηση καταλήγει σε τέσσερα συμπεράσματα. Η επιλογή top-k είναι πρόβλημα κίνησης δεδομένων σε κάθε αρχιτεκτονική που εξετάστηκε και καμία υλοποίηση δεν περιορίζεται από την υπολογιστική ικανότητα. Η κατάταξη των δύο αλγορίθμων ανατρέπει με τον λόγο n/k και όχι με την αρχιτεκτονική, με διαφορά που φτάνει τις τρεις τάξεις μεγέθους. Η επιλογή του ορίου μέτρησης ανατρέπει πλήρως την κατάταξη των αρχιτεκτονικών. Τέλος, χαμηλή κατανάλωση ισχύος δεν συνεπάγεται χαμηλή κατανάλωση ενέργειας: η μονάδα νευρωνικής επεξεργασίας έχει τη χαμηλότερη ισχύ από όλες τις υλοποιήσεις και ταυτόχρονα καταναλώνει πολλαπλάσια ενέργεια, διότι χρειάζεται πολλαπλάσιο χρόνο.

Αναπαραγωγιμότητα. Ολόκληρη η πειραματική διαδικασία, από την κατασκευή των εκτελέσιμων έως την παραγωγή των διαγραμμάτων, εκτελείται από δέσμες εντολών

που περιλαμβάνονται στο αποθετήριο. Οι συνθήκες μέτρησης σταθεροποιούνται ρητά και καταγράφονται μαζί με τα αποτελέσματα. Οι λεπτομέρειες δίνονται στο παράρτημα Γ'.

1.4 Δομή της εργασίας

Το κεφάλαιο 2 ορίζει το πρόβλημα, παρουσιάζει τις οικογένειες αλγορίθμων που το λύνουν και περιγράφει τα εκτελεστικά μοντέλα των τριών αρχιτεκτονικών, καταλήγοντας στις υπάρχουσες υλοποιήσεις και στο κενό που η εργασία καλείται να καλύψει.

Το κεφάλαιο 3 περιγράφει το σύστημα αναφοράς και την πειραματική διάταξη: τι ακριβώς μετριέται, με ποια σημασιολογία, με ποια μέτρα σύγκρισης και υπό ποιες συνθήκες - προϋπόθεση για την ανάγνωση των αποτελεσμάτων.

Τα κεφάλαια 4, 5 και 6 παρουσιάζουν τις υλοποιήσεις σε καθεμία από τις τρεις αρχιτεκτονικές. Ακολουθούν κοινή δομή, ώστε οι αντίστοιχες ενότητες να μπορούν να συγκριθούν άμεσα: σχεδιαστικές επιλογές, οι δύο αλγόριθμοι, διαχείριση μνήμης και κίνηση δεδομένων, υλοποίηση αναφοράς και, τέλος, οι περιοριστικοί παράγοντες που εντοπίστηκαν.

Το κεφάλαιο 7 παρουσιάζει και ερμηνεύει τα αποτελέσματα: ορθότητα, χρόνο εκτέλεσης, σύγκριση αρχιτεκτονικών, ανάλυση με το μοντέλο roofline, ενεργειακή αποτίμηση και, τέλος, την επίδραση του τύπου δεδομένων και της κατανομής της εισόδου.

Το κεφάλαιο 8 συνοψίζει όσα γενικεύονται, δηλώνει τα όρια εντός των οποίων ισχύουν και προτείνει κατευθύνσεις συνέχειας.

Τα παραρτήματα περιλαμβάνουν κατάλογο ακρωνυμίων, γλωσσάρι των ελληνικών όρων με τους αγγλικούς αντίστοιχούς τους και οδηγίες αναπαραγωγής των μετρήσεων.

Κεφάλαιο 2

Υπόβαθρο και σχετική εργασία

Το κεφάλαιο αυτό ορίζει το πρόβλημα, παρουσιάζει τις οικογένειες αλγορίθμων που το λύνουν και περιγράφει τα εκτελεστικά μοντέλα των τριών αρχιτεκτονικών, θεμελιώνοντας μόνο όσα χρειάζονται για να διαβαστούν τα κεφάλαια 4 έως 6, όπου παρουσιάζονται οι συγκεκριμένες υλοποιήσεις της εργασίας.

2.1 Το πρόβλημα της επιλογής top-k

Δοθέντος πίνακα A με n στοιχεία από ένα ολικά διατεταγμένο σύνολο και ενός ακεραίου $k \leq n$, το πρόβλημα της επιλογής top-k ζητά το υποσύνολο των k μεγαλύτερων στοιχείων του A . Η εργασία εξετάζει τη μορφή που ζητά μόνο το σύνολο αυτό και όχι τη σειρά των στοιχείων εντός του, καθώς αυτή είναι η μορφή που απαιτούν οι εφαρμογές και η μόνη ως προς την οποία μπορούν να συγκριθούν δίκαια αλγόριθμοι με διαφορετική εσωτερική οργάνωση. Κάθε υλοποίηση της εργασίας ταξινομεί επιπλέον τα k αποτελέσματά της πριν τα επιστρέψει. Αυτό κοστίζει $O(k \log k)$, αμελητέο έναντι του $O(n)$ της ίδιας της επιλογής, και δίνει μία ενιαία, ελέγξιμη απάντηση αντί για μια αυθαίρετη διάταξη του συνόλου.

Η κρίσιμη παρατήρηση είναι ότι το πρόβλημα ζητά αυστηρά λιγότερη πληροφορία από την ταξινόμηση. Η πλήρης ταξινόμηση προσδιορίζει τη σχετική σειρά και των n στοιχείων, ενώ η επιλογή αρκείται στον διαχωρισμό τους σε δύο ομάδες. Η διαφορά αυτή αποτυπώνεται στα κάτω φράγματα: κάθε αλγόριθμος βασισμένος σε συγκρίσεις απαιτεί $\Omega(n \log n)$ συγκρίσεις για ταξινόμηση, αλλά μόνο $\Theta(n)$ για επιλογή με σταθερό k [1]. Η επιλογή είναι επομένως ουσιωδώς φθηνότερη, και κάθε υλοποίηση που ταξινομεί ολόκληρη την είσοδο για να κρατήσει k στοιχεία επιτελεί περισσότερη εργασία από όση απαιτεί το πρόβλημα.

Το σχήμα 2.1 αποτυπώνει τη διαφορά.



Σχήμα 2.1: Η ίδια είσοδος υπό τις δύο απαιτήσεις. Η ταξινόμηση (α) προσδιορίζει και τις n θέσεις, ενώ η επιλογή (β) διαχωρίζει τα στοιχεία σε δύο ομάδες μόνο: τα k μεγαλύτερα, σε οποιαδήποτε σειρά, και τα υπόλοιπα, για τα οποία δεν κρατείται καμία πληροφορία σειράς.

Η απόσταση αυτή εξαρτάται από τον λόγο k/n : όταν το k είναι πολύ μικρότερο του n , η επιλογή είναι σχεδόν γραμμική και η ταξινόμηση σπαταλά σχεδόν όλη της την εργασία, ενώ καθώς το k πλησιάζει το n τα δύο προβλήματα σχεδόν ταυτίζονται και το περιθώριο εξαφανίζεται. Ολόκληρη η εργασία κινείται μεταξύ των δύο αυτών άκρων, και το κεφάλαιο 7 δείχνει ότι η κατάταξη των αλγορίθμων ανατρέπεται καθώς διανύεται η απόσταση.

Το πρόβλημα εμφανίζεται σε πλήθος εφαρμογών. Η αναζήτηση των k πλησιέστερων γειτόνων απαιτεί την επιλογή των μικρότερων αποστάσεων από έναν πίνακα αποστάσεων [2]. Τα συστήματα ανάκτησης πληροφορίας και συστάσεων επιστρέφουν τα k καλύτερα αποτελέσματα ενός ερωτήματος. Στα γλωσσικά μοντέλα, η δειγματοληψία top- k και η αναζήτηση δέσμης εκτελούν επιλογή σε κάθε βήμα παραγωγής. Κοινό χαρακτηριστικό των περιπτώσεων αυτών είναι ότι η επιλογή δεν αποτελεί το κύριο φορτίο αλλά επαναλαμβάνεται συχνά, οπότε το κόστος της είναι αισθητό ακριβώς επειδή προστίθεται σε κάθε επανάληψη.

2.2 Αλγόριθμοι επιλογής

Οι αλγόριθμοι επιλογής διακρίνονται σε οικογένειες με βάση ένα κριτήριο καθοριστικό για την επιτάχυνση: αν η ακολουθία των πράξεων εξαρτάται από τις τιμές των δεδομένων ή όχι. Ένας αλγόριθμος του οποίου το χρονοδιάγραμμα είναι σταθερό εκτελεί τις ίδιες πράξεις με την ίδια σειρά ανεξάρτητα από την είσοδο. Ένας αλγόριθμος που εξαρτάται από τα δεδομένα προσαρμόζει την πορεία του, εκτελώντας λιγότερη εργασία σε ευνοϊκές εισόδους και περισσότερη σε δυσμενείς.

Η διάκριση αυτή, η οποία αντιστοιχεί στην καθιερωμένη ταξινόμηση των παράλληλων αλγορίθμων επιλογής σε ταξινόμηση, μερική ταξινόμηση και μεθόδους διαμέρισης [3], δεν αφορά μόνο τη θεωρητική πολυπλοκότητα. Καθορίζει ποιο υλικό μπορεί να εκτελέσει αποδοτικά τον αλγόριθμο, διότι οι παράλληλες αρχιτεκτονικές προϋποθέτουν ότι πολλά στοιχεία επεξεργασίας εκτελούν την ίδια εντολή. Καθορίζει επίσης αν ο χρόνος εκτέλεσης είναι προβλέψιμος, ζήτημα που εξετάζεται πειραματικά στην ενότητα 7.7.

2.2.1 Δίκτυα διτονικής ταξινόμησης

Ένα δίκτυο ταξινόμησης είναι μια σταθερή ακολουθία συγκριτών. Κάθε συγκριτής δέχεται δύο θέσεις του πίνακα, συγκρίνει τα περιεχόμενά τους και τα ανταλλάσσει αν βρίσκονται σε λάθος σειρά. Οι θέσεις που συγκρίνει καθορίζονται εκ των προτέρων και δεν εξαρτώνται από τις τιμές, γεγονός που καθιστά το δίκτυο το τυπικό παράδειγμα αλγορίθμου ανεξάρτητου από τα δεδομένα. Η ίδια ακολουθία συγκρίσεων εκτελείται πάντοτε, και το μόνο που αλλάζει είναι το αποτέλεσμα κάθε σύγκρισης.

Οι συγκριτές οργανώνονται σε *επίπεδα*. Εντός ενός επιπέδου καμία θέση δεν εμφανίζεται σε δύο συγκριτές, οπότε όλοι οι συγκριτές του επιπέδου μπορούν να εκτελεστούν ταυτόχρονα. Τα επίπεδα όμως πρέπει να εκτελεστούν διαδοχικά, οπότε το πλήθος τους αποτελεί το βάθος του δικτύου και ορίζει το κάτω φράγμα του χρόνου σε απεριόριστα παράλληλο υλικό.

Η κατασκευή του Batcher στηρίζεται στην έννοια της διτονικής ακολουθίας [4]: μιας ακολουθίας που πρώτα αυξάνει και έπειτα μειώνεται, ή που προκύπτει από μια τέτοια με κυκλική ολίσθηση. Η θεμελιώδης ιδιότητα είναι ότι μια διτονική ακολουθία μήκους $2m$ μπορεί να ταξινομηθεί με $\log_2(2m)$ επίπεδα: συγκρίνοντας κάθε στοιχείο με εκείνο που απέχει m θέσεις προκύπτουν δύο διτονικές ακολουθίες μήκους m , από τις οποίες κάθε στοιχείο της πρώτης είναι μικρότερο ή ίσο από κάθε στοιχείο της δεύτερης. Οι δύο μισές ακολουθίες ταξινομούνται στη συνέχεια ανεξάρτητα με την ίδια διαδικασία.

Η πλήρης ταξινόμηση n στοιχείων προκύπτει με διαδοχική εφαρμογή: ζεύγη ταξινομημένων μπλοκ αντίθετης φοράς σχηματίζουν διτονική ακολουθία διπλάσιου μήκους, η οποία ταξινομείται και δίνει μπλοκ διπλάσιου μεγέθους. Το δίκτυο έχει $\log_2 n (\log_2 n + 1)/2$ επίπεδα και $n/2$ συγκριτές ανά επίπεδο, δηλαδή $O(n \log^2 n)$ συγκριτές συνολικά. Πρόκειται για παράγοντα $\log n$ μεγαλύτερο από το φράγμα $O(n \log n)$ που πετυχαίνουν οι σειριακοί αλγόριθμοι ταξινόμησης, οπότε η διτονική ταξινόμηση εκτελεί περισσότερες συγκρίσεις από όσες χρειάζονται. Το αντάλλαγμα είναι ότι οι συγκρίσεις αυτές είναι πλήρως προκαθορισμένες και ομοιόμορφες, εκτελέσιμες σε διανυσματικές μονάδες, σε μοντέλα SIMT και σε διατάξεις ροής δεδομένων χωρίς καμία απόκλιση ροής ελέγχου. Αυτή η ανταλλαγή, περισσότερες πράξεις έναντι τέλειας κανονικότητας, είναι ο λόγος για τον οποίο τα δίκτυα ταξινόμησης παραμένουν ανταγωνιστικά σε παράλληλο υλικό παρά την ασυμπτωτική τους μειονεξία.

2.2.2 Περικομμένη διτονική ταξινόμηση

Η πλήρης ταξινόμηση παράγει πολύ περισσότερη πληροφορία από όση ζητά η επιλογή. Η περικομμένη διτονική ταξινόμηση εκμεταλλεύεται το γεγονός αυτό απορρίπτοντας στοιχεία μόλις αποδειχθεί ότι δεν μπορούν να ανήκουν στο αποτέλεσμα [2]. Η ίδια ιδέα, της μείωσης του ενεργού πίνακα στο μισό σε κάθε βήμα, αποτελεί τη βάση και των υλοποιήσεων μερικής ταξινόμησης για μονάδες γραφικών [5].

Το σχήμα 2.2 αντιπαραθέτει τις δύο δομές. Έστω k' η μικρότερη δύναμη του δύο που δεν είναι μικρότερη του k . Η διαδικασία έχει δύο φάσεις: στην πρώτη εκτελείται κανονική διτονική ταξινόμηση, αλλά σταματά μόλις σχηματιστούν ταξινομημένα μπλοκ μεγέθους k' αντί να συνεχίσει έως το μοναδικό μπλοκ μεγέθους n . Στη δεύτερη, τα μπλοκ συγχωνεύονται ανά ζεύγη, και από τα $2k'$ στοιχεία κάθε ζεύγους κρατούνται μόνο τα k' μεγαλύτερα, με τα υπόλοιπα να απορρίπτονται οριστικά. Το βήμα αυτό υποδιπλασιάζει το μέγεθος του ενεργού πίνακα και επαναλαμβάνεται έως ότου απομείνει

ένα μπλοκ, το οποίο περιέχει το ζητούμενο αποτέλεσμα.


Η ορθότητα της απόρριψης είναι άμεση: αν ένα στοιχείο δεν ανήκει στα k' μεγαλύτερα δύο ταξινομημένων μπλοκ, τότε υπάρχουν ήδη k' στοιχεία μεγαλύτερα από αυτό στον πίνακα, οπότε δεν μπορεί να ανήκει στα k μεγαλύτερα του συνόλου.

Το κέρδος είναι διπλό. Η πρώτη φάση απαιτεί $\log_2 k' (\log_2 k' + 1)/2$ επίπεδα αντί για $\log_2 n (\log_2 n + 1)/2$, πλήθος που εξαρτάται από το k και όχι από το n . Τα επίπεδα της δεύτερης φάσης, από την άλλη, δρουν σε πίνακα που συρρικνώνεται γεωμετρικά, οπότε το κόστος τους αθροίζεται σε γραμμικό ως προς n όρο. Η συνολική πολυπλοκότητα πέφτει από $O(n \log^2 n)$ σε $O(n \log^2 k)$.

Για $n = 2^{24}$ και k ίσο με 8 το πλήρες δίκτυο έχει 300 επίπεδα και 2 516 582 400 συγκριτές, ενώ το περικομμένο έχει 90 επίπεδα και 92 274 668 συγκριτές, δηλαδή είκοσι επτά φορές λιγότερους. Για k ίσο με 131072 όμως τα μεγέθη είναι 279 επίπεδα και 1 441 595 392 συγκριτές, μόλις 1,7 φορές λιγότεροι από το πλήρες δίκτυο: το όφελος της περικοπής εξανεμίζεται καθώς το k μεγαλώνει, γεγονός που εξηγεί εν μέρει τη συμπεριφορά που καταγράφεται στην ενότητα 7.2.2.


Καθοριστικό είναι ότι η περικοπή δεν θυσιάζει την ανεξαρτησία από τα δεδομένα: ποια στοιχεία απορρίπτονται εξαρτάται από τις τιμές, αλλά πόσα και σε ποια βήματα δεν εξαρτάται, καθώς το χρονοδιάγραμμα των επιπέδων υπολογίζεται εκ των προτέρων από τα n και k μόνο. Η ιδιότητα αυτή διατηρεί την καταλληλότητα για παράλληλο υλικό και επιβεβαιώνεται πειραματικά στην ενότητα 7.7, όπου η υλοποίηση εμφανίζει διακύμανση κάτω του δώδεκα τοις εκατό μεταξύ πέντε πολύ διαφορετικών κατανομών εισόδου.

(α) πλήρες διτονικό δίκτυο, $n = 8$



Το βέλος δείχνει πού τοποθετείται το μεγαλύτερο από τα δύο στοιχεία.

(β) περικομμένο δίκτυο, $n = 16, k' = 4$



Κάθε συγχώνευση δέχεται $2k'$ στοιχεία και κρατά τα k' μεγαλύτερα· τα υπόλοιπα (διακεκομμένη) απορρίπτονται οριστικά.

Σχήμα 2.2: Το πλήρες διτονικό δίκτυο και η περικοπή του. Στο (α) κάθε οριζόντια γραμμή είναι μια θέση του πίνακα και κάθε κατακόρυφο βέλος μια σύγκριση-ανταλλαγή. Το δίκτυο είναι ανεξάρτητο από τα δεδομένα, καθώς εκτελεί πάντοτε την ίδια ακολουθία συγκρίσεων με την ίδια σειρά, όποιες και αν είναι οι τιμές. Στο (β), όταν ζητούνται μόνο τα k' καλύτερα στοιχεία, η πρώτη φάση σταματά μόλις σχηματιστούν ταξινομημένα μπλοκ μεγέθους k' , και στη δεύτερη κάθε συγχώνευση ζεύγους κρατά μόνο τα k' καλύτερα από τα $2k'$ που συγκρίθηκαν. Το μέγεθος του πίνακα υποδιπλασιάζεται σε κάθε βήμα, οπότε τα επόμενα βήματα κοστίζουν ολοένα λιγότερο.

2.2.3 Επιλογή με σωρούς και map-reduce


Η δεύτερη οικογένεια ακολουθεί αντίθετη λογική: αντί να επιβάλει σταθερό χρονοδιάγραμμα, διατηρεί μια δομή με τα k καλύτερα στοιχεία που έχουν εξεταστεί μέχρι στιγμής και την ενημερώνει μόνο όταν χρειάζεται.

Η δομή είναι σωρός ελαχίστου χωρητικότητας k . Η ρίζα του συγκρατεί το μικρότερο από τα k τρέχοντα καλύτερα στοιχεία και λειτουργεί ως κατώφλι εισόδου: για κάθε νέο στοιχείο εκτελείται μία σύγκριση με τη ρίζα, και αν το στοιχείο δεν την υπερβαίνει, απορρίπτεται χωρίς καμία περαιτέρω εργασία. Διαφορετικά αντικαθιστά τη ρίζα και ο σωρός αναδιατάσσεται σε $O(\log k)$ βήματα.

Η ασυμμετρία μεταξύ των δύο περιπτώσεων καθορίζει τη συμπεριφορά του αλγορίθμου. Σε τυχαία είσοδο το κατώφλι ανεβαίνει γρήγορα και η συντριπτική πλειονότητα των στοιχείων απορρίπτεται με μία σύγκριση, οπότε ο συνολικός χρόνος πλησιάζει το γραμμικό. Σε αύξουσα είσοδο όμως κάθε νέο στοιχείο υπερβαίνει τη ρίζα και επιβάλλει αναδιάταξη, δίνοντας $O(n \log k)$ στη χειρότερη περίπτωση. Ο ίδιος κώδικας εκτελεί δηλαδή θεμελιωδώς διαφορετικό όγκο εργασίας ανάλογα με τη σειρά εμφάνισης των τιμών, και η ενότητα 7.7 μετρά τη διαφορά αυτή σε παράγοντα εβδομήντα δύο.

Η παραλληλοποίηση ακολουθεί το σχήμα map-reduce, όπως δείχνει το σχήμα 2.3: στη

φάση map η είσοδος διαμερίζεται και κάθε εργάτης διατηρεί δικό του τοπικό σωρό, χωρίς συγχρονισμό με τους υπόλοιπους, και στη φάση reduce τα μερικά αποτελέσματα συγχωνεύονται σε ένα. Το σχήμα είναι ελκυστικό διότι η φάση map δεν απαιτεί καμία επικοινωνία, αλλά επιβάλλει ένα όριο που αποδεικνύεται κρίσιμο: κάθε τοπικός σωρός πρέπει πρώτα να γεμίσει με k στοιχεία για να αρχίσει να φιλτράρει, οπότε το πλήθος των εργατών που συνεισφέρουν πραγματικά δεν μπορεί να ξεπεράσει τον λόγο n/k . Το όριο αυτό είναι αμελητέο σε επεξεργαστή με οκτώ νήματα, αλλά καταστροφικό σε μονάδα γραφικών με χιλιάδες, όπως αναλύεται στην ενότητα 5.3.1.



Σχήμα 2.3: Η επιλογή με σωρούς και η παραλληλοποίησή της. Στο (α) η ρίζα του σωρού ελαχίστου λειτουργεί ως κατώφλι: το στοιχείο που δεν την υπερβαίνει απορρίπτεται με μία σύγκριση, ενώ εκείνο που την υπερβαίνει την αντικαθιστά και επιβάλλει κατολίσθηση. Στο (β) η είσοδος διαμερίζεται σε τμήματα, ένας σωρός ανά εργάτη και τα μερικά αποτελέσματα συγχωνεύονται σε ένα.

2.2.4 Επιλογή με βάση την αναπαράσταση


Η τρίτη οικογένεια δεν συγκρίνει τα στοιχεία μεταξύ τους αλλά εξετάζει τη δυαδική αναπαράστασή τους. Οι τιμές κατανέμονται σε κάδους ανάλογα με μια ομάδα ψηφίων, τα πλήθη των κάδων αθροίζονται και από αυτά προκύπτει σε ποιον κάδο βρίσκεται το k -οστό μεγαλύτερο στοιχείο: οι υπερκείμενοι κάδοι ανήκουν εξ ολοκλήρου στο αποτέλεσμα, οι υποκείμενοι απορρίπτονται εξ ολοκλήρου, και η αναζήτηση συνεχίζεται μόνο εντός του κρίσιμου κάδου με την επόμενη ομάδα ψηφίων.

Η διαδικασία φαίνεται στο σχήμα 2.4. Δύο ιδιότητες ξεχωρίζουν: το πλήθος των περασμάτων καθορίζεται από το πλάτος του τύπου δεδομένων και όχι από το k , οπότε η μέθοδος δεν εμφανίζει κανένα σημείο κατάρρευσης καθώς το k μεγαλώνει, και κάθε πέρασμα είναι ακολουθιακή ανάγνωση με μέτρηση συχνοτήτων, μοτίβο ιδιαίτερα ευνοϊκό για αρχιτεκτονικές υψηλού εύρους ζώνης.

Η μέθοδος εξαρτάται και αυτή από τα δεδομένα, αλλά με τρόπο διαφορετικό από τους σωρούς: κρίσιμη δεν είναι η σειρά εμφάνισης των τιμών, αλλά η κατανομή των ψηφίων τους. Όταν πολλά στοιχεία μοιράζονται τα ίδια σημαντικά ψηφία, ο κρίσιμος κάδος στενεύει αργά και απαιτούνται περισσότερα περάσματα. Η περίπτωση αυτή είναι γνωστή

στη βιβλιογραφία ως radix-adversarial κατανομή και αντιμετωπίζεται με προσαρμοστικές στρατηγικές αποθήκευσης υποψηφίων [3]. Η οικογένεια αυτή δεν υλοποιήθηκε στην παρούσα εργασία, αλλά αποτελεί τη βάση της βιβλιοθήκης αναφοράς της μονάδας γραφικών και εξετάζεται αναλυτικότερα στην ενότητα 5.5.1.

πέρασμα 1: τα 2 σημαντικότερα ψηφία



πέρασμα 2



Σχήμα 2.4: Η επιλογή με βάση την αναπαράσταση. Σε κάθε πέρασμα τα στοιχεία κατανέμονται σε κάδους ανάλογα με μια ομάδα ψηφίων και μετράται το πλήθος καθενός· από τα αθροιστικά πλήθη προκύπτει ποιοι κάδοι ανήκουν εξ ολοκλήρου στο αποτέλεσμα, ποιοι απορρίπτονται και ποιος είναι ο *κρίσιμος*. Καμία σύγκριση μεταξύ τιμών δεν εκτελείται ποτέ.

2.3 Αρχιτεκτονικές επεξεργασίας

Οι τρεις αρχιτεκτονικές που εξετάζει η εργασία εκθέτουν παραλληλία με θεμελιωδώς διαφορετικό τρόπο. Η ενότητα αυτή περιγράφει τα εκτελεστικά τους μοντέλα στον βαθμό που απαιτείται για να γίνουν κατανοητές οι σχεδιαστικές επιλογές των κεφαλαίων 4 έως 6.

2.3.1 Διανυσματικές επεκτάσεις CPU

Ο σύγχρονος επεξεργαστής γενικού σκοπού συνδυάζει δύο μορφές παραλληλίας: τα πολλαπλά νήματα, καθένα από τα οποία εκτελεί ανεξάρτητη ροή εντολών, και τις διανυσματικές επεκτάσεις, οι οποίες εφαρμόζουν την ίδια πράξη σε πολλά δεδομένα ταυτόχρονα εντός ενός νήματος.

Ένας καταχωρητής AVX-512 έχει πλάτος 512 bit και συγκρατεί δεκαέξι ακεραίους των 32 bit. Το ρεπερτόριο περιλαμβάνει, πέρα από τις αριθμητικές πράξεις, εντολές αναδιάταξης που μεταθέτουν στοιχεία εντός του καταχωρητή και εντολές ελαχίστου και μεγίστου που επιλέγουν κατά στοιχείο χωρίς διακλάδωση. Ο συνδυασμός αναδιάταξης, ελαχίστου και μεγίστου υλοποιεί ακριβώς έναν συγκριτή δικτύου ταξινόμησης, γεγονός που καθιστά τη διτονική ταξινόμηση φυσικό υποψήφιο για διανυσματοποίηση.

Ο περιοριστικός παράγοντας δεν είναι συνήθως ο ρυθμός των πράξεων αλλά η τροφοδοσία τους με δεδομένα. Η ιεραρχία κρυφών μνημών αντισταθμίζει εν μέρει τη διαφορά ταχύτητας από την κύρια μνήμη, αλλά μόνο για αλγορίθμους που επαναχρησιμοποιούν τα δεδομένα όσο αυτά βρίσκονται σε κοντινό επίπεδο. Ένας αλγόριθμος που εκτελεί πολλά διαδοχικά περάσματα πάνω σε ολόκληρο τον πίνακα, όπως η αφελής μεταφορά ενός δικτύου ταξινόμησης σε κώδικα, δεν επωφελείται καθόλου. Η αντιμετώπιση του προβλήματος αυτού είναι το κεντρικό θέμα της ενότητας 4.2.

2.3.2 Μοντέλο SIMT και ιεραρχία μνήμης GPU

Η μονάδα γραφικών οργανώνεται γύρω από το μοντέλο SIMT. Τα νήματα ομαδοποιούνται σε δέσμες που εκτελούν την ίδια εντολή σε διαφορετικά δεδομένα. Όταν τα νήματα μιας δέσμης ακολουθήσουν διαφορετικούς κλάδους, οι κλάδοι εκτελούνται σειριακά με τα ανενεργά νήματα απενεργοποιημένα, οπότε η απόκλιση ροής ελέγχου κοστίζει άμεσα και οι αλγόριθμοι χωρίς διακλαδώσεις πλεονεκτούν.

Οι δέσμες ομαδοποιούνται σε ομάδες νημάτων και οι ομάδες σε πλέγμα. Κάθε ομάδα διαθέτει κοινή μνήμη, μια μικρή περιοχή διαχειριζόμενη ρητά από το λογισμικό, με καθυστέρηση πολύ μικρότερη της καθολικής μνήμης. Αυτό είναι το εργαλείο με το οποίο ένας αλγόριθμος πολλών περασμάτων μετατρέπεται σε αλγόριθμο ενός περάσματος: αν το τμήμα δεδομένων που επεξεργάζεται μια ομάδα χωρά εκεί, όλα τα ενδιαμέσα βήματα εκτελούνται χωρίς επιστροφή στην καθολική μνήμη.

Η πρόσβαση στην καθολική μνήμη είναι αποδοτική μόνο όταν τα νήματα μιας δέσμης ζητούν διαδοχικές διευθύνσεις, οπότε οι επιμέρους αιτήσεις συγχωνεύονται σε λίγες συναλλαγές. Τέλος, η μονάδα γραφικών είναι διακριτή συσκευή: τα δεδομένα πρέπει να μεταφερθούν από και προς τη μνήμη της μέσω διαύλου του οποίου το εύρος ζώνης είναι τάξη μεγέθους μικρότερο από εκείνο της τοπικής μνήμης, και αυτή η μεταφορά είναι ο λόγος για τον οποίο η εργασία διακρίνει ρητά δύο πεδία μέτρησης, όπως ορίζεται στην ενότητα 3.3.1.

2.3.3 Αρχιτεκτονική ροής δεδομένων AIE

Ο όρος μονάδα νευρωνικής επεξεργασίας είχε διαφορετικές σημασίες ανά εποχή, από τις πρώτες προτάσεις για προσεγγιστικό υπολογισμό με στόχο την εξοικονόμηση ενέργειας [6, 7], έως τους αφιερωμένους επιταχυντές νευρωνικών δικτύων [8] των οποίων το πλεονέκτημα σε επιδόσεις ανά Watt έναντι επεξεργασιών και μονάδων γραφικών τεκμηριώθηκε με την ανάπτυξή τους σε κλίμακα κέντρου δεδομένων [9].

Καθοριστική για την κατανόηση των μονάδων αυτών είναι η αρχή σχεδίασης που διατυπώθηκε ρητά στην αρχιτεκτονική Eyeriss: η μετακίνηση ενός δεδομένου κοστίζει ενεργειακά τάξεις μεγέθους περισσότερο από την πράξη που θα εκτελεστεί πάνω του, οπότε η σχεδίαση πρέπει να οργανωθεί γύρω από τη μεγιστοποίηση της τοπικής επαναχρησιμοποίησης των δεδομένων [10]. Η αρχή αυτή δικαιώνεται πλήρως στη συνέλιξη και στον πολλαπλασιασμό πινάκων, όπου κάθε στοιχείο που φορτώνεται συμμετέχει σε πολλές πράξεις. Το πρόβλημα της επιλογής top-k βρίσκεται όμως στο ακριβώς αντίθετο άκρο: κάθε στοιχείο εξετάζεται ελάχιστες φορές και δεν υπάρχει ουσιαστικά καμία επαναχρησιμοποίηση προς εκμετάλλευση. Η παρατήρηση αυτή προδιαγράφει το βασικό εύρημα του κεφαλαίου 7 και επανέρχεται στην ενότητα 7.5.

Η αρχιτεκτονική που εξετάζει η εργασία ανήκει στην οικογένεια των AI Engines της AMD, η οποία εισήχθη με τα προσαρμοστικά συστήματα Versal [11] και ενσωματώθηκε στη συνέχεια, ως XDNA, σε επεξεργαστές γενικής χρήσης [12]. Η ενσωμάτωση αυτή είναι που καθιστά το ερώτημα της εργασίας πρακτικό: η μονάδα δεν είναι πλέον εξάρτημα κέντρου δεδομένων αλλά βρίσκεται στην ίδια ψηφίδα με τον επεξεργαστή ενός φορητού υπολογιστή, μοιράζεται την ίδια κύρια μνήμη και είναι διαθέσιμη σε κάθε εφαρμογή που θα μπορούσε να την αξιοποιήσει.

Το εκτελεστικό μοντέλο είναι χωρικό, θεμελιωδώς διαφορετικό από τα δύο προηγούμε-

να. Η μονάδα αποτελείται από διάταξη πλακιδίων, καθένα από τα οποία διαθέτει δικό του διανυσματικό επεξεργαστή και δική του τοπική μνήμη. Δεν υπάρχει κοινή μνήμη ούτε κρυφή μνήμη, οπότε η επικοινωνία γίνεται αποκλειστικά με ρητή μεταφορά δεδομένων μέσω δικτύου διασύνδεσης.

Η συνέπεια είναι ότι το πρόγραμμα δεν εκφράζεται ως ακολουθία πράξεων πάνω σε κοινό χώρο διευθύνσεων, αλλά ως γράφος υπολογιστικών πυρήνων συνδεδεμένων με κανάλια ροής: ο προγραμματιστής περιγράφει ποια πλακίδια εκτελούν ποιον πυρήνα και πώς ρέουν τα δεδομένα μεταξύ τους. Η αφαίρεση που χρησιμοποιεί η εργασία για τον σκοπό αυτό είναι το `object_fifo` του πλαισίου MLIR-AIE [13], το οποίο παρουσιάζεται στην ενότητα 6.1.2.

Δύο ιδιότητες του μοντέλου έχουν άμεσες συνέπειες για την επιλογή `top-k`. Το μέγεθος της τοπικής μνήμης κάθε πλακιδίου είναι μικρό και σταθερό, οπότε ο υπολογισμός πρέπει να τεμαχιστεί σε τμήματα που χωρούν σε αυτήν και τα μερικά αποτελέσματα να συγχωνευθούν αλλού. Η τροφοδοσία της διάταξης αποτελεί επίσης ευθύνη του `host`, ο οποίος πρέπει να προετοιμάσει και να προωθήσει κάθε τμήμα. Όταν ο υπολογισμός ανά στοιχείο είναι μικρός, όπως συμβαίνει στην επιλογή, το κόστος της τροφοδοσίας κυριαρχεί έναντι του κόστους του υπολογισμού. Η ενότητα 6.4.1 το επιβεβαιώνει με άμεση μέτρηση.

2.4 Υπάρχουσες υλοποιήσεις και βιβλιοθήκες

Η διαθεσιμότητα έτοιμων υλοποιήσεων διαφέρει δραματικά μεταξύ των τριών αρχιτεκτονικών και η ανισότητα αυτή διαμορφώνει τόσο το ερώτημα της εργασίας όσο και την επιλογή των μέτρων σύγκρισης της ενότητας 3.5.

Για τον επεξεργαστή, η πρότυπη βιβλιοθήκη της C++ προσφέρει τη `std::nth_element`, η οποία διαμερίζει τον πίνακα γύρω από το `k`-οστό στοιχείο σε αναμενόμενο γραμμικό χρόνο, και τη `std::partial_sort`, η οποία επιπλέον ταξινομεί το αποτέλεσμα διατηρώντας σωρό μεγέθους `k`. Και οι δύο είναι διαθέσιμες παντού και δοκιμασμένες, αλλά αυστηρά μονονηματικές: δεν αξιοποιούν ούτε τα πολλαπλά νήματα ούτε τις διανυσματικές επεκτάσεις του υλικού.

Για τη μονάδα γραφικών, η CUB του συνόλου βιβλιοθηκών CCCL [14] παρέχει τη `DeviceTopK`, υλοποίηση επιλογής με βάση την αναπαράσταση κατά την ενότητα 2.2.4. Πρόκειται για ώριμη και ιδιαίτερα βελτιστοποιημένη λύση, την οποία η εργασία χρησιμοποιεί ως μέτρο σύγκρισης χωρίς να επιχειρεί να την ξεπεράσει σε ολόκληρο το εύρος των παραμέτρων.

Η ένταση με την οποία εξαρτάται η επιλογή αλγορίθμου από το `k` αναγνωρίζεται και στη βιομηχανία: πρόσφατη εργασία για μονάδες γραφικών AMD διαπιστώνει ακριβώς την ίδια ανατροπή που καταγράφει η ενότητα 7.2.2 και την αντιμετωπίζει με προσαρμοστική στρατηγική, διτονική ταξινόμηση σε επίπεδο καταχωρητών για μικρό `k` και επιλογή με βάση την αναπαράσταση για μεγάλο, με εμπειρικά προσδιορισμένο σημείο μετάβασης [15]. Το γεγονός ότι μια ανεξάρτητη υλοποίηση σε διαφορετικό υλικό καταλήγει στην ίδια διάκριση ενισχύει το συμπέρασμα ότι η ανατροπή είναι ιδιότητα των αλγορίθμων και όχι της συγκεκριμένης πλατφόρμας.

Παράλληλα με τις ακριβείς μεθόδους αναπτύσσεται και μια διακριτή γραμμή *προσεγγιστικών* αλγορίθμων, οι οποίοι θυσιάζουν μέρος της ανάκλησης για ταχύτητα και απευ-

θύνονται κυρίως σε φορτία μηχανικής μάθησης, όπου η επιλογή top-k αποδεικνύεται συστηματικά στενωπός σε επιταχυντές σχεδιασμένους για πυκνό πολλαπλασιασμό πινάκων [16]. Η παρούσα εργασία περιορίζεται στην ακριβή επιλογή, όπως επιβάλλει ο έλεγχος ορθότητας της ενότητας 3.6.

Για τη μονάδα νευρωνικής επεξεργασίας δεν υπάρχει αντίστοιχη βιβλιοθήκη: το οικοσύστημα λογισμικού της είναι προσανατολισμένο σε τελεστές νευρωνικών δικτύων και δεν περιλαμβάνει πρωτογενή επιλογής top-k. Το πλησιέστερο διαθέσιμο υλικό είναι ένα επίσημο παράδειγμα διτονικής ταξινόμησης σε πλακίδιο AI Engine [17], το οποίο όμως εκτελεί *πλήρη* ταξινόμηση, μόνο για αριθμούς απλής ακρίβειας και για μεγέθη έως 1024 στοιχεία που χωρούν στην τοπική μνήμη ενός πλακιδίου. Η παρούσα εργασία αντιμετωπίζει αντ' αυτού επιλογή αντί ταξινόμησης, πέντε τύπους δεδομένων και εισόδους έως 2^{24} στοιχείων που απαιτούν διοχέτευση μέσω πολλαπλών πλακιδίων: ακριβώς το κενό που καλείται να καλύψει η εργασία αυτή.

Η απουσία έτοιμης λύσης έχει δύο συνέπειες: κάθε υλοποίηση πρέπει να κατασκευαστεί από το μηδέν στο επίπεδο του MLIR-AIE [13], γεγονός που καθιστά τη μονάδα το πιο απαιτητικό μέρος της εργασίας, και δεν υπάρχει φυσικό μέτρο σύγκρισης επί της συσκευής, οπότε η εργασία χρησιμοποιεί ως αναφορά την υλοποίηση του host, επιλογή που τεκμηριώνεται στην ενότητα 6.5.

Συνολικά, η βιβλιογραφία για την επιλογή top-k σε μονάδες γραφικών είναι εκτενής και καλύπτει τόσο μεθόδους βασισμένες σε δίκτυα ταξινόμησης όσο και μεθόδους βασισμένες στην αναπαράσταση [2, 15]. Αντιθέτως, η αντίστοιχη βιβλιογραφία για επιταχυντές ροής δεδομένων του τύπου AIE είναι περιορισμένη, καθώς οι μονάδες αυτές είναι πρόσφατες και η χρήση τους εστιάζει σε φορτία συνέλιξης και πολλαπλασιασμού πινάκων. Ακριβώς εκεί τοποθετείται η παρούσα εργασία.

Κεφάλαιο 3

Μεθοδολογία και πειραματική διάταξη

3.1 Σύστημα αναφοράς

Όλες οι μετρήσεις της εργασίας προέρχονται από ένα και μόνο σύστημα, το οποίο φέρει και τις τρεις αρχιτεκτονικές που συγκρίνονται: έναν επεξεργαστή γενικού σκοπού (CPU), μια διακριτή μονάδα γραφικών (GPU) και μια μονάδα νευρωνικής επεξεργασίας (NPU) ενσωματωμένη στην ίδια ψηφίδα με τον επεξεργαστή. Αυτό απομονώνει τις διαφορές των υλοποιήσεων από τις διαφορές των πλατφορμών, εισάγει όμως έναν περιορισμό: το σύστημα είναι φορητό, οπότε οι τρεις μονάδες μοιράζονται κοινό θερμικό και ενεργειακό όριο, ζήτημα που αντιμετωπίζεται όπως περιγράφεται στην ενότητα 3.8.

Σύστημα	Lenovo Legion 5 15AHP10
Λειτουργικό σύστημα	Arch Linux x86_64, πυρήνας 7.1.5-arch1-2
Κύρια μνήμη	32 GiB DDR5-5600, δύο κανάλια
CPU	AMD Ryzen 7 260
Πυρήνες / νήματα	8 / 16, έως 5.10 GHz
Κρυφή μνήμη	8 MiB L2, 16 MiB L3
Διανυσματικές επεκτάσεις	AVX-512
GPU	NVIDIA GeForce RTX 5060 Laptop
Μνήμη	8 GiB
Λογισμικό	driver 610.43.03, CUDA 13.3
Όρια ισχύος	50 W προεπιλογή, 115 W μέγιστο
NPU	AMD XDNA (RyzenAI-npu1)
Λογισμικό	XRT 2.21.75, firmware 1.5.5.391

Πίνακας 3.1: Το σύστημα αναφοράς στο οποίο εκτελέστηκαν όλες οι μετρήσεις.

Ο επεξεργαστής διαθέτει οκτώ φυσικούς πυρήνες με ταυτόχρονη πολυνηματικότητα. Όλες οι μετρήσεις εκτελούνται με ένα νήμα ανά φυσικό πυρήνα, ώστε να μη μοιράζονται δύο νήματα την ίδια διανυσματική μονάδα. Η ιεραρχία κρυφής μνήμης καθορίζει τα σημεία καμπίης της μετρημένης κλίμακας εύρους ζώνης (ενότητα 3.4): ανάλογα με το μέγεθος της εισόδου και τον τύπο δεδομένων, το σύνολο εργασίας μπορεί να χωρά στην

L2, στην L3 ή μόνο στην κύρια μνήμη, και κάθε υλοποίηση συγκρίνεται με το ταβάνι που αντιστοιχεί στο δικό της σύνολο εργασίας.

Η κύρια μνήμη είναι διατεταγμένη σε δύο πανομοιότυπες μονάδες των 16 GiB σε διπλό κανάλι, στα 5600 MT/s. Διάταξη ενός μόνο καναλιού θα υποδιπλασίαζε το διαθέσιμο εύρος ζώνης, οπότε μια υλοποίηση περιορισμένη από τη μνήμη θα έδινε ουσιαδώς διαφορετικά αποτελέσματα σε ένα κατά τα άλλα ίδιο σύστημα.

Η μονάδα νευρωνικής επεξεργασίας δεν διαθέτει δική της μνήμη. Τροφοδοτείται από την ίδια DDR5 και μέσω των ίδιων ελεγκτών μνήμης με τον επεξεργαστή, στην ίδια ψηφίδα πυριτίου. Αυτό έχει δύο συνέπειες που επανεμφανίζονται σε όλη την εργασία: το κόστος προετοιμασίας των δεδομένων στον host δεν είναι διαχωρίσιμο από το κόστος του υπολογισμού, και ο μετρητής ενέργειας που χρησιμοποιείται καλύπτει ολόκληρο το πακέτο και όχι τα πλακίδια AIE ξεχωριστά (ενότητα 3.3.3).

Τα στοιχεία του πίνακα 3.1 επαληθεύτηκαν από το ίδιο το σύστημα και όχι από φυλλάδια κατασκευαστή.

3.2 Δομή της υποδομής μετρήσεων


Η υποδομή μετρήσεων έχει τέσσερα επίπεδα, με μία αρχή να διατρέχει τον σχεδιασμό της: η διαδικασία της μέτρησης είναι κοινή για όλες τις αρχιτεκτονικές και μόνο ο υπολογιστικός πυρήνας διαφέρει, οπότε καμία υλοποίηση δεν ελέγχει τον τρόπο με τον οποίο μετρείται η ίδια.

Το πρώτο επίπεδο είναι ένας κοινός πυρήνας σε C++ που μοιράζονται και οι τρεις υλοποιήσεις. Διαβάζει τις παραμέτρους, παράγει την είσοδο, χρονοδιαγραμματίζει τα επίπεδα του διτονικού δικτύου, διαβάζει τους μετρητές ενέργειας, εκτελεί τον βρόχο προθέρμανσης και μέτρησης, ελέγχει την ορθότητα και τυπώνει την αναφορά. Όλα αυτά συμβαίνουν σε ένα σημείο, ώστε οι χρονομετρήσεις και οι μετρήσεις ενέργειας κάθε αρχιτεκτονικής να ορίζονται από τον ίδιο κώδικα.

Το δεύτερο επίπεδο είναι τα εκτελέσιμα ανά αρχιτεκτονική. Κάθε ένα υλοποιεί την ίδια διεπαφή για τους τρεις συγκρινόμενους αλγόριθμους, δηλαδή τη διτονική ταξινόμηση, το map-reduce με τοπικούς σωρούς και την υλοποίηση αναφοράς, παρέχοντας μόνο τη συνάρτηση που εκτελεί τον υπολογισμό. Αυτή καλείται από τον κοινό βρόχο μέτρησης του πρώτου επιπέδου.

Το τρίτο επίπεδο είναι ο οδηγός των σαρώσεων. Απαριθμεί τον παραμετρικό χώρο της ενότητας 3.7 και εκτελεί κάθε περίπτωση ως ξεχωριστή διεργασία, καταγράφοντας αυτούσια την έξοδό της μαζί με την έκβασή της, ώστε κάθε περίπτωση να ξεκινά από καθαρή κατάσταση μνήμης και η αποτυχία μιας να μην ακυρώνει τη σάρωση.

Το τέταρτο επίπεδο μετατρέπει τα ακατέργαστα αποτελέσματα σε πίνακες και διαγράμματα, πάνω στο ίδιο κείμενο αναφοράς που διαβάζει και ο χρήστης. Δεν υπάρχει χωριστή διαδρομή εξόδου προς τα εργαλεία, οπότε οι τιμές στα διαγράμματα είναι εξ ορισμού οι τιμές που τύπωσε το εκτελέσιμο. Μαζί με τα αποτελέσματα αποθηκεύεται και το περιβάλλον εκτέλεσης, όπως περιγράφεται στην ενότητα 3.8, και οι εντολές που παράγουν κάθε στάδιο δίνονται στο παράρτημα Γ'. Η συνολική δομή συνοψίζεται στο σχήμα 3.1.



Σχήμα 3.1: Τα τέσσερα επίπεδα της υποδομής μετρήσεων. Η διαδικασία της μέτρησης ορίζεται μία μόνο φορά, στον κοινό πυρήνα του πρώτου επιπέδου, και οι τρεις υλοποιήσεις παρέχουν αποκλειστικά τη συνάρτηση που εκτελεί τον υπολογισμό.

3.3 Μετρούμενα μεγέθη


3.3.1 Πεδία μέτρησης: algo και end-to-end

Η σύγκριση τριών αρχιτεκτονικών προϋποθέτει μια απόφαση για το τι ακριβώς προσμετράται ως κόστος. Ένας επιταχυντής που ολοκληρώνει τον υπολογισμό ταχύτατα, αλλά απαιτεί τη μεταφορά ολόκληρης της εισόδου από και προς την κύρια μνήμη, δεν είναι απαραίτητα ταχύτερος από τον επεξεργαστή που δουλεύει επιτόπου, οπότε κάθε περίπτωση μετριέται σε δύο πεδία και όχι σε ένα.

Το πεδίο end-to-end περιλαμβάνει ολόκληρη την κλήση από την πλευρά του host: όλα όσα απαιτούνται ώστε, με δεδομένη μια είσοδο στην κύρια μνήμη, το αποτέλεσμα να βρεθεί επίσης στην κύρια μνήμη. Το πεδίο algo περιλαμβάνει μόνο την περιοχή στην οποία εκτελείται ο ίδιος ο υπολογισμός. Η διαφορά τους είναι το κόστος που επιβάλλει η ίδια η ετερογένεια, και συνοψίζεται ανά αρχιτεκτονική στον πίνακα 3.2 και σχηματικά στο σχήμα 3.2.

Αρχιτεκτονική	Περιεχόμενο του algo	Διαφορά από το end-to-end
CPU	ταυτίζεται με το end-to-end	—
GPU	περιοχή μεταξύ συμβάντων CUDA	μεταφορές H2D/D2H, δεσμεύσεις μνήμης
NPU	περιοχή της εκφόρτωσης	εντοπισμός συσκευής, φόρτωση ρύθμισης εκφόρτωσης

Πίνακας 3.2: Το περιεχόμενο των δύο πεδίων μέτρησης ανά αρχιτεκτονική.



Σχήμα 3.2: Τα δύο πεδία μέτρησης ανά αρχιτεκτονική. Το χρώμα κάθε σταδίου δηλώνει σε ποια μονάδα ανήκει η εργασία του, με κόκκινο για το επιπλέον κόστος που επιβάλλει η κάθε αρχιτεκτονική: μεταφορές διαύλου στη μονάδα γραφικών, κωδικοποίηση, συγχώνευση και τελική διόρθωση στον host για τη μονάδα νευρωνικής επεξεργασίας.

Στον επεξεργαστή τα δύο πεδία ταυτίζονται εξ ορισμού, αφού είναι ο ίδιος ο επιταχυντής και δεν υπάρχει κόστος host προς αφαίρεση. Κάθε άλλη επιλογή θα του απέδιδε πλεονέκτημα που δεν του αναλογεί.

Ο μετρητής ενέργειας ανοίγει και κλείνει στα ίδια ακριβώς σημεία του κώδικα με το αντίστοιχο χρονόμετρο, οπότε ο χρόνος και η ενέργεια αναφέρονται στην ίδια περιοχή εκτέλεσης και είναι άμεσα συγκρίσιμα. Καταγράφεται επιπλέον ένα τρίτο, ευρύτερο παράθυρο γύρω από ολόκληρο τον βρόχο μέτρησης, ως άνω φράγμα ελέγχου, που συζητείται στην ενότητα 3.3.3.

Η επιλογή του πεδίου καθορίζει επομένως το ερώτημα στο οποίο απαντά μια μέτρηση: το end-to-end είναι το δίκαιο πεδίο για σύγκριση μεταξύ αρχιτεκτονικών, διότι καμία δεν αποκρύπτει το κόστος μεταφοράς των δεδομένων της, ενώ το algo είναι χρήσιμο για σύγκριση εντός της ίδιας αρχιτεκτονικής, αλλά δεν επαρκεί από μόνο του για ισχυρισμούς μεταξύ αρχιτεκτονικών, ακριβώς επειδή αποσιωπά τις μεταφορές.

3.3.2 Μέτρηση χρόνου

Τα δύο πεδία δεν μετρώνται απαραίτητα με τον ίδιο μηχανισμό. Το πεδίο end-to-end μετριέται πάντοτε με ρολόι του host, εκατέρωθεν της κλήσης, καθώς εξ ορισμού αφορά χρόνο που αντιλαμβάνεται ο host. Το πεδίο algo μετριέται με τον μηχανισμό που διαθέτει η κάθε αρχιτεκτονική για την περιοχή του υπολογισμού της.

Στη μονάδα γραφικών η μέτρηση δεν μπορεί να γίνει με ρολόι του host. Οι πυρήνες εκκινούν ασύγχρονα: η κλήση επιστρέφει μόλις ο πυρήνας τοποθετηθεί στη ροή εντολών και όχι όταν ολοκληρωθεί. Ένα ρολόι του host θα μετρούσε επομένως τον χρόνο της εκκίνησης και όχι της εκτέλεσης, ενώ η εξαναγκασμένη συγχρόνιση θα πρόσθετε το δικό της κόστος στον πυρήνα. Χρησιμοποιούνται αντ' αυτού συμβάντα (events) που καταγράφονται μέσα στη ροή εντολών και χρονομετρούνται από την ίδια τη συσκευή.

Στη μονάδα νευρωνικής επεξεργασίας δεν υπάρχει αντίστοιχος μετρητής της συσκευής,

οπότε το πεδίο `algo` ορίζεται από ρολόι του `host` γύρω από την περιοχή της εκφόρτωσης. Η περιοχή αυτή δεν περιέχει μόνο την εκτέλεση στα πλακίδια: περιλαμβάνει τη δέσμευση και προετοιμασία των `buffers`, την αποστολή των εργασιών και την τελική συγχώνευση των μερικών αποτελεσμάτων στον `host`. Το μέγεθος αυτό επομένως πρέπει να διαβάζεται ως το κόστος ολόκληρης της διαδικασίας εκφόρτωσης και όχι ως ο χρόνος υπολογισμού των πλακιδίων ΑΙΕ. Η διάκριση αυτή είναι ουσιώδης για τα συμπεράσματα του κεφαλαίου 6.

Από τις 50 μετρούμενες επαναλήψεις κάθε περίπτωσης προκύπτουν τρία μεγέθη ανά πεδίο: η μέση τιμή, στην οποία βασίζονται οι συγκρίσεις, η τυπική απόκλιση, ένδειξη της σταθερότητας της μέτρησης υπό τις καθλωμένες συνθήκες της ενότητας 3.8, και η ελάχιστη τιμή, κάτω φράγμα του επιτεύξιμου χρόνου. Οι μετρητές έχουν διακριτική ικανότητα τάξης νανοδευτερολέπτου, έναντι μετρούμενων περιοχών από λίγες δεκάδες μικροδευτερόλεπτα έως εκατοντάδες χιλιοστά, οπότε το κόστος της ίδιας της χρονομέτρησης είναι αμελητέο και δεν αφαιρείται.

3.3.3 Μέτρηση ενέργειας

Η ενέργεια μετριέται από το ίδιο το εκτελέσιμο και όχι από εξωτερικό περιτύλιγμα που παρακολουθεί τη διεργασία. Ένα εξωτερικό εργαλείο μετρά ολόκληρη τη διεργασία, ενώ ο βρόχος μέτρησης καταλαμβάνει μόνο ένα μέρος της που μάλιστα διαφέρει συστηματικά ανά αρχιτεκτονική. Ένα τέτοιο εργαλείο θα εισήγαγε συστηματική μεροληψία υπέρ των αρχιτεκτονικών με μικρότερο κόστος αρχικοποίησης. Οι μετρητές διαδίδονται επομένως μέσα στη διεργασία, στα ίδια ακριβώς σημεία του κώδικα με τα χρονόμετρα της ενότητας 3.3.2.

Οι πηγές διαφέρουν ανά αρχιτεκτονική, το πεδίο όμως παραμένει συμμετρικό. Για όλες τις αρχιτεκτονικές μετριέται η ενέργεια του πακέτου του επεξεργαστή μέσω των μετρητών `RAPL`, ενώ για τη μονάδα γραφικών προστίθεται και η ισχύς της κάρτας. Το πεδίο `end-to-end` αντιστοιχεί επομένως στο συνολικό κόστος επίλυσης και για τις τρεις, χωρίς η μονάδα γραφικών να αποκρύπτει το κόστος που επιβάλλει στον `host`.

Η αναφερόμενη ενέργεια είναι το άθροισμα, όχι η μέση τιμή, των 50 επαναλήψεων: οι μετρητές `RAPL` κβαντίζουν κάθε επιμέρους ανάγνωση, αλλά μετρούν αθροιστικά χωρίς επαναφορά, οπότε το άθροισμα παραμένει ακριβές ακόμη και όταν κάθε επιμέρους διαφορά είναι της τάξης του βήματος κβαντισμού. Η ανάγνωση των μετρητών απαιτεί αυξημένα δικαιώματα. Όταν αυτά λείπουν, το εκτελέσιμο δηλώνει ρητά ότι η μέτρηση δεν είναι διαθέσιμη αντί να αναφέρει μηδενικές τιμές ως δεδομένα.

Από τα πεδία του `RAPL` χρησιμοποιείται μόνο το `package`: το υποπεδίο `core` βρέθηκε αναξιόπιστο σε αυτόν τον επεξεργαστή, καταγράφοντας μόλις 6 W υπό πλήρες φορτίο οκτώ νημάτων, ενώ η ισχύς του πακέτου αυξάνεται κατά περίπου 53 W.

Για τη μονάδα γραφικών, ο μετρητής συνολικής ενέργειας της βιβλιοθήκης `NVML` αποδείχθηκε επίσης ακατάλληλος: προχωρά σε βήματα περίπου 20 J κάθε λίγες δεκάδες χιλιοστά, οπότε η οριοθέτηση ενός πυρήνα διάρκειας χιλιοστών επιστρέφει τυχαίο πολλαπλάσιο του βήματος. Τρεις πανομοιότυπες εκτελέσεις έδωσαν τιμές που διέφεραν πάνω από τέσσερις φορές, ενώ ο αντίστοιχος χρόνος διέφερε κατά 0.2%. Αντ' αυτού ένα βοηθητικό νήμα δειγματοληπτεί τη στιγμιαία ισχύ της κάρτας κάθε 2 ms και την ολοκληρώνει ως προς τον χρόνο. Η ίδια η ένδειξη ισχύος ανανεώνεται αραιότερα από αυτή την περίοδο δειγματοληψίας, οπότε ένα παράθυρο `algo` λίγων χιλιοστών στηρίζεται

σε ένδειξη που δεν έχει προλάβει να ανανεωθεί. Η άθροιση στις 50 επαναλήψεις εξομαλύνει αυτή την ανακρίβεια χωρίς να την εξαλείφει, σε αντίθεση με τους μετρητές RAPL που ανανεώνονται σε κλίμακα χιλιοστού.

Πέραν της μεικτής τιμής αναφέρεται και η καθαρή ενέργεια, δηλαδή η μεικτή μείον την ενέργεια που θα καταλάωνε το σύστημα σε αδράνεια για το ίδιο διάστημα, με την ισχύ αδράνειας μετρημένη πριν από κάθε σάρωση για το σύνολο των μετρητών κάθε αρχιτεκτονικής. Το καθαρό μέγεθος είναι προτιμότερο ιδίως για τη μονάδα νευρωνικής επεξεργασίας, όπου κυριαρχεί η στατική κατανάλωση του υπόλοιπου συστήματος, και για τη μονάδα γραφικών, όπου αναιρεί το κόστος του ίδιου του μηχανισμού δειγματοληψίας.

Πρέπει να δηλωθεί τι δεν μπορούν να δείξουν αυτές οι μετρήσεις. Ο μετρητής του πακέτου καλύπτει ολόκληρη την ψηφίδα: πυρήνες host, πλακίδια NPU, uncore και ελεγκτή μνήμης, όλα υπό έναν κοινό μετρητή, οπότε μια εκτέλεση στη μονάδα νευρωνικής επεξεργασίας μετριέται ως η συνολική ενέργεια του συστήματος όσο αυτή εργάζεται, συμπεριλαμβανομένης της προετοιμασίας δεδομένων στον host. Πρόκειται για δίκαιη, συμμετρική σύγκριση κόστους επίλυσης, δεν αρκεί όμως για να αποδειχθεί ότι η μονάδα εκτελεί τον υπολογισμό καταναλώνοντας η ίδια λιγότερη ενέργεια, αφού η δική της κατανάλωση δεν διαχωρίζεται ποτέ από εκείνη του host. Η απομόνωσή της θα απαιτούσε εξωτερική μετρητική διάταξη.

3.3.4 Μέτρηση κίνησης δεδομένων

Πέρα από τον χρόνο και την ενέργεια, κάθε εκτέλεση καταγράφει τα bytes που διακίνησε και τις πράξεις που εκτέλεσε. Αυτές είναι οι συντεταγμένες που τοποθετούν την εκτέλεση στο διάγραμμα της ενότητας 3.4, οπότε σφάλμα στην καταμέτρησή τους δεν προκαλεί απλώς ανακρίβεια, αλλά μπορεί να οδηγήσει σε εντελώς λανθασμένο συμπέρασμα για το τι περιορίζει την υλοποίηση.

Για τον λόγο αυτό η κίνηση δεν εκτιμάται από μοντέλο, αλλά συσσωρεύεται από τον ίδιο τον κώδικα εκεί όπου συντελείται: ανά ομάδα συγχωνευμένων περασμάτων στον επεξεργαστή, ανά εκκίνηση πυρήνα στη μονάδα γραφικών, ανά παρτίδα δεδομένων στη μονάδα νευρωνικής επεξεργασίας. Αυτό έχει σημασία επειδή η προφανής εκτίμηση, πλήθος στοιχείων επί μέγεθος τύπου, υποθέτει ότι κάθε στοιχείο διαβάζεται μία φορά. Η περικομμένη διτονική ταξινόμηση αντίθετα διατρέχει το σύνολο εργασίας επανειλημμένα, με συντελεστή που δεν είναι σταθερός: περίπου επταπλάσιος της αφελούς εκτίμησης για k πολύ μικρότερο του n , αυξανόμενος σημαντικά και διαφορετικός ανά αρχιτεκτονική για τα μεγαλύτερα k , όπου η περικοπή παύει να αποδίδει. Η αφελής εκτίμηση θα έκανε κάθε υλοποίηση να φαίνεται ότι αξιοποιεί μικρό μόνο κλάσμα του διαθέσιμου εύρους ζώνης, οδηγώντας εσφαλμένα στο συμπέρασμα ότι καμία δεν πλησιάζει το ταβάνι της μνήμης.

Η καταμέτρηση ελέγχεται με ανεξάρτητη επαλήθευση όπου αυτό είναι εφικτό. Για τη διτονική ταξινόμηση με k έως 4096, ο επεξεργαστής και η μονάδα γραφικών εκτελούν το ίδιο χρονοδιάγραμμα επιπέδων και υπολογίζουν την κίνησή τους σε εντελώς ξεχωριστό κώδικα, καταλήγοντας όμως στην ίδια τιμή μέχρι το τελευταίο byte. Αυτό αποτελεί ισχυρή ένδειξη ότι το μοντέλο είναι σωστό. Για το map-reduce οι δύο τιμές διαφέρουν, όπως αναμένεται: αν και αμφότερες διατηρούν τοπικό σωρό ανά νήμα, ο επεξεργαστής εκτελεί λίγα νήματα ενώ η μονάδα γραφικών χιλιάδες, με αντίστοιχα μεγαλύτερο χώρο

εργασίας και επιπλέον συγχώνευση σε δέντρο εντός κάθε ομάδας νημάτων, οπότε οι δύο υλοποιήσεις πράγματι μετακινούν διαφορετικό όγκο δεδομένων.

Δεν είναι κάθε ποσότητα εξίσου παρατηρήσιμη, και κάθε εκτέλεση δηλώνει η ίδια την ποιότητα των αριθμών της. Για τη διτονική ταξινόμηση τα bytes και το πλήθος των πράξεων είναι ακριβή, καθώς το χρονοδιάγραμμα είναι πλήρως απαριθμήσιμο. Για το map-reduce τα bytes είναι ακριβή ενώ το πλήθος των συγκρίσεων είναι κάτω φράγμα, επειδή η αναδιάταξη των τοπικών σωρών εξαρτάται από τα δεδομένα. Για την υλοποίηση αναφοράς και τα δύο μεγέθη είναι κάτω φράγματα, διότι τα εσωτερικά περάσματα των βιβλιοθηκών δεν είναι παρατηρήσιμα από τον κώδικα που τις καλεί.


Οι πράξεις μετρώνται σε συγκρίσεις-ανταλλαγές και όχι σε πράξεις κινητής υποδιαστολής: η επιλογή top-k δεν εκτελεί αριθμητικές πράξεις, οπότε ένα μέγεθος σε FLOP δεν θα αντιστοιχούσε σε τίποτα που εκτελείται πραγματικά, ενώ η σύγκριση-ανταλλαγή είναι η φυσική μονάδα εργασίας του προβλήματος.

3.4 Μοντέλο roofline

Ο χρόνος εκτέλεσης λέει πόσο γρήγορη είναι μια υλοποίηση, μα όχι γιατί δεν είναι ταχύτερη. Το μοντέλο roofline [18] απαντά σε αυτό, αντιπαραβάλλοντας κάθε μέτρηση με τα δύο ανώτατα όρια του μηχανήματος: ένα εύρος ζώνης β και μια υπολογιστική ικανότητα π . Ποιο από τα δύο δεσμεύει δεν είναι ιδιότητα ούτε μόνο του μηχανήματος ούτε μόνο του αλγορίθμου, αλλά της σχέσης τους, την οποία εκφράζει η υπολογιστική ένταση, το πηλίκο των πράξεων W προς τα bytes Q που μετακινούνται:

$$I = \frac{W}{Q}, \quad P = \min(\pi, \beta I)$$

Το σχήμα 3.3 δείχνει πώς διαβάζεται το διάγραμμα.



Σχήμα 3.3: Η ανάγνωση του μοντέλου roofline. Το κεκλιμένο τμήμα αντιστοιχεί στο όριο βI που επιβάλλει το εύρος ζώνης και το οριζόντιο στο όριο π που επιβάλλει η υπολογιστική ικανότητα· η επιτεύξιμη επίδοση είναι το ελάχιστο των δύο. Επειδή το εύρος ζώνης εξαρτάται από το μέγεθος του συνόλου εργασίας, το κεκλιμένο τμήμα δεν είναι μία ευθεία αλλά μια κλίμακα από παράλληλες ευθείες, μία ανά βαθμίδα της ιεραρχίας μνήμης, και κάθε μέτρηση συγκρίνεται με εκείνη που αντιστοιχεί στο δικό της σύνολο εργασίας. Το σημείο A περιορίζεται από τη μνήμη και θα ωφεληθεί μόνο από μείωση της κίνησης δεδομένων, το B από την υπολογιστική ικανότητα, ενώ το C απέχει και από τα δύο ταβάνια: εκεί ο περιορισμός δεν είναι το υλικό αλλά η οργάνωση της εκτέλεσης.

Η εφαρμογή του μοντέλου εδώ αποκλίνει από τη συνήθη πρακτική σε τρία σημεία, και τα τρία αναγκαία για να είναι οι συγκρίσεις έντιμες.

Πρώτον, και τα δύο ταβάνια μετρώνται στο ίδιο μηχανήμα με χωριστά εκτελέσιμα αντί να ληφθούν από φυλλάδια κατασκευαστή, αφού ζητούμενο είναι τι πράγματι επιτυγχάνεται και όχι τι θα μπορούσε να επιτύχει το υλικό υπό ιδανικές συνθήκες.

Δεύτερον, το ταβάνι της μνήμης δεν είναι μόνον ένας αριθμός: το επιτεύξιμο εύρος ζώνης εξαρτάται από το μέγεθος του συνόλου εργασίας, αφού τα δεδομένα φτάνουν πολύ γρηγορότερα όσο χωρούν σε κάποιο επίπεδο κρυφής μνήμης παρά από την κύρια μνήμη. Το εύρος ζώνης μετριέται επομένως σε διαδοχικά μεγέθη συνόλου εργασίας, ξεκινώντας από 32 KiB και διπλασιάζοντας κάθε φορά, και κάθε μέτρηση συγκρίνεται με το ταβάνι του δικού της συνόλου εργασίας. Η κλίμακα αυτή μετρά το εύρος ζώνης υπό επαναχρησιμοποίηση, που θα φαινόταν ακατάλληλο για έναν αλγόριθμο που διατρέχει την είσοδο μία μόνο φορά. Εδώ όμως η ένταση δεν ευσταθεί, αφού η είσοδος ανακτάται από το αντίγραφο ασφαλείας ακριβώς πριν από τη χρονομετρούμενη περιοχή (ενότητα 3.8), οπότε για σύνολα εργασίας έως το μέγεθος της τελευταίας βαθμίδας τα δεδομένα είναι ήδη παρόντα σε αυτήν και η μέτρηση αντιστοιχεί σε δεύτερο πέρασμα. Πέραν αυτού του μεγέθους η κλίμακα συγκλίνει από μόνη της στον ρυθμό της κύριας μνήμης.

Τρίτον, το υπολογιστικό ταβάνι μετριέται σε συγκρίσεις-ανταλλαγές, για τον λόγο της ενότητας 3.3.4. Αν κάθε σύγκριση-ανταλλαγή χρησιμοποιούσε το αποτέλεσμα της προηγούμενης θα σχηματιζόταν αλυσίδα εξαρτήσεων, μετρώντας την καθυστέρηση μιας πράξης αντί για τον ρυθμό εκτέλεσης πολλών, και το ταβάνι θα έβγαине πολλαπλάσια

χαμηλότερο με κάθε υλοποίηση να φαίνεται εσφαλμένα να το αγγίζει. Ο πυρήνας μέτρησης εκτελεί επομένως 64 ανεξάρτητες αλυσίδες παράλληλα, με εναλλαγή τριών καταχωρητών ώστε καμία πράξη να μην παραλείπεται από τον μεταγλωττιστή.

Για τη μονάδα νευρωνικής επεξεργασίας το μοντέλο έχει διαφορετική σημασία: δεν υπάρχει διαθέσιμος πυρήνας ΑΙΕ με ρυθμιζόμενη υπολογιστική ένταση, οπότε τα μετρημένα ταβάνια αφορούν τη διαδρομή τροφοδοσίας της μονάδας και όχι τον υπολογισμό στα πλακίδια. Διαβάζονται ως «πόσο γρήγορα μπορεί ο host να ετοιμάσει τα δεδομένα που καταναλώνει η μονάδα», που είναι άλλωστε ο πραγματικός περιορισμός της υλοποίησης.

3.5 Βιβλιοθήκες σύγκρισης

Το μέτρο σύγκρισης για την επίδοση είναι μια καθιερωμένη υλοποίηση βιβλιοθήκης ανά αρχιτεκτονική. Μια νέα υλοποίηση έχει αξία μόνο αν είναι ταχύτερη από αυτό που έχει ήδη στη διάθεσή του ο προγραμματιστής.

Για τον επεξεργαστή χρησιμοποιείται η `std::partial_sort`. Η επιλογή της έναντι της `std::nth_element` δεν είναι αυτονόητη, αλλά για k πολύ μικρότερο του n είναι σαφώς ταχύτερη, αφού διατηρεί σωρό μεγέθους k που παραμένει στην κρυφή μνήμη και απορρίπτει τα περισσότερα στοιχεία με μία μόνο σύγκριση.

Για τη μονάδα γραφικών χρησιμοποιείται η `cub::DeviceTopK`, η οποία υλοποιεί επιλογή με βάση την αναπαράσταση. Είναι σημαντικό ότι πρόκειται για πραγματική συνάρτηση επιλογής $\text{top-}k$ και όχι πλήρη ταξινόμηση ακολουθούμενη από περικοπή, οπότε η σύγκριση γίνεται με αντίπαλο που επιλύει το ίδιο πρόβλημα με βελτιστοποιημένο τρόπο.

Για τη μονάδα νευρωνικής επεξεργασίας δεν υπάρχει αντίστοιχο μέτρο σύγκρισης: η αλυσίδα εργαλείων της αρχιτεκτονικής ΑΙΕ παρέχει μεταγλωττιστή και παραδείγματα πυρήνων, όχι βιβλιοθήκη αλγορίθμων, οπότε δεν υφίσταται καθιερωμένη υλοποίηση $\text{top-}k$ για το υλικό αυτό, ούτε από τον κατασκευαστή ούτε από τρίτους. Χρησιμοποιείται αντ' αυτού η ίδια `std::partial_sort` του επεξεργαστή, εκτελούμενη εξ ολοκλήρου στον host χωρίς καμία αξιοποίηση της μονάδας. Αυτό αλλάζει το ερώτημα στο οποίο απαντά η σύγκριση: όχι «είναι η υλοποίησή μας καλύτερη από έναν βελτιστοποιημένο πυρήνα ΑΙΕ», αφού τέτοιος πυρήνας δεν υπάρχει, αλλά «αξίζει να μεταφερθεί ο υπολογισμός στη μονάδα, ή είναι προτιμότερο να εκτελεστεί με τα μέσα που ήδη διαθέτει ο host». Αυτό είναι το ερώτημα που αντιμετωπίζει στην πράξη όποιος εξετάζει τη χρήση της.

Το κοινό μέτρο σύγκρισης προσφέρει επιπλέον έναν ανεξάρτητο έλεγχο της υποδομής: επειδή πρόκειται κυριολεκτικά για τον ίδιο κώδικα στο ίδιο υλικό, οι δύο μετρήσεις οφείλουν να συμπίπτουν, και η σύμπτωσή τους στα αποτελέσματα του κεφαλαίου 7 επιβεβαιώνει ότι η υποδομή δεν εισάγει συστηματική μεροληψία ανάλογα με την αρχιτεκτονική που δηλώνεται.

3.6 Έλεγχος ορθότητας

Μια μέτρηση χρόνου έχει νόημα μόνο αν το αποτέλεσμα είναι σωστό, οπότε κάθε περίπτωση κάθε σάρωσης επαληθεύεται και όσες αποτύχουν καταγράφονται ως αποτυχίες αντί να συμπεριληφθούν στα αποτελέσματα.

Ο έλεγχος γίνεται ως προς ξεχωριστή υλοποίηση επαλήθευσης, η οποία δεν πρέπει να συγχέεται με τις βιβλιοθήκες της ενότητας 3.5: εκείνες αποτελούν μέτρο σύγκρισης επίδοσης, ενώ αυτή κρίνει αν ένα αποτέλεσμα είναι σωστό. Πρόκειται για την απλούστερη δυνατή υλοποίηση: αντίγραφο της εισόδου ταξινομείται πλήρως στον host και κρατούνται τα πρώτα k στοιχεία. Είναι αργή, χωρίς πρόθεση ανταγωνισμού, με μοναδικό ρόλο να είναι προφανώς σωστή ώστε να εμπιστεύεται κανείς την ετυμηγορία της.

Η σύγκριση δεν γίνεται με τον ίδιο τρόπο για όλους τους τύπους: οι ακέραιοι απαιτούν απόλυτη ισότητα, οι τύποι κινητής υποδιαστολής ανοχή, σχετική ή απόλυτη ανάλογα με το μέγεθος των τιμών, αφού διαφορετικές αρχιτεκτονικές εκτελούν τις πράξεις με διαφορετική σειρά και ενδιαμέση ακρίβεια. Επειδή κάθε υλοποίηση επιστρέφει το αποτέλεσμα της ταξινομημένο, με την ίδια σειρά που έχει και η υλοποίηση επαλήθευσης (ενότητα 2.1), η σύγκριση γίνεται θέση προς θέση και όχι ως σύνολο. Όταν εκτελούνται τόσο το πλήρες όσο και το περικομμένο δίκτυο, τα δύο αποτελέσματα συγκρίνονται επιπλέον μεταξύ τους, ως ανεξάρτητος έλεγχος ότι η περικοπή δεν αλλοιώνει το αποτέλεσμα.

Στην κύρια σάρωση της εργασίας επαληθεύτηκαν και οι 2700 περιπτώσεις χωρίς καμία αποτυχία.

3.7 Παραμετρικός χώρος

Κάθε εκτέλεση καθορίζεται πλήρως από τις παραμέτρους της γραμμής εντολών. Καμία δεν διαβάζεται από αρχείο ρυθμίσεων ή μεταβλητή περιβάλλοντος, ώστε η περιγραφή μιας μέτρησης να είναι πάντοτε πλήρης και αναπαραγώγιμη. Ο πλήρης κατάλογος δίνεται στο παράρτημα Γ'.

Το μέγεθος της εισόδου είναι δύναμη του δύο, n ίσο με 2^q , με το q να σαρώνεται από 3 έως 24. Το ανώτερο όριο, περίπου 16,8 εκατομμύρια στοιχεία, είναι αρκετά μεγάλο ώστε το σύνολο εργασίας να ξεπερνά κατά πολύ την κρυφή μνήμη και η μέτρηση να αφορά την κύρια μνήμη. Το κατώτερο δεν είναι αυθαίρετο, αφού για q μικρότερο του 3 η είσοδος έχει λιγότερα στοιχεία από το μικρότερο ζητούμενο k .

Η παράμετρος k λαμβάνει τις τιμές 8, 256, 4096 και 131072, τάξεις μεγέθους απόσταση μεταξύ τους, καλύπτοντας καταστάσεις από ένα k τόσο μικρό ώστε ο σωρός να χωράει σε ελάχιστους καταχωρητές, έως ένα k που αποτελεί σημαντικό ποσοστό της ίδιας της εισόδου. Όπου το k υπερβαίνει το n , περιορίζεται σε αυτό.

3.7.1 Τύποι δεδομένων

Σαρώνονται πέντε τύποι δεδομένων, οι οποίοι δίνονται στον πίνακα 3.3.

Τύπος	Αντιστοίχιση σε C++	Μέγεθος	Περιγραφή
int	std::int32_t	32 bit	ακέραιος με πρόσημο
uint	std::uint32_t	32 bit	ακέραιος χωρίς πρόσημο
float	float	32 bit	κινητής υποδιαστολής απλής ακρίβειας
double	double	64 bit	κινητής υποδιαστολής διπλής ακρίβειας
half	_Float16	16 bit	κινητής υποδιαστολής μισής ακρίβειας

Πίνακας 3.3: Οι τύποι δεδομένων που σαρώνονται.


Ο τύπος επηρεάζει τη μέτρηση με δύο τρόπους: καθορίζει πόσα bytes μετακινούνται ανά στοιχείο, οπότε η θέση της ίδιας υλοποίησης απέναντι στο ταβάνι της μνήμης μετατοπίζεται ανάλογα με τον τύπο, και καθορίζει το κόστος μιας σύγκρισης, που δεν είναι ίδιο για όλους τους τύπους.

3.7.2 Κατανομές εισόδου

Η κατανομή των τιμών της εισόδου δεν είναι αδιάφορη: οι αλγόριθμοι με σωρούς εκτελούν εργασία μόνο όταν ένα νέο στοιχείο υπερβαίνει τη ρίζα του σωρού, οπότε η σειρά εμφάνισης των τιμών μεταβάλλει δραστικά τον χρόνο τους. Σαρώνονται οι πέντε κατανομές του πίνακα 3.4. Το εκτελέσιμο υποστηρίζει επιπλέον την κανονική κατανομή, μη χρησιμοποιημένη εδώ καθώς η trimodal καλύπτει την περίπτωση συσσωρευμένων τιμών εντονότερα. Η μορφή καθεμιάς φαίνεται στο σχήμα 3.4.

Κατανομή	Περιγραφή
uniform	ομοιόμορφη στο εύρος τιμών
trimodal	τρεις στενές συστάδες εντός του εύρους
sorted	αύξουσα σειρά
reverse	φθίνουσα σειρά
adversarial	τιμές στο κάτω ήμισυ με αύξουσες αιχμές

Πίνακας 3.4: Οι κατανομές εισόδου που σαρώνονται.



Σχήμα 3.4: Οι πέντε κατανομές εισόδου, με την τιμή κάθε στοιχείου συναρτήσει της θέσης του στον πίνακα. Η uniform και η trimodal δεν έχουν διάταξη και διαφέρουν μόνο ως προς το ποιες τιμές εμφανίζονται: οι δύο διατεταγμένες είναι τα άκρα για την επιλογή με σωρό. Στην adversarial το σώμα των τιμών παραμένει κάτω από τη μέση τιμή του εύρους (διακεκομμένη), με μεμονωμένες αιχμές σε τακτά διαστήματα.

Οι δύο διατεταγμένες κατανομές αποτελούν τα δύο άκρα για την επιλογή με σωρό (ενότητα 2.2.3): η φθίνουσα είναι η ευνοϊκότερη περίπτωση και η αύξουσα η δυσμενέστερη. Η adversarial διατηρεί αυτή τη δυσμενή συμπεριφορά χωρίς να είναι πλήρως ταξινομημένη: το μεγαλύτερο μέρος των τιμών βρίσκεται στο κάτω ήμισυ του εύρους, με αύξουσες αιχμές σε τακτά διαστήματα.

Η διτονική ταξινόμηση δεν εξαρτάται από τα δεδομένα, καθώς εκτελεί το ίδιο δίκτυο συγκρίσεων ανεξάρτητα από τις τιμές, και λειτουργεί έτσι ως μάρτυρας: αν ο χρόνος της μεταβληθεί μεταξύ κατανομών, η μεταβολή οφείλεται στη μέτρηση και όχι στον αλγόριθμο.

3.8 Συνθήκες μέτρησης και επαναληψιμότητα

Το σύστημα δεν βρίσκεται εκ των προτέρων σε κατάσταση κατάλληλη για μέτρηση: στην προεπιλεγμένη διαμόρφωση ο διαχειριστής συχνότητας είναι powersave και η ενίσχυση συχνότητας ενεργή, οπότε η συχνότητα λειτουργίας μεταβάλλεται με το φορτίο και τη θερμοκρασία. Πρόκειται για συστηματική μετατόπιση κατά τη διάρκεια μιας σάρωσης καθώς το σύστημα θερμαίνεται, όχι για τυχαίο θόρυβο, οπότε η τυπική απόκλιση δειγμάτων υπό μετατοπιζόμενες συνθήκες δεν θα αποτύπωνε την πραγματική αβεβαιότητα της μέτρησης.

Για τον λόγο αυτό, πριν από κάθε σάρωση το σύστημα καθιλώνεται σε σταθερή, τεκμηριωμένη κατάσταση, συνοψισμένη στον πίνακα 3.5, καταγράφεται πριν από τη σάρωση και αποκαθίσταται μετά. Οι αντίστοιχες εντολές δίνονται στο παράρτημα Γ'.

Παράμετρος	Κατάσταση κατά τη μέτρηση
Διαχειριστής συχνότητας CPU	performance
Ενίσχυση συχνότητας CPU	απενεργοποιημένη
Νήματα CPU	8, ένα ανά φυσικό πυρήνα
GPU persistence mode	ενεργοποιημένο
Όριο ισχύος GPU	σταθερό σε όλη τη σάρωση
Περίοδος ψύξης μεταξύ μονάδων	15 s
Επαναλήψεις προθέρμανσης	5 ανά περίπτωση
Μετρούμενες επαναλήψεις	50 ανά περίπτωση

Πίνακας 3.5: Οι συνθήκες στις οποίες καθιλώνεται το σύστημα πριν από κάθε σάρωση.

Το όριο ισχύος της μονάδας γραφικών επιλέγεται μία φορά, εντός των ορίων του πίνακα 3.1, και διατηρείται σταθερό. Η τιμή του είναι αυθαίρετη, αλλά κάθε αλλαγή της κατά τη σάρωση θα μετέβαλλε ταυτόχρονα τον χρόνο και την ενέργεια.

Όπως αναφέρθηκε στην ενότητα 3.1, οι τρεις μονάδες μοιράζονται κοινό θερμικό όριο. Περίοδος ψύξης 15 s μεταξύ διαδοχικών μονάδων εμποδίζει η καθεμία να ξεκινά από τη θερμική κατάσταση της προηγούμενης, ενώ κατά τη σάρωση δεν εκτελείται άλλο υπολογιστικό φορτίο. Πρόκειται για μετρίασμό και όχι εξάλειψη του προβλήματος, αφού σε φορητό σύστημα η θερμική σύζευξη μεταξύ των μονάδων δεν μπορεί να αρθεί, κάτι που παραμένει αναγνωρισμένος περιορισμός των μετρήσεων.

Κάθε περίπτωση εκτελείται 5 φορές ως προθέρμανση και 50 υπό μέτρηση, με αναφερόμενη τη μέση τιμή, την τυπική απόκλιση και το ελάχιστο. Πριν από κάθε επανάληψη

η είσοδος ανακτάται από αντίγραφο ασφαλείας, εκτός της χρονομετρούμενης περιοχής, ώστε το κόστος της αντιγραφής να μην προσμετράται και κάθε επανάληψη να ξεκινά από πανομοιότυπη είσοδο. Αυτό είναι κρίσιμο, αφού οι υλοποιήσεις που εξαρτώνται από τα δεδομένα θα εμφάνιζαν διαφορετικά τεχνητά βελτιωμένους χρόνους σε ήδη μερικώς ταξινομημένη είσοδο.

Πέρα από τις επαναλήψεις εντός μιας περίπτωσης, κάθε συνδυασμός κατανομής και σπόρου γεννήτριας τυχαίων αριθμών αποτελεί ανεξάρτητο δείγμα. Τα διαγράμματα συναθροίζουν αυτά τα δείγματα και απεικονίζουν τη διασπορά τους ως ζώνες σφάλματος, διακρίνοντας την αβεβαιότητα λόγω δεδομένων από την αβεβαιότητα λόγω μέτρησης.

Τέλος, κάθε εκτέλεση καταγράφει η ίδια το περιβάλλον στο οποίο έτρεξε: την αναθεώρηση του αποθετηρίου, τον πυρήνα, τον μεταγλωττιστή και τις εκδόσεις των οδηγών και βιβλιοθηκών εκτέλεσης κάθε μονάδας. Έτσι, κάθε σύνολο μετρήσεων τεκμηριώνει τις συνθήκες παραγωγής του χωρίς να εξαρτάται από εξωτερική καταγραφή που ενδέχεται να αποκλίνει.

Κεφάλαιο 4

Υλοποίηση σε CPU


4.1 Σχεδιαστικές επιλογές

Τέσσερις αποφάσεις διαπερνούν και τις δύο υλοποιήσεις του κεφαλαίου και περιγράφονται εδώ μία φορά: ο τρόπος αξιοποίησης των διανυσματικών εντολών, ο τρόπος με τον οποίο ο ίδιος αλγόριθμος υποστηρίζει πέντε τύπους δεδομένων, ο χειρισμός της μισής ακρίβειας και ο τρόπος κατανομής της εργασίας σε νήματα.

4.1.1 Διανυσματοποίηση

Και οι δύο αλγόριθμοι στηρίζονται σε μια πράξη που διανυσματοποιείται εξαιρετικά καλά. Η σύγκριση-ανταλλαγή δύο στοιχείων ισοδυναμεί με τον υπολογισμό του ελαχίστου και του μεγίστου τους, και οι δύο αυτές πράξεις υπάρχουν ως εντολές που δρουν ταυτόχρονα σε ολόκληρο διανυσματικό καταχωρητή, χωρίς διακλαδώσεις. Ένας καταχωρητής 512 bit εκτελεί δεκαέξι συγκρίσεις ακεραίων απλής ακρίβειας στον χρόνο μίας. Οι εντολές αναφέρονται εδώ με τα ονόματα των αντίστοιχων ενδογενών συναρτήσεων του προτύπου [19], το οποίο υλοποιείται και από τον επεξεργαστή της ενότητας 3.1.

Η δυσκολία δεν βρίσκεται στη σύγκριση, αλλά στην τοποθέτηση των στοιχείων. Για να συγκριθούν δύο στοιχεία που απέχουν απόσταση j , πρέπει να βρεθούν στην ίδια θέση δύο διαφορετικών καταχωρητών. Όταν το j είναι μικρότερο από το πλάτος του καταχωρητή, αυτό επιτυγχάνεται με αναδιάταξη εντός του καταχωρητή: το περιεχόμενο μετατίθεται κατά j θέσεις, υπολογίζονται ελάχιστο και μέγιστο, και το αποτέλεσμα ανασυντίθεται επιλέγοντας εναλλάξ από τα δύο με μια μάσκα. Η ακολουθία «αναδιάταξη, ελάχιστο, μέγιστο, επιλογή» είναι το θεμελιώδες μοτίβο πάνω στο οποίο χτίζεται η συγχώνευση επιπέδων της ενότητας 4.2, και αποτυπώνεται στο σχήμα 4.1.



Σχήμα 4.1: Το θεμελιώδες μοτίβο «αναδιάταξη, ελάχιστο, μέγιστο, επιλογή» για σύγκριση-ανταλλαγή σε απόσταση $j = 2$, σε καταχωρητή οκτώ θέσεων. Το περιεχόμενο μετατίθεται ώστε κάθε στοιχείο να βρεθεί απέναντι στο ταίρι του, υπολογίζονται ταυτόχρονα ελάχιστο και μέγιστο για όλες τις θέσεις, και το αποτέλεσμα ανασυντίθεται επιλέγοντας το ελάχιστο όπου το αντίστοιχο bit της μάσκας είναι μηδέν και το μέγιστο όπου είναι ένα. Καμία διακλάδωση δεν μεσολαβεί και καμία τιμή δεν εξετάζεται ξεχωριστά.

Το πλάτος των καταχωρητών δεν είναι γνωστό κατά τη μεταγλώττιση. Ο κώδικας μεταγλωττίζεται με όλες τις διαδρομές παρούσες και η επιλογή γίνεται κατά την εκκίνηση, με ερώτημα προς τον επεξεργαστή για τις εντολές που υποστηρίζει: αν υπάρχει AVX-512 επιλέγονται οι καταχωρητές των 512 bit, διαφορετικά οι των 256, και σε τελευταία ανάλυση η βαθμωτή διαδρομή. Το ίδιο εκτελέσιμο τρέχει επομένως σε οποιοδήποτε μηχάνημα, με τη διαφορά ότι σε διαφορετικό υλικό ακολουθεί διαφορετική διαδρομή κώδικα και τα αποτελέσματά του δεν είναι άμεσα συγκρίσιμα, όπως σημειώνεται και στο παράρτημα Γ'.

4.1.2 Αφαίρεση διανυσματικών τύπων

Οι διανυσματικές εντολές είναι εξειδικευμένες ανά τύπο δεδομένων: άλλη εντολή υπολογίζει το ελάχιστο ακεραίων με πρόσημο, άλλη χωρίς πρόσημο, και άλλη αριθμών κινητής υποδιαστολής. Με πέντε τύπους, δύο πλάτη καταχωρητών και δύο αλγορίθμους, η άμεση συγγραφή θα οδηγούσε σε είκοσι σχεδόν πανομοιότυπες παραλλαγές του ίδιου κώδικα, με αντίστοιχο κόστος συντήρησης και κίνδυνο η μία να αποκλίνει από την άλλη.

Αντ' αυτού ορίζεται μια ενιαία διεπαφή. Για κάθε συνδυασμό τύπου και πλάτους δηλώνεται μια δομή που εκθέτει πάντοτε τα ίδια ονόματα: τον διανυσματικό τύπο, το πλάτος του σε στοιχεία, τη φόρτωση και την αποθήκευση, το ελάχιστο, το μέγιστο, την επιλογή με μάσκα, την αναδιάταξη, και την παραγωγή της μάσκας υποψηφίων που χρησιμοποιεί το map-reduce. Οι αλγόριθμοι γράφονται μία φορά ως προς τη διεπαφή αυτή και δεν αναφέρονται ποτέ σε συγκεκριμένη εντολή.


Το όφελος είναι διπλό. Η προσθήκη ενός τύπου δεδομένων απαιτεί μόνο μια νέα εξειδίκευση της δομής και καμία αλλαγή στους αλγορίθμους, και η ίδια η απουσία μιας εξειδίκευσης είναι ανιχνεύσιμη κατά τη μεταγλώττιση: αν για κάποιον συνδυασμό

τύπου και πλάτους δεν έχει οριστεί διεπαφή, ο κώδικας οδηγείται αυτόματα στη βαθμωτή διαδρομή αντί να αποτύχει. Ο έλεγχος ορθότητας της ενότητας 3.6 επικυρώνει κάθε συνδυασμό χωριστά, οπότε η ισοδυναμία των διαδρομών δεν είναι υπόθεση αλλά επαληθευμένη ιδιότητα.

4.1.3 Υποστήριξη αριθμών κινητής υποδιαστολής μισής ακρίβειας

Η μισή ακρίβεια αποτελεί ιδιαίτερη περίπτωση, διότι ο επεξεργαστής αποθηκεύει μεν τιμές των 16 bit, δεν διαθέτει όμως αριθμητικές εντολές που να δρουν απευθείας πάνω τους στο πλάτος που χρειάζεται ο αλγόριθμος. Η προφανής λύση, η βαθμωτή επεξεργασία, θα ακύρωνε κάθε όφελος.

Η λύση που υιοθετείται εκμεταλλεύεται το γεγονός ότι η μετατροπή μεταξύ των δύο αναπαραστάσεων είναι μία μόνο εντολή. Η εξειδίκευση της διεπαφής για τη μισή ακρίβεια ορίζει ως διανυσματικό τύπο εκείνον της απλής ακρίβειας: η φόρτωση διαβάσει δεκαέξι τιμές των 16 bit και τις μετατρέπει σε δεκαέξι τιμές των 32, όλες οι πράξεις εκτελούνται σε απλή ακρίβεια, και η αποθήκευση μετατρέπει πίσω. Τα δεδομένα παραμένουν σε μισή ακρίβεια στη μνήμη και βρίσκονται σε απλή μόνο όσο διαρκεί ο υπολογισμός, όπως δείχνει το σχήμα 4.2.



Σχήμα 4.2: Η διαδρομή της μισής ακρίβειας. Τα δεδομένα παραμένουν σε 16 bit στη μνήμη, όπου καταλαμβάνουν τον μισό χώρο, και μετατρέπονται σε απλή ακρίβεια μόνο εντός των καταχωρητών, όσο διαρκεί ο υπολογισμός.

Η προσέγγιση αυτή είναι ακριβής και όχι προσεγγιστική. Κάθε τιμή μισής ακρίβειας αναπαρίσταται επακριβώς σε απλή, ενώ οι μόνες πράξεις που εκτελούνται είναι το ελάχιστο και το μέγιστο, οι οποίες επιλέγουν μία από τις δύο εισόδους αντί να υπολογίζουν νέα τιμή. Καμία στρογγυλοποίηση δεν μεσολαβεί, οπότε το αποτέλεσμα είναι ταυτόσημο με εκείνο μιας υποθετικής υλοποίησης που θα δούλευε εγγενώς σε μισή ακρίβεια.

Το κέρδος είναι σημαντικό ακριβώς για τους λόγους της ενότητας 4.4. Το πλάτος του καταχωρητή σε στοιχεία παραμένει δεκαέξι, όσο και για την απλή ακρίβεια, οπότε ο ρυθμός των συγκρίσεων δεν μεταβάλλεται. Η κίνηση δεδομένων όμως υποδιπλασιάζεται, καθώς κάθε στοιχείο καταλαμβάνει τα μισά bytes. Για αλγορίθμους περιορισμένους από τη μνήμη, όπως αποδείχθηκαν και οι δύο, αυτό μεταφράζεται άμεσα σε επιτάχυνση.

4.1.4 Παραλληλοποίηση σε πολλαπλά νήματα

Οι δύο αλγόριθμοι παραλληλοποιούνται με θεμελιωδώς διαφορετικό τρόπο, και η διαφορά αυτή καθορίζει πόσο επιθετικά μπορεί να κλιμακωθεί ο καθένας.

Η διτονική ταξινόμηση έχει καθολικές εξαρτήσεις: κάθε ομάδα επιπέδων απαιτεί ολοκληρωμένο το αποτέλεσμα της προηγούμενης. Η παραλληλία είναι επομένως αποκλειστικά εντός ομάδας, με φράγμα συγχρονισμού ανάμεσά τους. Το πλεονέκτημα είναι ότι τα νήματα δεν διατηρούν ιδιωτική κατάσταση και το κόστος τους εξαντλείται στον συγχρονισμό.

Το map-reduce έχει την αντίθετη δομή: τα νήματα εργάζονται εντελώς ανεξάρτητα πάνω σε ξένα μεταξύ τους τμήματα και συναντώνται μία μόνο φορά, στη συγχώνευση. Δεν απαιτείται κανένας συγχρονισμός κατά τη σάρωση, κάθε νήμα όμως διατηρεί δικό του σωρό μεγέθους k και η τελική συγχώνευση είναι σειριακή και ανάλογη του πλήθους των νημάτων.

Η συνέπεια είναι ότι το βέλτιστο πλήθος νημάτων δεν είναι το ίδιο για τους δύο. Η διτονική ταξινόμηση αντέχει περισσότερα νήματα σε μικρότερες εισόδους, ενώ το map-reduce απαιτεί σημαντικά μεγαλύτερο μερίδιο εργασίας ανά νήμα για να αποσβέσει το κόστος του επιπλέον σωρού και της σειριακής φάσης. Και στις δύο περιπτώσεις το πλήθος περιορίζεται δυναμικά ανάλογα με το μέγεθος της εισόδου, ώστε η παραλληλία να μην κοστίζει περισσότερο από όσο αποδίδει. Η επίδραση της επιλογής αυτής στα αποτελέσματα σχολιάζεται στην ενότητα 4.6.

4.2 Διτονική ταξινόμηση


Το χρονοδιάγραμμα επιπέδων της ενότητας 2.2.2 κατασκευάζεται μία φορά και είναι κοινό και για τις τρεις αρχιτεκτονικές: μια πρώτη φάση σχηματίζει ταξινομημένα μπλοκ μεγέθους k' , της μικρότερης δύναμης του δύο που δεν είναι μικρότερη του k , και μια δεύτερη τα συγχωνεύει ανά ζεύγη κρατώντας κάθε φορά τα k' καλύτερα από τα $2k'$ που συγκρίθηκαν.

Η άμεση μεταφορά αυτού του χρονοδιαγράμματος σε κώδικα οδηγεί σε υλοποίηση απελπιστικά περιορισμένη από τη μνήμη. Για k ίσο με 256, η πρώτη φάση και μόνο αποτελείται από 36 επίπεδα, καθένα από τα οποία θα ήταν ένα ξεχωριστό πέρασμα πάνω σε ολόκληρο τον πίνακα. Σε είσοδο τεσσάρων εκατομμυρίων στοιχείων αυτό σημαίνει δεκάδες διαδοχικές αναγνώσεις και εγγραφές δεκαέξι MB, με ελάχιστο υπολογισμό ανάμεσά τους. Ολόκληρη η υλοποίηση της παρούσας εργασίας είναι οργανωμένη γύρω από την αποφυγή αυτού ακριβώς του σχήματος.


Η βασική τεχνική είναι η συγχώνευση διαδοχικών επιπέδων σε ένα πέρασμα. Ένα επίπεδο χαρακτηρίζεται από την απόσταση j μεταξύ των στοιχείων που συγκρίνονται, και η απόσταση αυτή καθορίζει τι είναι εφικτό. Όταν το j είναι μικρότερο από το πλάτος του διανυσματικού καταχωρητή, τα δύο στοιχεία κάθε σύγκρισης βρίσκονται ήδη μέσα στον ίδιο καταχωρητή, και μια ολόκληρη ακολουθία τέτοιων επιπέδων εκτελείται τότε ως μία φόρτωση, μια σειρά αναδιατάξεων και συγκρίσεων εντός καταχωρητών, και μία αποθήκευση. Όταν το j είναι μεγαλύτερο, αλλά το σύνολο εργασίας ενός τμήματος χωρά στην κρυφή μνήμη, η ακολουθία εκτελείται τμήμα προς τμήμα, με το κάθε τμήμα να παραμένει στην κρυφή μνήμη για όλα τα επίπεδα. Μόνο τα επίπεδα με πολύ μεγάλο j

απαιτούν ξεχωριστό πέρασμα. Επιπλέον, ένα επίπεδο περικοπής του οποίου η απόσταση ισούται με το πλάτος του καταχωρητή απορροφά και τα επίπεδα επαναταξινόμησης που το ακολουθούν. Η αντιπαράθεση των δύο σχημάτων δίνεται στο σχήμα 4.3.

(α) άμεση μεταφορά



(β) συγχώνευση επιπέδων



Σχήμα 4.3: Η συγχώνευση διαδοχικών επιπέδων σε ένα πέρασμα. Κάθε ζεύγος βελών είναι μία ανάγνωση και μία εγγραφή ολόκληρου του πίνακα. Στο (α) κάθε επίπεδο είναι ξεχωριστό πέρασμα προς τη μνήμη· στο (β) τα επίπεδα ομαδοποιούνται κατά απόσταση j και μόνο η τελευταία ομάδα διατηρεί ξεχωριστό πέρασμα. Οι αριθμοί του σχήματος είναι ενδεικτικοί.

Το αποτέλεσμα είναι ότι η κίνηση δεδομένων δεν είναι απλώς μετρήσιμη, όπως περιγράφηκε στην ενότητα 3.3.4, αλλά και προβλέψιμη από τη δομή του χρονοδιαγράμματος. Η πρώτη φάση συμπύσσεται σε ένα πέρασμα επί τόπου, δηλαδή μία ανάγνωση και μία εγγραφή ανά στοιχείο, άρα $2n$. Κάθε βήμα της δεύτερης φάσης διαβάζει n_i στοιχεία και γράφει $n_i/2$, και η επαναταξινόμηση που ακολουθεί προσθέτει άλλα $2 \cdot n_i/2$, συνολικά $2,5 n_i$. Επειδή το n_i υποδιπλασιάζεται σε κάθε βήμα, το άθροισμα της δεύτερης φάσης είναι μια γεωμετρική σειρά:

$$\sum_i 2,5 n_i = 2,5 \left(n + \frac{n}{2} + \frac{n}{4} + \dots \right) = 2,5 \times 2n = 5n.$$

Η συνολική κίνηση είναι επομένως περίπου $7n$ στοιχεία, που είναι η προέλευση του συντελεστή επανάληψης της ενότητας 3.3.4. Για $n = 2^{22}$ και k ίσο με 256 η έκφραση αυτή δίνει 117 435 392 bytes, τιμή που ταυτίζεται ακριβώς με τη μετρούμενη.

Η ταυτόχρονη εκτέλεση σε πολλά νήματα γίνεται εντός κάθε ομάδας και όχι μεταξύ ομάδων, καθώς κάθε ομάδα εξαρτάται από το αποτέλεσμα της προηγούμενης. Το εύρος εξόδου κάθε ομάδας μοιράζεται στα νήματα, με τα όρια ευθυγραμμισμένα στο μέγεθος του τμήματος ή της γραμμής κρυφής μνήμης, ώστε δύο νήματα να μη γράφουν ποτέ στην ίδια γραμμή. Ανάμεσα στις ομάδες μεσολαβεί φράγμα συγχρονισμού και το πλήθος των νημάτων περιορίζεται επιπλέον ανάλογα με το μέγεθος της εισόδου, ώστε για μικρές εισόδους το κόστος του συγχρονισμού να μην υπερβαίνει το όφελος της παραλληλίας.

Τα επίπεδα περικοπής δεν μπορούν να εκτελεστούν επί τόπου, διότι κάθε στοιχείο της εξόδου προκύπτει από δύο στοιχεία της εισόδου σε διαφορετικές θέσεις. Για τον λόγο αυτό διατηρείται ένας δεύτερος πίνακας ίδιου μεγέθους και οι δύο πίνακες εναλλάσσονται μετά από κάθε τέτοια ομάδα. Η επιπλέον μνήμη είναι το τίμημα για την αποφυγή ενδιάμεσων αντιγραφών.


Τέλος, κάθε διανυσματική διαδρομή συνοδεύεται από ισοδύναμη βαθμωτή. Αν το υλικό δεν υποστηρίζει το απαιτούμενο πλάτος, ή αν οι παράμετροι ενός επιπέδου βρίσκονται εκτός του εύρους που χειρίζεται η διανυσματική υλοποίηση, η ίδια ακολουθία επιπέδων εκτελείται βαθμωτά. Το αποτέλεσμα είναι ταυτόσημο και διαφέρει μόνο ο χρόνος, κάτι που επιτρέπει στον έλεγχο ορθότητας της ενότητας 3.6 να επικυρώνει και τις δύο διαδρομές.

4.3 Map-reduce με τοπικούς σωρούς

Ο δεύτερος αλγόριθμος ακολουθεί εντελώς διαφορετική λογική από τον πρώτο. Αντί να επιβάλει μια σταθερή ακολουθία συγκρίσεων ανεξάρτητη από τα δεδομένα, διατηρεί τα k καλύτερα στοιχεία που έχει δει μέχρι στιγμής και εξετάζει κάθε νέο στοιχείο ως προς αυτά. Η είσοδος χωρίζεται σε τμήματα, ένα ανά νήμα, κάθε νήμα παράγει τα δικά του k καλύτερα, και τα επιμέρους αποτελέσματα συγχωνεύονται στο τέλος.

Κάθε νήμα διατηρεί έναν σωρό μεγέθους k , του οποίου η ρίζα είναι το χειρότερο από τα k στοιχεία που έχουν επιλεγεί. Ο σωρός αρχικοποιείται μαζικά από τα πρώτα k στοιχεία του τμήματος, κάτι που κοστίζει γραμμικά ως προς το k και είναι φθηνότερο από k διαδοχικές εισαγωγές. Από εκεί και πέρα, η ρίζα λειτουργεί ως κατώφλι: κάθε στοιχείο που δεν το ξεπερνά μπορεί να απορριφθεί χωρίς καμία περαιτέρω εργασία.

Το κρίσιμο σημείο της υλοποίησης είναι ότι η απόρριψη αυτή γίνεται μαζικά. Το κατώφλι αντιγράφεται σε έναν διανυσματικό καταχωρητή και συγκρίνεται ταυτόχρονα με ένα ολόκληρο μπλοκ στοιχείων, παράγοντας μια δυαδική μάσκα που δείχνει ποια από αυτά είναι υποψήφια. Η υλοποίηση εξετάζει τέσσερα τέτοια μπλοκ μαζί και, αν η ένωση των τεσσάρων μασκών είναι μηδενική, προσπερνά και τα τέσσερα με έναν μόνο έλεγχο. Στη συνηθισμένη περίπτωση, όπου ο σωρός έχει ήδη γεμίσει με μεγάλες τιμές και τα περισσότερα στοιχεία απορρίπτονται, το μεγαλύτερο μέρος της εισόδου διασχίζεται ακριβώς με αυτόν τον τρόπο: διαβάζεται, συγκρίνεται διανυσματικά και απορρίπτεται, χωρίς κανένα στοιχείο να εξεταστεί ποτέ ξεχωριστά. Η διαδικασία απεικονίζεται στο σχήμα 4.4.



Στη συνηθισμένη περίπτωση ακολουθείται σχεδόν πάντοτε η αριστερή διαδρομή.

Σχήμα 4.4: Η μαζική απόρριψη του map-reduce. Η ρίζα του σωρού αντιγράφεται σε ολόκληρο έναν διανυσματικό καταχωρητή και συγκρίνεται ταυτόχρονα με τέσσερα μπλοκ της εισόδου, παράγοντας μία δυαδική μάσκα ανά μπλοκ. Η ένωση των μασκών επιλέγει τη μία από τις δύο διαδρομές στο κάτω μέρος του σχήματος.

Μόνο για τα bits που είναι πράγματι αναμμένα εκτελείται βαθμωτή εργασία. Για κάθε τέτοιο στοιχείο, η ρίζα αντικαθίσταται και ο σωρός αποκαθίσταται με κατολίσθηση προς τα κάτω. Η αντικατάσταση της ρίζας προτιμάται από την εξαγωγή και επανεισαγωγή, καθώς η δεύτερη θα διέσχιζε τον σωρό δύο φορές αντί για μία.

Εδώ ακριβώς βρίσκεται η πηγή της εξάρτησης από τα δεδομένα που περιγράφηκε στην ενότητα 3.7.2. Αν η είσοδος είναι φθίνουσα, ο σωρός γεμίζει αμέσως με τις μεγαλύτερες τιμές, το κατώφλι ανεβαίνει στο μέγιστο δυνατό από την αρχή και όλη η υπόλοιπη είσοδος απορρίπτεται μαζικά. Αν είναι αύξουσα, συμβαίνει το αντίθετο: κάθε νέο στοιχείο ξεπερνά τη ρίζα, καμία μάσκα δεν είναι μηδενική και για κάθε στοιχείο εκτελείται πλήρης κατολίσθηση. Ο ίδιος κώδικας, με είσοδο ίδιου μεγέθους, εκτελεί στη μία περίπτωση σχεδόν καμία εργασία πέρα από την ανάγνωση και στην άλλη τη μέγιστη δυνατή.

Η φάση της συγχώνευσης είναι απλή και σειριακή. Τα στοιχεία κάθε τοπικού σωρού προσφέρονται διαδοχικά στον πρώτο, με το ίδιο κριτήριο κατωφλίου, και το τελικό αποτέλεσμα ταξινομείται. Το κόστος της φάσης αυτής είναι ανάλογο του γινομένου των νημάτων επί k και δεν εξαρτάται από το μέγεθος της εισόδου, οπότε για μεγάλα n είναι αμελητέο έναντι της σάρωσης.

Η κίνηση δεδομένων προκύπτει άμεσα από τη δομή αυτή: κάθε στοιχείο της εισόδου διαβάζεται ακριβώς μία φορά, και η συγχώνευση διακινεί δύο φορές το γινόμενο των νημάτων επί k . Το μέγεθος είναι επομένως ακριβές. Αντιθέτως, το πλήθος των συγκρίσεων αναφέρεται ως κάτω φράγμα, ακριβώς επειδή το βάθος κάθε κατολίσθησης εξαρτάται από τις τιμές, η καταμέτρηση προσμετρά μία σύγκριση ανά στοιχείο και αγνοεί την αναδιάταξη του σωρού. Η διάκριση αυτή είναι εκείνη που δηλώνεται στην ενότητα 3.3.4.

Το πλήθος των νημάτων περιορίζεται πολύ πιο συντηρητικά από ό,τι στη διτονική ταξινόμηση: απαιτείται περίπου ένα εκατομμύριο στοιχεία ανά νήμα. Ο λόγος είναι ότι κάθε επιπλέον νήμα προσθέτει έναν ακόμη σωρό μεγέθους k και επιβαρύνει τη σειριακή συγχώνευση, οπότε πάνω από κάποιο σημείο η παραλληλία κοστίζει περισσότερο

από όσο αποδίδει. Η συνέπεια είναι ότι για είσοδο τεσσάρων εκατομμυρίων στοιχείων χρησιμοποιούνται τέσσερα νήματα και όχι οκτώ, ακόμη και όταν ζητούνται οκτώ.

4.4 Διαχείριση μνήμης και κίνηση δεδομένων

Οι δύο αλγόριθμοι επιλύουν το ίδιο πρόβλημα στο ίδιο μηχάνημα, αλλά η συμπεριφορά τους ως προς τη μνήμη είναι ριζικά διαφορετική. Η αντιπαράθεσή τους είναι διαφωτιστική, διότι το μεγαλύτερο μέρος της διαφοράς στην επίδοση εξηγείται από αυτήν και μόνο.

Η θεμελιώδης διαφορά είναι ο όγκος της κίνησης. Από τις εκφράσεις των ενοτήτων 4.2 και 4.3, η διτονική ταξινόμηση διακινεί περίπου $7n$ στοιχεία, ενώ το map-reduce διακινεί n συν έναν όρο ανάλογο του γινομένου των νημάτων επί k , ο οποίος για μικρό k είναι αμελητέος. Για είσοδο τεσσάρων εκατομμυρίων ακεραίων, η πρώτη διακινεί 117 MB και η δεύτερη 17 MB. Ο λόγος επτά προς ένα δεν είναι αποτέλεσμα υλοποίησης, αλλά του ίδιου του αλγορίθμου: το δίκτυο ταξινόμησης υποχρεούται να διατρέξει τα δεδομένα πολλές φορές, ενώ η επιλογή με σωρό τα διατρέχει ακριβώς μία.

Εξίσου σημαντική είναι η φύση της πρόσβασης. Το map-reduce διαβάζει την είσοδο και δεν τη μεταβάλλει ποτέ, οπότε η κίνηση είναι καθαρά ακολουθιακή ανάγνωση, το ευνοϊκότερο δυνατό μοτίβο για τον προσκομιστή δεδομένων. Η διτονική ταξινόμηση αντιθέτως γράφει σε κάθε πέρασμα, και οι συγκρίσεις γίνονται μεταξύ στοιχείων που απέχουν μεταβλητή απόσταση, η οποία σε ορισμένα επίπεδα είναι μεγαλύτερη από ολόκληρο το τμήμα που χωρά στην κρυφή μνήμη.

Διαφέρει επίσης το αποτύπωμα στη μνήμη. Η διτονική ταξινόμηση απαιτεί δεύτερο πίνακα ισομεγέθη με τον πρώτο, για τον λόγο που εξηγήθηκε στην ενότητα 4.2, οπότε δεσμεύει συνολικά $2n$ στοιχεία. Το map-reduce δεσμεύει μόνο τους τοπικούς σωρούς, δηλαδή γινόμενο νημάτων επί k στοιχεία, ανεξάρτητα από το μέγεθος της εισόδου. Για μικρό k το σύνολο αυτό είναι τόσο μικρό ώστε παραμένει μόνιμα στα ταχύτερα επίπεδα της ιεραρχίας, και η μόνη κίνηση προς την κύρια μνήμη είναι η ίδια η ανάγνωση της εισόδου.

Η συνέπεια είναι ότι οι δύο αλγόριθμοι βρίσκονται σε διαφορετικά σημεία απέναντι στα ταβάνια της ενότητας 3.4. Και οι δύο εκτελούν λίγες πράξεις ανά byte, οπότε κανένας δεν πλησιάζει το υπολογιστικό ταβάνι, όμως το map-reduce επιτυγχάνει σημαντικά υψηλότερο ρυθμό διακίνησης από τη διτονική ταξινόμηση, όπως αναμένεται από το ευνοϊκότερο μοτίβο πρόσβασης. Η διτονική ταξινόμηση πληρώνει διπλά: διακινεί επαπλάσιο όγκο και τον διακινεί με χαμηλότερο ρυθμό.

Πρέπει τέλος να σημειωθεί ότι το πλεονέκτημα αυτό δεν είναι καθολικό. Ο όρος που αφορά τους τοπικούς σωρούς μεγαλώνει ανάλογα με το k , και για τις μεγαλύτερες τιμές που εξετάζονται παύει να είναι αμελητέος: ο σωρός δεν χωρά πλέον στα ταχύτερα επίπεδα της κρυφής μνήμης και η φάση της συγχώνευσης, που είναι σειριακή, αποκτά βάρος συγκρίσιμο με τη σάρωση. Η διτονική ταξινόμηση, της οποίας η κίνηση εξαρτάται πολύ ασθενέστερα από το k , δεν υφίσταται αντίστοιχη επιβάρυνση. Η σύγκριση των δύο σε όλο το εύρος των παραμέτρων γίνεται στο κεφάλαιο 7.

4.5 Υλοποίηση αναφοράς

Το μέτρο σύγκρισης για τον επεξεργαστή είναι η `std::partial_sort` της πρότυπης βιβλιοθήκης, για τους λόγους που εξηγήθηκαν στην ενότητα 3.5. Ενσωματώνεται στην ίδια υποδομή με τις δύο υλοποιήσεις της εργασίας, εκτελείται στον ίδιο βρόχο μέτρησης και επαληθεύεται με τον ίδιο έλεγχο ορθότητας, οπότε οι χρόνοι της είναι άμεσα συγκρίσιμοι.

Υπάρχει ωστόσο μια ασυμμετρία που πρέπει να δηλωθεί ρητά, διότι επηρεάζει την ερμηνεία κάθε επιτάχυνσης που αναφέρεται στο κεφάλαιο 7. Η συνάρτηση της βιβλιοθήκης είναι αυστηρά μονονηματική: δεν δέχεται πλήθος νημάτων και δεν αξιοποιεί παρά έναν πυρήνα. Αντιθέτως, η διτονική ταξινόμηση χρησιμοποιεί έως οκτώ νήματα και το `map-reduce` έως τέσσερα ή οκτώ, ανάλογα με το μέγεθος της εισόδου, οπότε κάθε λόγος χρόνων μεταξύ των υλοποιήσεων της εργασίας και της βιβλιοθήκης συγκεντρώνει δύο διακριτές αιτίες: τη διαφορά του αλγορίθμου και τη διαφορά του πλήθους των πυρήνων.

Η επιλογή αυτή δεν είναι αυθαίρετη. Ερώτημα της εργασίας δεν είναι ποιος αλγόριθμος είναι καλύτερος υπό ίσους πόρους, αλλά πόσο ταχύτερα μπορεί να λυθεί το πρόβλημα σε κάθε αρχιτεκτονική σε σχέση με ό,τι έχει ήδη στη διάθεσή του ο προγραμματιστής. Η καθιερωμένη λύση για τον επεξεργαστή είναι πράγματι μονονηματική, ο αναγνώστης όμως πρέπει να έχει υπόψη ότι μια σύγκριση νήμα προς νήμα θα ήταν αυστηρότερη και θα έδινε μικρότερες επιταχύνσεις.

Πρέπει τέλος να σημειωθεί ότι η καταμετρούμενη κίνηση δεδομένων της υλοποίησης αναφοράς είναι κάτω φράγμα, όπως αναφέρθηκε στην ενότητα 3.3.4: προσμετρώνται μόνο η είσοδος και η έξοδος, ενώ τα εσωτερικά περάσματα της βιβλιοθήκης δεν είναι παρατηρήσιμα. Κάθε ποσοστό αξιοποίησης του ταβανιού μνήμης που αναφέρεται για αυτήν είναι επομένως υποεκτίμηση και δεν συγκρίνεται άμεσα με τα αντίστοιχα ποσοστά των δύο άλλων υλοποιήσεων.

4.6 Περιοριστικοί παράγοντες

Η τοποθέτηση των μετρήσεων απέναντι στα ταβάνια της ενότητας 3.4 δείχνει ότι ο περιοριστικός παράγοντας δεν είναι ο ίδιος σε ολόκληρο το εύρος των παραμέτρων, και μάλιστα αντιστρέφεται.

Για μικρό k και μεγάλη είσοδο, και οι δύο υλοποιήσεις περιορίζονται σαφώς από τη μνήμη. Στη μεγαλύτερη είσοδο που εξετάζεται, η διτονική ταξινόμηση προσεγγίζει τα τέσσερα πέμπτα του μετρημένου ταβανιού εύρους ζώνης και το `map-reduce` τα τρία τέταρτα, ενώ και οι δύο αξιοποιούν γύρω στο πέντε τοις εκατό του υπολογιστικού ταβανιού. Η απόσταση των δύο μεγεθών δεν αφήνει περιθώριο αμφιβολίας για τη φύση του περιορισμού.

Η διάγνωση αυτή έχει πρακτική συνέπεια για κάθε προσπάθεια βελτίωσης. Η διτονική ταξινόμηση δεν είναι αργή επειδή εκτελεί τις συγκρίσεις της αναποτελεσματικά, αλλά επειδή διακινεί επταπλάσιο όγκο δεδομένων. Καμία περαιτέρω βελτιστοποίηση του υπολογιστικού πυρήνα δεν πρόκειται να την επιταχύνει ουσιωδώς· το περιθώριο βρίσκεται αποκλειστικά στη μείωση της κίνησης. Το `map-reduce`, από την άλλη, διαβάζει ήδη κάθε στοιχείο ακριβώς μία φορά και λειτουργεί κοντά στον ρυθμό με τον οποίο η μνήμη

μπορεί να το τροφοδοτήσει. Υπό αυτή τη συνθήκη είναι ουσιαστικά βέλτιστο, με την έννοια ότι δεν μπορεί να γίνει ταχύτερο χωρίς να διαβάσει λιγότερα.

Για μεγάλο k η εικόνα αλλάζει ριζικά και καμία από τις δύο δεν πλησιάζει κανένα ταβάνι. Στη μεγαλύτερη τιμή του k που εξετάζεται, η αξιοποίηση και των δύο ταβανιών πέφτει σε ποσοστά της τάξης της μονάδας για το map-reduce και σε λίγο πάνω από δέκα τοις εκατό για τη διτονική ταξινόμηση. Όταν μια μέτρηση απέχει από αμφότερα τα ταβάνια, ο περιορισμός δεν είναι ούτε το εύρος ζώνης ούτε η υπολογιστική ικανότητα, αλλά οι καθυστερήσεις και η ανεπαρκής παραλληλία.

Ο μηχανισμός είναι σαφής για το map-reduce και προκύπτει από την ενότητα 4.3. Όσο μεγαλώνει το k , το κατώφλι του σωρού χαμηλώνει και το ποσοστό απόρριψης καταρρέει: η γρήγορη διαδρομή που προσπερνά τέσσερα μπλοκ ταυτόχρονα παύει να ενεργοποιείται και σχεδόν κάθε στοιχείο επιβάλλει πλήρη κατολίσθηση. Ταυτόχρονα ο σωρός παύει να χωρά στις ταχύτερες βαθμίδες της κρυφής μνήμης, οπότε κάθε κατολίσθηση γίνεται μια ακολουθία προσβάσεων με τυχαία διεύθυνση και βάθος λογαριθμικό ως προς το k . Ο αλγόριθμος μετατρέπεται από φραγμένος από το εύρος ζώνης σε φραγμένο από την καθυστέρηση, και στη μεγαλύτερη τιμή του k γίνεται τελικά βραδύτερος από τη διτονική ταξινόμηση, την οποία υπερτερούσε κατά παράγοντα έξι για μικρό k .

Δευτερεύων αλλά υπαρκτός παράγοντας είναι τα όρια κλιμάκωσης των νημάτων που περιγράφηκαν στις προηγούμενες ενότητες. Επειδή το map-reduce απαιτεί περίπου ένα εκατομμύριο στοιχεία ανά νήμα, σε μεσαία μεγέθη εισόδου χρησιμοποιείται μέρος μόνο των διαθέσιμων πυρήνων. Μέρος της απόστασης από το ταβάνι σε αυτή την περιοχή δεν οφείλεται στον αλγόριθμο αλλά στο ότι δεν εργάζεται ολόκληρος ο επεξεργαστής.

Κεφάλαιο 5

Υλοποίηση σε GPU

5.1 Σχεδιαστικές επιλογές

Δύο ζητήματα διαπερνούν και τις δύο υλοποιήσεις του κεφαλαίου: ο χειρισμός των τύπων δεδομένων και η αντιστοίχιση της εργασίας στη δομή εκτέλεσης της συσκευής.

Ο χειρισμός των τύπων ακολουθεί την ίδια λογική με τον επεξεργαστή, αλλά με απλούστερη μορφή. Ορίζεται μια δομή ανά τύπο που εκθέτει τις πράξεις τις οποίες χρειάζονται οι αλγόριθμοι, δηλαδή τις συγκρίσεις, το ελάχιστο, το μέγιστο και την ουδέτερη τιμή που χρησιμοποιείται για τη συμπλήρωση και οι αλγόριθμοι γράφονται μία φορά ως προς αυτήν. Η ουσιώδης διαφορά από την περίπτωση του επεξεργαστή είναι ότι εδώ δεν υπάρχει ζήτημα επιλογής πλάτους κατά την εκτέλεση: ο μεταγλωττιστής παράγει κώδικα για τη συγκεκριμένη αρχιτεκτονική της συσκευής, οπότε η αφαίρεση εξυπηρετεί μόνο τη διάκριση των τύπων και όχι τη διάκριση των διανυσματικών επεκτάσεων.

Απαιτείται επιπλέον μια αντιστοίχιση μεταξύ των τύπων του host και εκείνων της συσκευής, καθώς η μισή ακρίβεια εκπροσωπείται από διαφορετικό τύπο στα δύο περιβάλλοντα. Η αντιστοίχιση αυτή γίνεται σε ένα σημείο και είναι διαφανής για τους αλγορίθμους, οι οποίοι δεν γνωρίζουν σε ποια πλευρά εκτελούνται.

5.1.1 Αντιστοίχιση σε πλέγμα και ομάδες νημάτων

Η συσκευή εκτελεί νήματα οργανωμένα σε ομάδες και τις ομάδες σε πλέγμα. Η διάκριση δεν είναι διοικητική: νήματα της ίδιας ομάδας μπορούν να μοιραστούν γρήγορη μνήμη και να συγχρονιστούν μεταξύ τους, ενώ νήματα διαφορετικών ομάδων δεν έχουν καμία από τις δύο δυνατότητες. Κάθε αλγόριθμος πρέπει επομένως να τοποθετήσει τις εξαρτήσεις του εντός ομάδων όπου αυτό είναι δυνατόν.

Και οι δύο υλοποιήσεις χρησιμοποιούν ομάδες των 256 νημάτων, μέγεθος που ισορροπεί ανάμεσα σε αρκετά νήματα ώστε να καλύπτονται οι καθυστερήσεις της μνήμης και όχι τόσα ώστε να περιορίζεται το πλήθος των ομάδων που μπορούν να συνυπάρχουν σε κάθε πολυεπεξεργαστή.

Ο τρόπος με τον οποίο προκύπτει το μέγεθος του πλέγματος διαφέρει όμως ριζικά μεταξύ των δύο και η διαφορά αντανakλά τη δομή του κάθε αλγορίθμου. Στη διτονική

ταξινόμηση το πλέγμα καθορίζεται από τα δεδομένα: κάθε ομάδα αναλαμβάνει ένα πλακίδιο, οπότε το πλήθος των ομάδων είναι απλώς το πλήθος των πλακιδίων στα οποία χωρίζεται το ενεργό τμήμα, με άμεση αντιστοίχιση χωρίς ελευθερία επιλογής.

Στο map-reduce αντιθέτως το πλέγμα είναι αντικείμενο απόφασης και η απόφαση προκύπτει από τρεις ανεξάρτητους περιορισμούς: την κατάληψη που επιτρέπει το υλικό, την οποία η υλοποίηση ζητά από τη συσκευή αντί να την υποθέσει, τη συνθήκη πλήρωσης των σωρών της ενότητας 5.3.1, η οποία μειώνει σκόπιμα τις ομάδες όταν περισσότερα νήματα θα σήμαιναν σωρούς που δεν φιλτράρουν και τον διαθέσιμο χώρο εργασίας, αφού κάθε νήμα απαιτεί σωρό μεγέθους k και το συνολικό πλήθος των νημάτων περιορίζεται από ένα ανώτατο όριο μνήμης, το οποίο για τα μεγάλα k γίνεται δεσμευτικό. Από τους τρεις επικρατεί ο αυστηρότερος.

Η τελευταία αυτή εξάρτηση αξίζει να σημειωθεί, διότι είναι αντίστροφη της διαίσθησης: όσο μεγαλώνει το k , τόσο λιγότερα νήματα μπορεί να εκτελέσει η συσκευή, ακριβώς επειδή κάθε νήμα κοστίζει περισσότερη μνήμη. Ο περιορισμός δρα προς την ίδια κατεύθυνση με εκείνον της ενότητας 5.3.1 και οι δύο μαζί εξηγούν γιατί η υλοποίηση αδυνατεί να αξιοποιήσει τη συσκευή στις μεγάλες τιμές του k .

Τέλος, ανεξάρτητα από το μέγεθος του πλέγματος, η σειρά με την οποία τα νήματα προσπελαίνουν τη μνήμη έχει καθοριστική σημασία. Οι ταυτόχρονες προσβάσεις γειτονικών νημάτων συγχωνεύονται σε ενιαίες συναλλαγές μόνο αν αφορούν γειτονικές διευθύνσεις. Για τον λόγο αυτό η σάρωση του map-reduce δεν αναθέτει σε κάθε νήμα ένα συνεχόμενο τμήμα, όπως θα ήταν φυσικό στον επεξεργαστή, αλλά διατρέχει την είσοδο με βήμα ίσο με το συνολικό πλήθος των νημάτων.

5.2 Διτονική ταξινόμηση

Το χρονοδιάγραμμα των επιπέδων είναι το ίδιο με εκείνο της ενότητας 4.2, καθώς κατασκευάζεται από κοινό κώδικα. Ό,τι αλλάζει είναι ο τρόπος εκτέλεσής του, και το πρόβλημα που καλείται να λύσει η υλοποίηση παραμένει το ίδιο: το πλήθος των επιπέδων είναι μεγάλο και η αφελής αντιστοίχιση ενός επιπέδου σε μία εκκίνηση πυρήνα θα σήμαινε δεκάδες διαδοχικά περάσματα πάνω από την καθολική μνήμη.

Στη μονάδα γραφικών προστίθεται ένα δεύτερο κόστος που δεν υπάρχει στον επεξεργαστή. Κάθε εκκίνηση πυρήνα έχει σταθερή επιβάρυνση και μια σάρωση με εκατοντάδες εκκινήσεις πληρώνει την επιβάρυνση αυτή εκατοντάδες φορές. Για τον λόγο αυτό ολόκληρο το δίκτυο δεν εκκινείται πυρήνα προς πυρήνα, αλλά καταγράφεται μία φορά ως γράφος εκτέλεσης και στη συνέχεια αναπαράγεται. Η δρομολόγηση γίνεται έτσι μία φορά αντί για κάθε επίπεδο.

Οι πυρήνες που συνθέτουν τον γράφο είναι τριών ειδών και η επιλογή μεταξύ τους καθορίζεται από την απόσταση j του επιπέδου, όπως ακριβώς και στον επεξεργαστή. Όταν η απόσταση είναι μικρή, μια ολόκληρη ακολουθία επιπέδων εκτελείται μέσα στην κοινή μνήμη μιας ομάδας νημάτων, όπως περιγράφεται στην ενότητα 5.2.1. Όταν είναι πολύ μεγάλη ώστε να μη χωρά σε πλακίδιο, τα δεδομένα παραμένουν στην καθολική μνήμη και ένας πυρήνας εκτελεί έως πέντε διαδοχικά επίπεδα κρατώντας τα ενδιάμεσα αποτελέσματα σε καταχωρητές. Τα επίπεδα περικοπής, τέλος, έχουν δικό τους πυρήνα, ο οποίος διαβάσει δύο στοιχεία και γράφει ένα σε δεύτερο πίνακα, με τους δύο πίνακες να εναλλάσσονται όπως και στον επεξεργαστή.

5.2.1 Οργάνωση σε πλακίδια και κοινή μνήμη

Η κοινή μνήμη μιας ομάδας νημάτων είναι ρητά διαχειριζόμενη, σε αντίθεση με την κρυφή μνήμη του επεξεργαστή που λειτουργεί αυτόματα. Η υλοποίηση φορτώνει ένα πλακίδιο δεδομένων σε αυτήν, εκτελεί όσα επίπεδα είναι δυνατόν εξ ολοκλήρου μέσα της, και το γράφει πίσω μία φορά. Όσα επίπεδα συγχωνευθούν με τον τρόπο αυτό δεν κοστίζουν καμία επιπλέον κίνηση προς την καθολική μνήμη.

Το μέγεθος του πλακιδίου προκύπτει από δύο περιορισμούς: αφενός δεν μπορεί να ξεπεράσει τα 48 KB που διατίθενται ανά ομάδα νημάτων χωρίς ειδική ρύθμιση, αφετέρου επιλέγεται μικρότερο όταν το σύνολο εργασίας χωρά στην κρυφή μνήμη δεύτερου επιπέδου της συσκευής, οπότε ο περιορισμός δεν είναι πλέον η κίνηση προς την κύρια μνήμη, αλλά το πλήθος των ομάδων που μπορούν να είναι ταυτόχρονα ενεργές. Για ακεραίους των 32 bit το πλακίδιο καταλήγει στα 8192 στοιχεία.


Ο περιορισμός δεν αφορά μόνο την παρούσα υλοποίηση: οι δημοσιευμένες μέθοδοι μερικής ταξινόμησης για μονάδες γραφικών υπόκεινται στο ίδιο φράγμα και δεν υποστηρίζουν k πέρα από μερικές εκατοντάδες, ακριβώς επειδή οι δομές τους πρέπει να χωρούν στην κοινή μνήμη και στους καταχωρητές [3, 5].

Το όριο αυτό έχει συνέπεια που καθορίζει τη συμπεριφορά ολόκληρης της υλοποίησης. Ένα επίπεδο μπορεί να συγχωνευθεί μόνο αν η απόσταση των στοιχείων που συγκρίνει χωρά στο πλακίδιο, δηλαδή αν είναι μικρότερη από το ήμισυ του μεγέθους του. Επειδή οι αποστάσεις της πρώτης φάσης φτάνουν έως το ήμισυ του μεγέθους των ταξινομημένων μπλοκ, το κρίσιμο μέγεθος είναι το k' της ενότητας 4.2: όσο τα μπλοκ χωρούν στο πλακίδιο, σχεδόν όλα τα επίπεδα συγχωνεύονται.

Το σχήμα 5.1 αντιπαραθέτει τις δύο περιπτώσεις. Για τις μικρές και μεσαίες τιμές του k αυτό ισχύει, και η κίνηση δεδομένων προκύπτει ουσιαστικά ίδια με εκείνη του επεξεργαστή: περίπου επταπλάσια της αφελούς εκτίμησης, με τις δύο αρχιτεκτονικές να συμφωνούν μέχρι το τελευταίο byte για k έως 4096, όπως αναφέρθηκε στην ενότητα 3.3.4. Η σύμπτωση δεν είναι τυχαία: εκτελείται το ίδιο χρονοδιάγραμμα με ισοδύναμη στρατηγική συγχώνευσης, απλώς σε ρητά διαχειριζόμενη μνήμη αντί για αυτόματα.


Για τη μεγαλύτερη τιμή του k που εξετάζεται η συνθήκη καταρρέει. Τα ταξινομημένα μπλοκ αποκτούν μέγεθος 131072 στοιχείων, δεκαέξι φορές μεγαλύτερο από το πλακίδιο, οπότε το μεγαλύτερο μέρος των επιπέδων της πρώτης φάσης δεν μπορεί πλέον να συγχωνευθεί και εκτελείται με περάσματα πάνω από την καθολική μνήμη. Η μετρούμενη κίνηση αυξάνεται αντίστοιχα, από επταπλάσια σε εικοσιδιπλάσια έως εικοσιενναπλάσια της αφελούς εκτίμησης ανάλογα με το μέγεθος της εισόδου. Εδώ βρίσκεται η αιτία για την οποία ο συντελεστής επανάληψης της ενότητας 3.3.4 δηλώνεται μόνο για k πολύ μικρότερο του n , καθώς και ένα μέρος της εξήγησης για τη συμπεριφορά της υλοποίησης στα μεγάλα k .

(α) $k' \leq \text{πλακίδιο}$



ένα πέρασμα:
όλα τα επίπεδα
συγχωνεύονται

(β) $k' > \text{πλακίδιο}$



πολλά περάσματα:
τα επίπεδα με μεγάλη
απόσταση δεν χωρούν

Η μετρούμενη κίνηση περνά από $7n$ σε $25n$ έως $56n$ όταν το k' ξεπεράσει το πλακίδιο.

Σχήμα 5.1: Η σχέση του ταξινομημένου μπλοκ με το πλακίδιο της κοινής μνήμης. Ένα επίπεδο μπορεί να εκτελεστεί χωρίς επιστροφή στην καθολική μνήμη μόνο αν η απόσταση των στοιχείων που συγκρίνει χωρά στο πλακίδιο. Όσο τα ταξινομημένα μπλοκ μεγέθους k' χωρούν σε αυτό (α), σχεδόν όλα τα επίπεδα συγχωνεύονται σε ένα πέρασμα και η κίνηση δεδομένων ταυτίζεται με εκείνη του επεξεργαστή. Όταν το k' ξεπεράσει το μέγεθος του πλακιδίου (β), τα επίπεδα με μεγάλη απόσταση εκτελούνται με ξεχωριστά περάσματα πάνω από την καθολική μνήμη και η κίνηση πολλαπλασιάζεται. Για ακεραίους των 32 bit το πλακίδιο είναι 8192 στοιχεία, οπότε η μετάβαση συμβαίνει μεταξύ των δύο μεγαλύτερων τιμών του k που εξετάστηκαν.

5.3 Map-reduce με τοπικούς σωρούς

Ο αλγόριθμος είναι ο ίδιος με εκείνον της ενότητας 4.3: κάθε νήμα διατηρεί σωρό μεγέθους k με τα καλύτερα στοιχεία που έχει δει, η ρίζα λειτουργεί ως κατώφλι, και τα επιμέρους αποτελέσματα συγχωνεύονται στο τέλος. Η διαφορά βρίσκεται στην κλίμακα της αποσύνθεσης και στις συνέπειές της.

Στον επεξεργαστή τα νήματα είναι λίγα και κάθε ένα αναλαμβάνει συνεχόμενο τμήμα της εισόδου. Στη μονάδα γραφικών τα νήματα είναι χιλιάδες και διατρέχουν την είσοδο με βήμα ίσο με το συνολικό τους πλήθος, ώστε οι ταυτόχρονες προσβάσεις γειτονικών νημάτων να αφορούν γειτονικές διευθύνσεις και να συγχωνεύονται σε ενιαίες συναλλαγές μνήμης.

Κάθε νήμα διατηρεί δικό του σωρό, όχι κοινό ανά ομάδα. Οι σωροί δεν χωρούν στην κοινή μνήμη, καθώς το γινόμενο του πλήθους των νημάτων επί k υπερβαίνει κατά πολύ τα διαθέσιμα 48 KB ανά ομάδα, οπότε φυλάσσονται σε χώρο εργασίας στην καθολική μνήμη. Αυτό είναι και το σημείο όπου η υλοποίηση αποκλίνει ουσιαστικά από εκείνη του επεξεργαστή ως προς την κίνηση δεδομένων: ο χώρος εργασίας είναι ανάλογος του γινομένου των νημάτων επί k , και με χιλιάδες νήματα ο όρος αυτός παύει να είναι αμελητέος.

Η συγχώνευση γίνεται σε δύο επίπεδα. Εντός κάθε ομάδας νημάτων, οι σωροί συνε-

νώνονται ανά ζεύγη σε δέντρο, με λογαριθμικό πλήθος βημάτων ως προς το μέγεθος της ομάδας. Το αποτέλεσμα κάθε ομάδας συγχωνεύεται στη συνέχεια με τα υπόλοιπα. Η δομή αυτή αποφεύγει τη σειριακή φάση που επιβαρύνει τον επεξεργαστή, αλλά εισάγει το δικό της κόστος, καθώς κάθε βήμα του δέντρου διαβάσει και γράφει σωρούς από την καθολική μνήμη.

5.3.1 Όριο παραλληλίας για μεγάλα k

Η αποτελεσματικότητα του αλγορίθμου στηρίζεται εξ ολοκλήρου στην απόρριψη: ένα στοιχείο που δεν ξεπερνά τη ρίζα του σωρού κοστίζει μία μόνο σύγκριση. Η ρίζα όμως αποκτά νόημα ως κατώφλι μόνο αφού ο σωρός γεμίσει. Όσο περιέχει λιγότερα από k στοιχεία, κάθε νέο στοιχείο εισάγεται υποχρεωτικά και καμία απόρριψη δεν συμβαίνει.

Από την παρατήρηση αυτή προκύπτει ένας ποσοτικός περιορισμός. Αν η είσοδος μεγέθους n μοιραστεί σε P νήματα, κάθε νήμα βλέπει n/P στοιχεία και ο σωρός του γεμίζει μόνο αν $n/P \geq k$. Η συνθήκη αυτή ισοδυναμεί με

$$P \leq \frac{n}{k}$$

και θέτει ανώτατο όριο στο πλήθος των νημάτων που μπορούν να συνεισφέρουν ουσιαστικά. Πέραν αυτού, τα επιπλέον νήματα δεν επιταχύνουν τον υπολογισμό αλλά τον επιβαρύνουν: γεμίζουν χώρο εργασίας με σωρούς που δεν φιλτράρουν ποτέ και προσθέτουν επίπεδα στο δέντρο συγχώνευσης.

Ο περιορισμός είναι δεσμευτικός ακριβώς εκεί όπου η μονάδα γραφικών θα ήταν πιο χρήσιμη. Για τη μεγαλύτερη τιμή του k που εξετάζεται και για είσοδο δεκαέξι εκατομμυρίων στοιχείων, ο λόγος n/k είναι μόλις 128. Μια συσκευή με χιλιάδες πυρήνες μπορεί επομένως να απασχολήσει ουσιαστικά εκατόν είκοσι οκτώ νήματα, δηλαδή κλάσμα της τάξης του ενός τοις εκατό των διαθέσιμων. Η υποδομή δεν υποαπασχολείται από αδυναμία υλοποίησης, αλλά από τη δομή του ίδιου του αλγορίθμου.

Το σχήμα 5.2 αποτυπώνει τις δύο περιπτώσεις. Η υλοποίηση αναγνωρίζει τη συνθήκη και αντιδρά σε αυτήν. Πριν από την εκκίνηση υπολογίζεται αν οι σωροί προλαβαίνουν να γεμίσουν με πλήρη κατάληψη της συσκευής. Όταν αυτό ισχύει, το πλήθος των ομάδων περιορίζεται σκόπιμα, αντίστροφα ανάλογα του k , ώστε κάθε νήμα να αναλάβει μεγαλύτερο μερίδιο εισόδου και ο σωρός του να φιλτράρει αποδοτικά: θυσιάζεται δηλαδή ονομαστική παραλληλία για πραγματική απόρριψη. Όταν αντιθέτως οι σωροί δεν πρόκειται να γεμίσουν σε καμία περίπτωση, η μείωση των ομάδων δεν θα προσέφερε τίποτα και η συσκευή χρησιμοποιείται με πλήρη κατάληψη.



Η ωφέλιμη παραλληλία φράσσεται επομένως στο $P \leq n/k$, ανεξάρτητα από το μέγεθος του πλέγματος.

Σχήμα 5.2: Το όριο παραλληλίας του map-reduce για μεγάλα k . Κάθε νήμα διατηρεί δικό του σωρό μεγέθους k και μπορεί να απορρίψει στοιχεία μόνο αφού ο σωρός γεμίσει, δηλαδή μόνο αφού δει τουλάχιστον k στοιχεία. Όταν το τμήμα που αναλογεί σε κάθε νήμα είναι μεγαλύτερο από k (α), το κατώφλι ενεργοποιείται νωρίς και το υπόλοιπο του τμήματος φιλτράρεται. Όταν όμως το πλήθος των νημάτων αυξηθεί τόσο ώστε το τμήμα να γίνει μικρότερο από k (β), κανένας σωρός δεν γεμίζει και το φιλτράρισμα δεν ενεργοποιείται ποτέ. Πρόκειται για ιδιότητα του αλγορίθμου και όχι της υλοποίησης: ούτε το μέγεθος του πλέγματος ούτε η διάταξη του χώρου εργασίας μπορούν να την άρουν.

5.4 Διαχείριση μνήμης και κίνηση δεδομένων

Στη μονάδα γραφικών η διαχείριση της μνήμης αποκτά μια διάσταση που δεν υπάρχει στον επεξεργαστή. Δεν πρόκειται πλέον για μία ιεραρχία με διαδοχικά επίπεδα, αλλά για δύο ξεχωριστά συστήματα μνήμης που συνδέονται με έναν δίαυλο ασύγκριτα βραδύτερο από αμφότερα. Η μετρημένη τοπική μνήμη της συσκευής αποδίδει περίπου 320 GB/s, ενώ ο δίαυλος προς τον host μόλις 14 GB/s: διαφορά μεγαλύτερη του εικοσαπλάσιου.

Εντός της συσκευής, η εικόνα της κίνησης είναι ανάλογη με εκείνη του επεξεργαστή, αλλά όχι ταυτόσημη. Για μικρό k η διτονική ταξινόμηση διακινεί επταπλάσιο όγκο, όπως και στον επεξεργαστή, ενώ η κίνηση του map-reduce εξαρτάται αισθητά από το μέγεθος της εισόδου. Η διαφορά οφείλεται εξ ολοκλήρου στον χώρο εργασίας των σωρών που περιγράφηκε στην ενότητα 5.3: με χιλιάδες νήματα, καθένα από τα οποία διατηρεί δικό του σωρό στην καθολική μνήμη, ο όρος που στον επεξεργαστή ήταν αμελητέος γίνεται συγκρίσιμος με την ίδια τη σάρωση.

Η μεταφορά προς και από τη συσκευή είναι όμως εκείνη που κυριαρχεί. Η είσοδος πρέπει να διασχίσει τον δίαυλο μία φορά προς τη συσκευή και το αποτέλεσμα να επιστρέψει. Για είσοδο τεσσάρων εκατομμυρίων ακεραίων, τα δεκαεπτά περίπου MB απαιτούν πάνω από ένα χιλιοστό του δευτερολέπτου μόνο για να φτάσουν εκεί, τη στιγμή που ο ίδιος ο πυρήνας της διτονικής ταξινόμησης ολοκληρώνεται σε μισό. Η μεταφορά κοστίζει δηλαδή περισσότερο από διπλάσια του υπολογισμού που εξυπηρετεί.

Η παρατήρηση αυτή είναι ακριβώς ο λόγος για τον οποίο η εργασία μετρά δύο πεδία

και όχι ένα, όπως ορίστηκε στην ενότητα 3.3.1. Για την ίδια εκτέλεση, ο αλγοριθμικός χρόνος είναι περίπου μισό χιλιοστό του δευτερολέπτου ενώ ο συνολικός ξεπερνά τα δύο: σχεδόν τα τρία τέταρτα του κόστους δεν αφορούν καθόλου τον υπολογισμό. Μια σύγκριση που θα στηριζόταν αποκλειστικά στο αλγοριθμικό πεδίο θα απέδιδε στη μονάδα γραφικών πλεονέκτημα που δεν έχει όταν το πρόβλημα τίθεται ως μεταφορά δεδομένων από την κύρια μνήμη και πίσω.

Αξίζει να σημειωθεί ότι η καθιερωμένη τεχνική βελτίωσης των μεταφορών, δηλαδή η χρήση κλειδωμένης μνήμης στον host ώστε να αποφεύγεται μια ενδιάμεση αντιγραφή, δεν προσφέρει ουσιαστικό όφελος στο συγκεκριμένο σύστημα. Οι μετρήσεις των δύο διαδρομών διαφέρουν κατά ποσοστό της τάξης του δύο τοις εκατό, γεγονός που υποδεικνύει ότι ο περιοριστικός παράγοντας είναι ο ίδιος ο δίαυλος και όχι ο τρόπος προετοιμασίας των δεδομένων εκατέρωθέν του.

Ως προς το αποτύπωμα στη μνήμη της συσκευής, οι δύο υλοποιήσεις ακολουθούν τη λογική των αντίστοιχων του επεξεργαστή: η διτονική ταξινόμηση δεσμεύει τους δύο πίνακες μεγέθους n της ενότητας 5.2 και το map-reduce τους σωρούς ανά νήμα της ενότητας 5.3. Για τις μεγάλες τιμές του k , ο χώρος εργασίας των σωρών μπορεί να προσεγγίσει σε μέγεθος την ίδια την είσοδο.

5.5 Υλοποίηση αναφοράς

Το μέτρο σύγκρισης για τη μονάδα γραφικών είναι η συνάρτηση επιλογής top- k της βιβλιοθήκης CUB, η οποία συνοδεύει την εργαλειοθήκη CUDA. Σε αντίθεση με την περίπτωση του επεξεργαστή, όπου η υλοποίηση αναφοράς είναι μονονηματική και η σύγκριση συγκεντρώνει δύο αιτίες, εδώ δεν υπάρχει καμία ασυμμετρία: η βιβλιοθήκη εκτελείται στην ίδια συσκευή, αξιοποιεί την ίδια παραλληλία και μετριέται με τον ίδιο τρόπο. Η σύγκριση είναι επομένως αυστηρή.

Η ενσωμάτωσή της ακολουθεί το πρωτόκολλο δύο κλήσεων που απαιτεί η βιβλιοθήκη. Η πρώτη κλήση δεν εκτελεί υπολογισμό, αλλά δηλώνει πόσος βοηθητικός χώρος απαιτείται, ο οποίος στη συνέχεια δεσμεύεται, και η δεύτερη εκτελεί την επιλογή. Μόνο η δεύτερη περικλείεται από τα συμβάντα που ορίζουν το αλγοριθμικό πεδίο, ενώ η δέσμευση και οι μεταφορές μένουν εκτός, ακριβώς όπως και στις δύο υλοποιήσεις της εργασίας.

Η καταμετρούμενη κίνηση δεδομένων περιορίζεται στην είσοδο και την έξοδο και αναφέρεται ως κάτω φράγμα, διότι τα εσωτερικά περάσματα της βιβλιοθήκης δεν είναι παρατηρήσιμα από τον κώδικα που την καλεί. Το ίδιο ισχύει και για το πλήθος των συγκρίσεων.

Πρέπει να δηλωθεί εξαρχής ότι το μέτρο αυτό είναι ισχυρό. Στη μεγαλύτερη είσοδο που εξετάζεται, η βιβλιοθήκη ολοκληρώνει την επιλογή σε χρόνο που παραμένει σχεδόν σταθερός καθώς το k μεταβάλλεται κατά τέσσερις τάξεις μεγέθους, ενώ οι δύο υλοποιήσεις της εργασίας επιβαρύνονται σημαντικά. Μόνο για το μικρότερο k το map-reduce την προσπερνά οριακά. Η ερμηνεία της διαφοράς δίνεται στην ενότητα 5.6, αφού πρώτα εξηγηθεί ο μηχανισμός στον οποίο οφείλεται.

5.5.1 Επιλογή με βάση την αναπαράσταση στη CUB

Η βιβλιοθήκη [14] δεν χρησιμοποιεί ούτε δίκτυο ταξινόμησης ούτε σωρούς, αλλά την επιλογή με βάση την αναπαράσταση της ενότητας 2.2.4.

Δύο ιδιότητες της μεθόδου εξηγούν την επίδοσή της. Πρώτον, δεν ταξινομεί ποτέ ολόκληρη την είσοδο. Εκτελεί λίγα περάσματα, καθένα από τα οποία είναι μια ακολουθιακή ανάγνωση συνοδευόμενη από μέτρηση συχνοτήτων, δηλαδή ακριβώς το μοτίβο που η αρχιτεκτονική εκτελεί καλύτερα. Δεύτερον, και σημαντικότερον, το πλήθος των περασμάτων καθορίζεται από το πλάτος του τύπου δεδομένων και όχι από το k : η επιλογή οκτώ στοιχείων και η επιλογή εκατόν τριάντα χιλιάδων κοστίζουν ουσιαστικά το ίδιο.

Η ανεξαρτησία αυτή από το k είναι η θεμελιώδης διαφορά από αμφοτέρους τους αλγόριθμους της εργασίας. Η διτονική ταξινόμηση επιβαρύνεται καθώς μεγαλώνει το k , διότι μεγαλώνουν τα ταξινομημένα μπλοκ και, όπως δείχθηκε στην ενότητα 5.2.1, παύουν να χωρούν στο πλακίδιο. Το map-reduce επιβαρύνεται ακόμη περισσότερο, για τον λόγο της ενότητας 5.3.1. Η επιλογή με βάση την αναπαράσταση δεν έχει κανένα αντίστοιχο σημείο κατάρρευσης.

Η μέθοδος δεν είναι πάντως αδιάφορη ως προς τα δεδομένα. Ο ρυθμός με τον οποίο στενεύει η αναζήτηση εξαρτάται από το πόσο ομοιόμορφα κατανέμονται οι τιμές των ψηφίων: όταν πολλά στοιχεία μοιράζονται τα ίδια σημαντικά ψηφία, ο κρίσιμος κάδος παραμένει μεγάλος και απαιτούνται περισσότερα περάσματα. Η εξάρτηση αυτή είναι διαφορετικής φύσης από εκείνη των σωρών, καθώς αφορά την αναπαράσταση των τιμών και όχι τη σειρά εμφάνισής τους, και επανέρχεται στη συζήτηση των τύπων δεδομένων στο κεφάλαιο 7.

5.6 Περιοριστικοί παράγοντες

Στη μονάδα γραφικών οι περιοριστικοί παράγοντες πρέπει να εξεταστούν χωριστά για κάθε πεδίο μέτρησης, διότι δεν είναι οι ίδιοι. Στο πεδίο end-to-end κυριαρχεί ο διάυλος προς τον host, όπως δείχθηκε στην ενότητα 5.4: σχεδόν τα τρία τέταρτα του χρόνου δεν αφορούν καθόλου υπολογισμό. Ό,τι ακολουθεί αφορά επομένως το αλγοριθμικό πεδίο, όπου φαίνονται τα όρια της ίδιας της συσκευής.

Για μικρό k η διτονική ταξινόμηση περιορίζεται σαφώς από τη μνήμη, φτάνοντας τα τρία πέμπτα περίπου του μετρημένου ταβανιού εύρους ζώνης, ενώ αξιοποιεί μόλις το δυόμισι τοις εκατό του υπολογιστικού. Η υλοποίηση αξιοποιεί δηλαδή τη συσκευή αποδοτικά. Το πρόβλημά της δεν είναι ο τρόπος με τον οποίο κινεί τα δεδομένα, αλλά το ότι υποχρεούται να κινήσει επταπλάσιο όγκο.

Η αντιπαράθεση με τη βιβλιοθήκη αναφοράς κάνει τη διάκριση αυτή ποσοτική και είναι το πιο διδακτικό σημείο του κεφαλαίου. Η βιβλιοθήκη αξιοποιεί μόλις το ένα πέμπτο περίπου του ταβανιού εύρους ζώνης, δηλαδή σαφώς λιγότερο από τη διτονική ταξινόμηση, και παρ' όλα αυτά ολοκληρώνει ταχύτερα. Ο λόγος είναι ότι διακινεί απλάσιο όγκο αντί για επταπλάσιο. Ο λόγος των δύο χρόνων που προβλέπεται από τα δύο αυτά ζεύγη μεγεθών συμπίπτει σχεδόν ακριβώς με τον μετρούμενο.

Το συμπέρασμα αξίζει να διατυπωθεί ρητά, καθώς είναι εύκολο να παραβλεφθεί: η εγγύτητα στο ταβάνι μετρά την ποιότητα της υλοποίησης, ενώ ο συνολικός όγκος κίνησης

μετρά την ποιότητα του αλγορίθμου. Μια υλοποίηση μπορεί να αξιοποιεί το υλικό καλύτερα από μια άλλη και να χάνει, αν ο αλγόριθμός της ζητά από το υλικό περισσότερα. Αυτό ακριβώς συμβαίνει εδώ.

Το map-reduce για μικρό k είναι το μόνο σημείο όπου μια υλοποίηση της εργασίας υπερτερεί της βιβλιοθήκης, αν και οριακά. Διαβάζει την είσοδο μία φορά και απορρίπτει σχεδόν τα πάντα, οπότε πλησιάζει το ελάχιστο δυνατό έργο για το πρόβλημα. Η αξιοποίηση του ταβανιού παραμένει μέτρια, γεγονός που υποδεικνύει ότι το περιθώριο εκεί δεν είναι αλγοριθμικό, αλλά αφορά την οργάνωση των προσβάσεων.

Για μεγάλο k η εικόνα αλλάζει ριζικά. Το map-reduce καταρρέει σε βαθμό που η αξιοποίηση αμφοτέρων των ταβανιών γίνεται κλάσμα του ενός τοις εκατό. Όταν μια μέτρηση απέχει τόσο από κάθε ταβάνι, ο περιορισμός δεν είναι ούτε η μνήμη ούτε ο υπολογισμός. Είναι η απουσία εργασίας προς εκτέλεση. Ο λόγος δόθηκε στην ενότητα 5.3.1: στη μεγαλύτερη είσοδο και για το μεγαλύτερο k , μόλις εκατόν είκοσι οκτώ νήματα μπορούν να φιλτράρουν. Ολόκληρη η συσκευή περιμένει ένα κλάσμα του ενός τοις εκατό των πυρήνων της.

Η διτονική ταξινόμηση επιβαρύνεται και αυτή, αλλά πολύ ηπιότερα. Η αξιοποίηση του ταβανιού μνήμης υποχωρεί περίπου στο ένα τρίτο, καθώς η απώλεια της συγχώνευσης στην κοινή μνήμη αυξάνει την κίνηση χωρίς αντίστοιχη αύξηση της χρήσιμης εργασίας. Παραμένει ωστόσο λειτουργική και, για το μεγαλύτερο k , καταλήγει ταχύτερη από το map-reduce κατά δύο τάξεις μεγέθους.

Συνολικά, καμία από τις δύο υλοποιήσεις δεν περιορίζεται από παράγοντα που θα αίρετο με περαιτέρω βελτιστοποίηση του κώδικα. Η διτονική ταξινόμηση θα ωφελούνταν μόνο από μείωση της κίνησης, δηλαδή από διαφορετικό δίκτυο. Το map-reduce θα ωφελούνταν μόνο από διαφορετική αποσύνθεση για μεγάλα k , ώστε η παραλληλία να μην εξαρτάται από τον λόγο n/k . Και στις δύο περιπτώσεις το όριο είναι αλγοριθμικό και όχι υλοποιησιακό.

Κεφάλαιο 6

Υλοποίηση σε NPU

6.1 Σχεδιαστικές επιλογές

Η μονάδα νευρωνικής επεξεργασίας διαφέρει από τις δύο προηγούμενες αρχιτεκτονικές όχι ως προς τον βαθμό, αλλά ως προς το είδος. Δεν πρόκειται για συσκευή στην οποία εκτελείται ένα πρόγραμμα με τη συνήθη έννοια, αλλά για μια διάταξη πλακιδίων που διαμορφώνεται εκ των προτέρων, χωρίς κρυφή μνήμη, χωρίς δυναμική δέσμευση μνήμης και χωρίς δυνατότητα να μεταβάλει τη ροή των δεδομένων της κατά την εκτέλεση.

Το ερώτημα του σχεδιασμού αλλάζει επομένως ριζικά. Στον επεξεργαστή και στη μονάδα γραφικών το ζητούμενο ήταν πώς κατανέμεται ο αλγόριθμος σε νήματα. Εδώ το ζητούμενο είναι ποιο μικρό και σταθερό κομμάτι εργασίας μπορεί να εκτελέσει η διάταξη αποδοτικά, και πώς θα το τροφοδοτεί ο host αδιάκοπα.

6.1.1 Ροή ανάπτυξης με MLIR-AIE

Δεν υπάρχει περιβάλλον προγραμματισμού αντίστοιχο εκείνου της μονάδας γραφικών. Η εργασία στηρίζεται στο πλαίσιο MLIR-AIE [13] και στη διεπαφή IRON [20] που το συνοδεύει. Η ανάπτυξη απαιτεί δύο ξεχωριστά τεχνουργήματα, τα οποία παράγονται από διαφορετικές αλυσίδες εργαλείων και συνενώνονται στο τέλος.

Το πρώτο είναι η περιγραφή της ίδιας της διάταξης: ποια πλακίδια χρησιμοποιούνται, ποια κανάλια δεδομένων τα συνδέουν και με ποιο μοτίβο κινούνται τα δεδομένα από και προς την κύρια μνήμη. Η περιγραφή αυτή συντάσσεται σε μια ειδική γλώσσα ενσωματωμένη στην Python, μεταφράζεται σε ενδιάμεση αναπαράσταση και τελικά σε δυαδικό αρχείο διαμόρφωσης του υλικού. Το δεύτερο είναι ο υπολογιστικός πυρήνας που εκτελεί κάθε πλακίδιο, γραμμένος σε C++ με χρήση των διανυσματικών πρωτογενών της αρχιτεκτονικής και μεταγλωτισμένος χωριστά.

Η συνέπεια που καθορίζει όλα τα υπόλοιπα είναι ότι η διαμόρφωση αυτή είναι σταθερή κατά τη μεταγλώττιση. Η τοπολογία, τα μεγέθη των ενδιάμεσων απομονωτών και το σχήμα μεταφοράς των δεδομένων αποφασίζονται πριν από κάθε εκτέλεση και δεν εξαρτώνται από τις παραμέτρους του προβλήματος. Μεταβολή του k ή του μεγέθους της εισόδου δεν αλλάζει τίποτα στη συσκευή· αλλάζει μόνο τον τρόπο με τον οποίο ο host τεμαχίζει την είσοδο και ερμηνεύει τα αποτελέσματα.


6.1.2 Τοπολογία πλακιδίων και object_fifo

Η διάταξη οργανώνεται σε στήλες. Κάθε στήλη διαθέτει ένα πλακίδιο διασύνδεσης που επικοινωνεί με την κύρια μνήμη και, πάνω από αυτό, υπολογιστικά πλακίδια. Η υλοποίηση της διτονικής ταξινόμησης χρησιμοποιεί τέσσερις στήλες με δύο υπολογιστικά πλακίδια η καθεμία, δηλαδή οκτώ συνολικά.

Η μεταφορά των δεδομένων δεν προγραμματίζεται με ρητές εντολές αντιγραφής, αλλά δηλώνεται ως κανάλι μεταξύ δύο πλακιδίων. Κάθε κανάλι συνοδεύεται από πλήθος ενδιάμεσων απομονωτών, το οποίο εδώ ορίζεται σε δύο· η επιλογή αυτή είναι που επιτρέπει την επικάλυψη: όσο το πλακίδιο επεξεργάζεται τον έναν απομονωτή, ο μηχανισμός άμεσης προσπέλασης μνήμης γεμίζει τον άλλο. Χωρίς αυτήν, κάθε πλακίδιο θα σταματούσε σε κάθε μεταφορά.

Κάθε υπολογιστικό πλακίδιο διαθέτει δικό του ζεύγος καναλιών προς το πλακίδιο διασύνδεσης της στήλης του, ένα για την είσοδο και ένα για την έξοδο. Δεν υπάρχει επικοινωνία μεταξύ υπολογιστικών πλακιδίων, κάτι που δεν αποτελεί έλλειψη της υλοποίησης αλλά συνειδητή επιλογή: όπως θα φανεί στην ενότητα 6.2, η εργασία που ανατίθεται στη διάταξη είναι εξ ορισμού ανεξάρτητη ανά πλακίδιο και δεν απαιτεί καμία ανταλλαγή.

Η συνολική οργάνωση φαίνεται στο σχήμα 6.1. Η ποσότητα δεδομένων που επεξεργάζεται η διάταξη σε μία αποστολή προκύπτει από το γινόμενο των παραπάνω. Κάθε πλακίδιο δέχεται τμήματα των 1024 στοιχείων και επεξεργάζεται 128 τέτοια τμήματα ανά αποστολή, οπότε με οκτώ πλακίδια η παρτίδα ανέρχεται σε ένα εκατομμύριο στοιχεία περίπου. Είσοδοι μεγαλύτερες από αυτό τεμαχίζονται σε διαδοχικές παρτίδες.



Ανά πυρήνα: 128 τεμάχια × 1024 στοιχεία int32. Ανά παρτίδα: $8 \times 128 \times 1024 = 1\,048\,576$ στοιχεία.

Σχήμα 6.1: Η τοπολογία πλακιδίων της υλοποίησης και οι ουρές object_fifo που τα συνδέουν. Κάθε στήλη διαθέτει ένα πλακίδιο διεπαφής (shim) που επικοινωνεί με την κύρια μνήμη και δύο υπολογιστικά πλακίδια, καθένα από τα οποία συνδέεται με το shim της στήλης του μέσω ενός ζεύγους ουρών βάθους δύο: μία για την είσοδο και μία για την έξοδο. Το βάθος δύο επιτρέπει στον πυρήνα να επεξεργάζεται ένα τεμάχιο ενώ το επόμενο μεταφέρεται. Τα πλακίδια μνήμης της ενδιάμεσης σειράς δεν χρησιμοποιούνται, καθώς κάθε πυρήνας καταναλώνει ξένο προς τους υπόλοιπους τμήμα της εισόδου και δεν απαιτείται διαμοιρασμός ή αναδιανομή δεδομένων μεταξύ τους.

6.2 Διτονική ταξινόμηση

Εδώ πρέπει να δηλωθεί εξ αρχής μια ουσιώδης διαφορά από τα δύο προηγούμενα κεφάλαια, η οποία επηρεάζει την ερμηνεία κάθε μέτρησης: η διάταξη δεν εκτελεί το χρονοδιάγραμμα επιπέδων της ενότητας 4.2. Δεν εκτελεί δηλαδή περικομμένη διτονική ταξινόμηση.

Ο λόγος είναι δομικός. Το χρονοδιάγραμμα απαιτεί συγκρίσεις μεταξύ στοιχείων που απέχουν αυθαίρετα μεγάλη απόσταση, άρα ανταλλαγή δεδομένων μεταξύ πλακιδίων και πολλαπλά περάσματα πάνω από ολόκληρη την είσοδο. Η τοπολογία της ενότητας 6.1.2 δεν προσφέρει ούτε το ένα ούτε το άλλο: τα πλακίδια δεν επικοινωνούν μεταξύ τους και κάθε στοιχείο περνά από τη διάταξη μία μόνο φορά.

Η υλοποίηση αναδιατυπώνει επομένως το πρόβλημα. Η διάταξη αναλαμβάνει μια σταθερή και τοπική εργασία: ταξινομεί ανεξάρτητα διαδοχικές ακολουθίες δεκαέξι στοιχείων. Ο host αναλαμβάνει στη συνέχεια την επιλογή, συγχωνεύοντας τις ταξινομημένες αυτές ακολουθίες σε έναν σωρό μεγέθους k .

Η κατανομή αυτή δεν είναι αυθαίρετη. Επειδή κάθε ακολουθία επιστρέφει ταξινομημένη, ο host μπορεί να την εγκαταλείψει μόλις συναντήσει στοιχείο που δεν ξεπερνά τη ρίζα του σωρού: όλα τα επόμενα της ίδιας ακολουθίας είναι κατ' ανάγκην χειρότερα. Η ταξινόμηση που εκτελεί η διάταξη δεν είναι δηλαδή αυτοσκοπός, αλλά μηχανισμός που επιτρέπει στον host να απορρίπτει δεκαέξι στοιχεία τη φορά αντί για ένα.

6.2.1 Πυρήνας υπολογιστικού πλακιδίου

Η διτονική ταξινόμηση σε πλακίδιο AI Engine αποτελεί αντικείμενο και επίσημου παραδείγματος της πλατφόρμας [17], το οποίο όμως εκτελεί πλήρη ταξινόμηση σε ένα μόνο πλακίδιο.

Το μέγεθος των δεκαέξι δεν είναι τυχαίο: είναι ακριβώς το πλήθος των ακεραίων των 32 bit που χωρούν σε έναν διανυσματικό καταχωρητή της αρχιτεκτονικής. Η ταξινόμηση δεκαέξι στοιχείων με διτονικό δίκτυο απαιτεί δέκα βήματα σύγκρισης-ανταλλαγής, και καθένα από αυτά εκτελείται εξ ολοκλήρου εντός του καταχωρητή.

Κάθε βήμα ακολουθεί το ίδιο μοτίβο με εκείνο της ενότητας 4.1.1: μια αναδιάταξη φέρνει κάθε στοιχείο δίπλα στο ταίρι του, υπολογίζονται το ελάχιστο και το μέγιστο, και μια μάσκα επιλέγει ποιο από τα δύο κρατά κάθε θέση ώστε να προκύψει η σωστή κατεύθυνση. Ολόκληρο το δίκτυο εκτελείται χωρίς καμία πρόσβαση στη μνήμη του πλακιδίου: τα δεδομένα φορτώνονται μία φορά, υφίστανται δέκα μετασχηματισμούς σε καταχωρητές και αποθηκεύονται μία φορά.

Κάθε κλήση του πυρήνα επεξεργάζεται ένα τμήμα 1024 στοιχείων, δηλαδή εξήντα τέσσερις ανεξάρτητες ακολουθίες. Οι ακολουθίες αυτές δεν έχουν καμία εξάρτηση μεταξύ τους, γεγονός που επιτρέπει στον μεταγλωττιστή να τις διοχετεύσει και να καλύψει τις καθυστερήσεις των επιμέρους εντολών.

6.2.2 Κλιμάκωση σε πολλαπλά πλακίδια

Επειδή οι ακολουθίες είναι ανεξάρτητες, η κλιμάκωση σε περισσότερα πλακίδια είναι τετριμμένη: αρκεί να δοθεί σε καθένα διαφορετικό τμήμα της παρτίδας. Δεν απαιτείται

ούτε συγχρονισμός ούτε ανταλλαγή δεδομένων, και το μόνο που αλλάζει είναι το μοτίβο μεταφοράς που δηλώνεται στη διαμόρφωση της συσκευής.

Η δυνατότητα αυτή αξιοποιήθηκε. Η υλοποίηση επεκτάθηκε ώστε να χρησιμοποιεί δύο υπολογιστικά πλακίδια ανά στήλη αντί για ένα, φτάνοντας τα οκτώ συνολικά. Η επέκταση απέδωσε αισθητή βελτίωση, γεγονός που επιβεβαίωσε ότι μέχρι εκείνο το σημείο η υλοποίηση περιοριζόταν πράγματι από τον υπολογισμό στη διάταξη.

Το σημαντικότερο όμως αποτέλεσμα της επέκτασης δεν ήταν η βελτίωση αυτή καθαυτή, αλλά το ότι μετακίνησε τον περιοριστικό παράγοντα αλλού. Με οκτώ πλακίδια η διάταξη έπαψε να είναι το στενό σημείο, και όπως ποσοτικοποιείται στην ενότητα 6.4.1, ο χρόνος καταναλώνεται πλέον σχεδόν εξ ολοκλήρου στον host. Περαιτέρω κλιμάκωση σε ακόμη περισσότερα πλακίδια δεν θα είχε κανένα αποτέλεσμα.

6.3 Map-reduce με τοπικούς σωρούς

Ο δεύτερος αλγόριθμος ακολουθεί την ίδια αρχή κατανομής εργασίας, με ακόμη πιο περιορισμένο ρόλο για τη διάταξη. Χρησιμοποιούνται τέσσερα υπολογιστικά πλακίδια, ένα ανά στήλη, και ο πυρήνας δεν ταξινομεί: για κάθε τμήμα της εισόδου υπολογίζει μια σύνοψη, δηλαδή την καλύτερη τιμή που αυτό περιέχει.

Ο host διατηρεί τον σωρό μεγέθους k και χρησιμοποιεί τις συνόψεις ως φίλτρο. Αν η καλύτερη τιμή ενός ολόκληρου τμήματος δεν ξεπερνά τη ρίζα του σωρού, το τμήμα απορρίπτεται στο σύνολό του χωρίς να εξεταστεί κανένα στοιχείο του. Μόνο για τα τμήματα που περνούν το φίλτρο ο host διατρέχει τα επιμέρους στοιχεία.

Το φίλτρο αυτό προϋποθέτει ότι ο σωρός έχει ήδη ένα ρεαλιστικό κατώφλι πριν εξεταστεί το πρώτο τμήμα, κάτι που εδώ δεν προκύπτει αυτόματα όπως στον επεξεργαστή και στη μονάδα γραφικών, όπου ο σωρός αρχικοποιείται μαζικά από τα πρώτα k στοιχεία της εισόδου. Ο host δειγματοληπτει αντ' αυτού εκ των προτέρων ένα τμήμα της εισόδου, ίσο σε μέγεθος με το μεγαλύτερο από το k και το δύο τοις εκατό του n , με ανώτατο όριο το ίδιο το n , και το εισάγει απευθείας στον σωρό πριν αποσταλεί η πρώτη εργασία στη διάταξη. Έτσι το φίλτρο των συνόψεων λειτουργεί αποτελεσματικά από την αρχή, αντί να χρειάζεται να συσσωρευτούν αρκετά τμήματα πρώτα. Για πολύ μικρές εισόδους το δείγμα αυτό μπορεί να καλύψει ολόκληρη την είσοδο, οπότε καμία εργασία δεν αποστέλλεται καν στη διάταξη, όπως σχολιάζεται στην ενότητα 7.2.1.

Η κατανομή ρόλων είναι επομένως η αντίστροφη της διαισθητικής: η διάταξη δεν εκτελεί την επιλογή, αλλά παράγει την πληροφορία που επιτρέπει στον host να την εκτελέσει φθηνά. Το μοτίβο αυτό, όπου το επιταχυνόμενο τμήμα είναι ένα φίλτρο και όχι ο ίδιος ο υπολογισμός, ταιριάζει στη φύση της διάταξης: μια σταθερή, τοπική, πλήρως προβλέψιμη πράξη πάνω σε ροή δεδομένων.

6.4 Διαχείριση μνήμης και κίνηση δεδομένων

Η μονάδα νευρωνικής επεξεργασίας δεν διαθέτει δική της μνήμη, όπως αναφέρθηκε στην ενότητα 3.1. Τα δεδομένα δεν διασχίζουν διάυλο προς ξεχωριστή συσκευή, όπως στη μονάδα γραφικών, αλλά βρίσκονται ήδη στην ίδια φυσική μνήμη με εκείνα του host. Αυτό που ονομάζεται μεταφορά είναι στην πραγματικότητα συγχρονισμός ενός κοινού απομονωτή.

Η διαφορά αυτή φαίνεται αρχικά πλεονέκτημα, και ως προς το κόστος της μεταφοράς είναι: δεν υπάρχει το εικοσαπλάσιο χάσμα εύρους ζώνης της ενότητας 5.4. Έχει όμως και την αντίστροφη όψη: επειδή η μνήμη είναι κοινή, κάθε byte που ετοιμάζει ο host για τη διάταξη καταναλώνει το ίδιο εύρος ζώνης που θα χρησιμοποιούσε ο επεξεργαστής αν εκτελούσε ο ίδιος τον υπολογισμό. Η προετοιμασία δεν είναι δωρεάν, και όπως θα φανεί αμέσως, είναι το κυρίαρχο κόστος.

6.4.1 Διοχέτευση και ρόλος του host

Για να μη μένει η διάταξη αδρανής μεταξύ διαδοχικών παρτίδων, η εκτέλεση οργανώνεται ως διοχέτευση τριών σταδίων με δύο σύνολα απομονωτών που εναλλάσσονται. Όσο η διάταξη επεξεργάζεται μια παρτίδα, ο host προετοιμάζει την επόμενη και συγχωνεύει τα αποτελέσματα της προηγούμενης.


Η δομή της διοχέτευσης δίνεται στο σχήμα 6.2. Η μέτρηση των επιμέρους σταδίων είναι το πιο διαφωτιστικό αποτέλεσμα ολόκληρου του κεφαλαίου. Για είσοδο δεκαέξι εκατομμυρίων ακεραίων, η οποία τεμαχίζεται σε δεκαέξι παρτίδες, ο χρόνος κατανέμεται όπως φαίνεται στον πίνακα 6.1.

Στάδιο	Χρόνος (ms)	Ποσοστό
Προετοιμασία παρτίδας	4,86	61 %
Συγχώνευση αποτελεσμάτων	2,19	27 %
Αναμονή της διάταξης	0,54	7 %
Αποστολή εργασιών	0,11	1 %
Αρχικοποίηση	0,08	1 %
Σύνολο	7,98	100 %

Πίνακας 6.1: Κατανομή του χρόνου της περιοχής εκφόρτωσης ανά στάδιο.

Το συμπέρασμα είναι μονοσήμαντο. Λιγότερο από το ένα δέκατο του χρόνου αναλώνεται σε αναμονή της διάταξης· περίπου το ενενήντα τοις εκατό είναι εργασία που εκτελεί ο ίδιος ο host. Η διοχέτευση αποδίδει όσο το βραδύτερο στάδιό της, και το βραδύτερο στάδιο δεν βρίσκεται στη συσκευή.

Αυτό εξηγεί επίσης γιατί η μέτρηση του αλγοριθμικού πεδίου για τη συγκεκριμένη αρχιτεκτονική δεν πρέπει να διαβάζεται ως χρόνος υπολογισμού των πλακιδίων, όπως σημειώθηκε ήδη στην ενότητα 3.3.2. Το πεδίο περικλείει ολόκληρη τη διαδικασία εκφόρτωσης, της οποίας το μεγαλύτερο μέρος εκτελείται στον επεξεργαστή.



Σχήμα 6.2: Η διοχέτευση τριών σταδίων της εκφόρτωσης. Ενώ τα πλακίδια επεξεργάζονται την παρτίδα b_i , ο host κωδικοποιεί ήδη την b_{i+1} στον δεύτερο buffer και συγχωνεύει τα αποτελέσματα της b_{i-1} . Επειδή τα τρία στάδια επικαλύπτονται, ο συνολικός χρόνος δεν είναι το άθροισμά τους αλλά το γινόμενο του πλήθους των παρτίδων επί τη διάρκεια του πλατύτερου σταδίου. Στη συγκεκριμένη υλοποίηση το στάδιο αυτό είναι η κωδικοποίηση στον host: μόνο αυτό εκτελείται χωρίς διακοπή, ενώ τα υπόλοιπα δύο μένουν αδρανή για μέρος κάθε περιόδου. Καμία περαιτέρω επιτάχυνση του πυρήνα AIE δεν μπορεί επομένως να μειώσει τον συνολικό χρόνο.

6.4.2 Κωδικοποίηση δεδομένων και τύποι

Ο πυρήνας της διάταξης λειτουργεί αποκλειστικά σε ακεραίους των 32 bit. Δεν γνωρίζει, και δεν χρειάζεται να γνωρίζει, τι αναπαριστούν οι τιμές που συγκρίνει. Κάθε τύπος δεδομένων της εργασίας πρέπει επομένως να αντιστοιχιστεί σε ακέραιο κλειδί που διατηρεί τη σχετική διάταξη των τιμών, με τους κανόνες μετατροπής τύπων της πλατφόρμας [21].

Η αντιστοίχιση είναι διαφορετική ανά τύπο. Οι προσημασμένοι ακέραιοι χρησιμοποιούνται αυτούσιοι. Στους απρόσημους αντιστρέφεται το πλεόν σημαντικό bit. Στους αριθμούς κινητής υποδιαστολής απλής ακρίβειας αντιστρέφεται είτε το πρόσημο είτε το σύνολο των υπόλοιπων bit, ανάλογα με το πρόσημο, ώστε η δυαδική σύγκριση να συμπίπτει με την αριθμητική. Η μισή ακρίβεια διευρύνεται πρώτα σε απλή, μετατροπή που είναι ακριβής, και στη συνέχεια ακολουθεί την ίδια διαδρομή.

Το κρίσιμο σημείο είναι ότι η κωδικοποίηση αυτή εκτελείται στον host και αποτελεί μέρος του σταδίου προετοιμασίας του πίνακα 6.1. Το κόστος του τύπου δεδομένων στη συγκεκριμένη αρχιτεκτονική δεν είναι επομένως κόστος της συσκευής, αλλά του επεξεργαστή. Η παρατήρηση αυτή έχει πρακτική συνέπεια: η κωδικοποίηση της μισής ακρίβειας, που αρχικά εκτελούνταν βαθμωτά, αποδείχθηκε αρκετά ακριβή ώστε να επιβαρύνει αισθητά το κυρίαρχο στάδιο, και αντικαταστάθηκε από διανυσματική διαδρομή που μετατρέπει οκτώ τιμές ανά εντολή.

6.4.3 Τελική διόρθωση στον host

Η διπλή ακρίβεια δεν χωρά σε κλειδί των 32 bit. Η κωδικοποίηση διατηρεί τα 32 πλέον σημαντικά bit του πλήρους κλειδιού των 64, οπότε δύο διαφορετικές τιμές μπορούν να αντιστοιχιστούν στο ίδιο κλειδί. Η διάταξη δεν επιστρέφει δηλαδή το ακριβές αποτέλεσμα, αλλά κάτι ασθενέστερο: ένα κατώφλι.

Η ορθότητα αποκαθίσταται με ένα επιπλέον στάδιο στον host. Από τα κλειδιά που επέστρεψε η διάταξη προκύπτει το χειρότερο, το οποίο ορίζει το κατώφλι. Ο host

διατρέχει τότε ξανά ολόκληρη την είσοδο, συλλέγει όσα στοιχεία έχουν κλειδί εντός του κατωφλίου, και εκτελεί ακριβή επιλογή μεταξύ αυτών και μόνο.

Το κόστος είναι ένα πρόσθετο πέρασμα πάνω από την είσοδο, το οποίο επιβαρύνει αποκλειστικά τη διπλή ακρίβεια. Το όφελος είναι ότι το αποτέλεσμα είναι ακριβές και περνά τον ίδιο έλεγχο ορθότητας με όλους τους άλλους τύπους, χωρίς χαλάρωση του κριτηρίου. Η εναλλακτική, δηλαδή η αποδοχή προσεγγιστικού αποτελέσματος για έναν μόνο τύπο, θα καθιστούσε τη σύγκριση μεταξύ τύπων άνιση.

6.5 Υλοποίηση αναφοράς

Το μέτρο σύγκρισης είναι η ίδια συνάρτηση της πρότυπης βιβλιοθήκης που χρησιμοποιείται και για τον επεξεργαστή, εκτελούμενη εξ ολοκλήρου στον host. Οι λόγοι της επιλογής, καθώς και το τι σημαίνει για την ερμηνεία των αποτελεσμάτων, αναλύθηκαν στην ενότητα 3.5 και δεν επαναλαμβάνονται εδώ.

Αξίζει μόνο να υπενθυμιστεί το ουσιώδες: δεν υπάρχει υλοποίηση top-k για την ίδια τη διάταξη με την οποία θα μπορούσε να συγκριθεί η παρούσα εργασία. Το ερώτημα στο οποίο απαντά η σύγκριση δεν είναι επομένως αν η υλοποίηση είναι καλύτερη από έναν βελτιστοποιημένο πυρήνα ΑΙΕ, αλλά αν αξίζει καθόλου να μεταφερθεί ο υπολογισμός στη μονάδα αντί να εκτελεστεί με τα μέσα που ήδη διαθέτει ο host.

6.6 Περιοριστικοί παράγοντες

Ο περιοριστικός παράγοντας έχει ήδη προσδιοριστεί ποσοτικά στον πίνακα 6.1 και δεν αφήνει περιθώριο ερμηνείας: η υλοποίηση περιορίζεται από τον host και όχι από τη συσκευή. Το ερώτημα που απομένει είναι γιατί η εργασία του host είναι τόσο ακριβή.

Το στάδιο της προετοιμασίας, που καταναλώνει τα τρία πέμπτα του χρόνου, περιλαμβάνει ένα πλήρες πέρασμα ανάγνωσης πάνω από την είσοδο, τη μετατροπή κάθε στοιχείου σε ακέραιο κλειδί και μια εγγραφή ισόποσου όγκου στον κοινό απομονωτή. Πρόκειται δηλαδή για κίνηση δεδομένων τουλάχιστον διπλάσια του μεγέθους της εισόδου, πάνω στην ίδια μνήμη και με το ίδιο εύρος ζώνης που θα χρησιμοποιούσε ο επεξεργαστής. Το στάδιο της συγχώνευσης προσθέτει ακόμη ένα πέρασμα ανάγνωσης πάνω από τα αποτελέσματα.

Από τη διαπίστωση αυτή προκύπτει το κεντρικό συμπέρασμα του κεφαλαίου. Ακόμη και αν η διάταξη ολοκληρώνει τη δική της εργασία ακαριαία, ο συνολικός χρόνος θα μειωνόταν κατά λιγότερο από ένα δέκατο. Η επιτάχυνση δεν μπορεί να προέλθει από τη συσκευή, διότι η συσκευή δεν είναι εκεί που δαπανάται ο χρόνος. Καμία προσθήκη υπολογιστικών πλακιδίων, καμία βελτιστοποίηση του πυρήνα και καμία αύξηση της συχνότητας δεν θα άλλαζε ουσιωδώς το αποτέλεσμα.

Η σύγκριση με τον επεξεργαστή κάνει το επιχείρημα οξύτερο. Ο host που τροφοδοτεί τη μονάδα είναι ο ίδιος επεξεργαστής που, στο κεφάλαιο 4, επιλύει ολόκληρο το πρόβλημα μόνος του. Του ζητείται εδώ να εκτελέσει σχεδόν την ίδια ποσότητα κίνησης δεδομένων απλώς για να προετοιμάσει τα δεδομένα για κάποιον άλλον. Δεν προκαλεί επομένως έκπληξη ότι η εκφόρτωση δεν αποδίδει: το κόστος της προετοιμασίας είναι συγκρίσιμο με το κόστος της ίδιας της λύσης.

Πρέπει τέλος να τονιστεί ότι το συμπέρασμα αφορά το συγκεκριμένο πρόβλημα και όχι την αρχιτεκτονική εν γένει. Η επιλογή top-k έχει ελάχιστη υπολογιστική ένταση: εκτελεί μία σύγκριση ανά στοιχείο και δεν επαναχρησιμοποιεί σχεδόν τίποτα. Μια διάταξη ροής δεδομένων αποδίδει όταν κάθε στοιχείο που εισέρχεται σε αυτήν υφίσταται πολλές πράξεις, ώστε το κόστος της τροφοδοσίας να αποσβένεται. Εδώ συμβαίνει το αντίθετο, και η αναντιστοιχία αυτή, όχι κάποια αδυναμία της υλοποίησης, είναι η ουσιαστική αιτία.

Κεφάλαιο 7

Αποτελέσματα και αξιολόγηση

Το κεφάλαιο αυτό παρουσιάζει τα αποτελέσματα των μετρήσεων και τα ερμηνεύει με βάση τους μηχανισμούς που περιγράφηκαν στα τρία προηγούμενα κεφάλαια. Όπου δεν δηλώνεται διαφορετικά, τα διαγράμματα αφορούν ακεραίους των 32 bit και ομοιόμορφη κατανομή εισόδου. Η επίδραση του τύπου δεδομένων και της κατανομής εξετάζεται χωριστά στις ενότητες 7.6 και 7.7.


7.1 Ορθότητα

Προϋπόθεση για κάθε σύγκριση χρόνου είναι η ορθότητα του αποτελέσματος. Η κύρια σάρωση περιλαμβάνει 2700 περιπτώσεις, οι οποίες καλύπτουν και τις τρεις αρχιτεκτονικές, τους τρεις αλγόριθμους, τους πέντε τύπους δεδομένων, μεγέθη εισόδου από 2^3 έως 2^{24} και τις τέσσερις τιμές του k . Όλες επαληθεύτηκαν ως προς την υλοποίηση επαλήθευσης της ενότητας 3.6 και όλες πέτυχαν: ποσοστό επιτυχίας 100% για κάθε αρχιτεκτονική και αλγόριθμο, χωρίς καμία εξαίρεση.

Το αποτέλεσμα αυτό σημαίνει ότι κάθε χρόνος που παρουσιάζεται στη συνέχεια αντιστοιχεί σε υλοποίηση που παρήγαγε το σωστό σύνολο των k στοιχείων και ότι οι συγκρίσεις που ακολουθούν αφορούν πράγματι τον ίδιο υπολογισμό.

7.2 Χρόνος εκτέλεσης

7.2.1 Εξάρτηση από το μέγεθος εισόδου



Σχήμα 7.1: Χρόνος συναρτήσεως του μεγέθους εισόδου, για k ίσο με 8, στα δύο πεδία μέτρησης. Η κατάταξη των αρχιτεκτονικών ανατρέπεται πλήρως μεταξύ των δύο.


Στο αριστερό σχήμα, που αφορά το αλγοριθμικό πεδίο, η μονάδα γραφικών είναι ταχύτερη στη μικρότερη είσοδο, ολοκληρώνοντας σε 0.010 ms έναντι 0.022 ms του επεξεργαστή, και πάλι στη μεγαλύτερη, σε 0.43 ms έναντι 1.23 ms· σχεδόν σε ολόκληρη την ενδιαμέση περιοχή όμως ο επεξεργαστής είναι ο ταχύτερος από τους δύο. Το ακριβές μέγεθος στο οποίο οι δύο εναλλάσσουν θέσεις είναι από μόνο του ασταθές μεταξύ επαναλαμβανόμενων εκτελέσεων της ίδιας σάρωσης: σε αυτούς τους μικρούς απόλυτους χρόνους, αμφότερες οι αρχιτεκτονικές βρίσκονται αρκετά κοντά στην ανάλυση του χρονόμετρου ώστε η κατάταξη εκεί να αντικατοπτρίζει θόρυβο μέτρησης και όχι σταθερή αρχιτεκτονική διαφορά.

Η μονάδα νευρωνικής επεξεργασίας εμφανίζει σαφές κατώφλι στα μικρά μεγέθη. Οι καμπύλες της παραμένουν εντελώς επίπεδες γύρω στο μισό χιλιοστό του δευτερολέπτου μέχρι περίπου 2¹⁶ στοιχεία: σε όλη αυτή την περιοχή ο χρόνος δεν εξαρτάται καθόλου από το μέγεθος της εισόδου, διότι κυριαρχείται από το σταθερό κόστος αποστολής και αναμονής. Ο επεξεργαστής παρουσιάζει ανάλογο, αλλά πολύ χαμηλότερο κατώφλι, της τάξης των πέντε εκατοστών του χιλιοστού.

Ένα σημείο ωστόσο ξεχωρίζει από αυτή την εικόνα: στο μικρότερο μέγεθος εισόδου, όπου n και k ταυτίζονται, το map-reduce της μονάδας νευρωνικής επεξεργασίας εμφανίζει χρόνο αισθητά κάτω από το κατώφλι που μόλις περιγράφηκε. Ο λόγος βρίσκεται στη δειγματοληψία της ενότητας 6.3: όταν n=k=8, το δείγμα που τροφοδοτεί τον σωρό καλύπτει ολόκληρη την είσοδο, οπότε καμία εργασία δεν αποστέλλεται ποτέ στα πλακίδια. Το σημείο αυτό μετρά επομένως αποκλειστικά την πλευρά του host και δεν αντιπροσωπεύει πραγματική συμμετοχή της διάταξης.

Η εικόνα αυτή όμως ανατρέπεται πλήρως στο δεξιό σχήμα, όταν η μέτρηση περιλαμβάνει και τη μεταφορά των δεδομένων. Στο πεδίο end-to-end ο επεξεργαστής είναι ταχύτερος από κάθε άλλη αρχιτεκτονική σε *όλα* τα μεγέθη που εξετάστηκαν, συμπεριλαμβανομένου του μεγαλύτερου: τα 0.43 ms του πυρήνα της μονάδας γραφικών γίνονται 5.69 ms συνολικά, ενώ ο επεξεργαστής παραμένει στα 1.23 ms, καθώς για αυτόν τα δύο πεδία ταυτίζονται.

Το αλγοριθμικό πεδίο μετρά πόσο καλά εκτελεί η κάθε συσκευή τον υπολογισμό· το συνολικό μετρά αν αξίζει να της ανατεθεί. Οι δύο απαντήσεις δεν συμπίπτουν, και η ενότητα 7.5 δείχνει ότι η δεύτερη είναι εκείνη που καθορίζει και την ενεργειακή εικόνα. Η μονάδα νευρωνικής επεξεργασίας απαιτεί 9.97 ms στη μεγαλύτερη είσοδο, περισσότερο από κάθε άλλη αρχιτεκτονική και στα δύο πεδία, για τους λόγους της ενότητας 6.6.




Σχήμα 7.2: Κάθε αλγόριθμος στις τρεις αρχιτεκτονικές, για k ίσο με 8.

Η σύγκριση της ίδιας διτονικής ταξινόμησης στις τρεις αρχιτεκτονικές είναι διαφωτιστική, διότι εκτελείται το ίδιο χρονοδιάγραμμα επιπέδων και η διαφορά οφείλεται αποκλειστικά στην υλοποίηση. Οι δύο αρχιτεκτονικές γενικού σκοπού εναλλάσσουν θέσεις κατά μήκος του εύρους: ο επεξεργαστής είναι ταχύτερος από τη μονάδα γραφικών στο μεγαλύτερο μέρος των μικρών έως μεσαίων μεγεθών, και η μονάδα γραφικών προηγείται μόνο στα μεγαλύτερα μεγέθη, φτάνοντας παράγοντα έξι στο μεγαλύτερο μέγεθος που εξετάστηκε, συνεπές με τη διαφορά του διαθέσιμου εύρους ζώνης. Όπως και στην παραπάνω σύγκριση, το ακριβές μέγεθος στο οποίο οι δύο εναλλάσσουν θέσεις μετακινείται μεταξύ επαναλαμβανόμενων εκτελέσεων της ίδιας σάρωσης και δεν πρέπει να διαβάζεται ως σταθερό όριο. Η μονάδα νευρωνικής επεξεργασίας βρίσκεται κοντά στον επεξεργαστή σε αυτά τα μεγαλύτερα μεγέθη, κάτι που είναι συνεπές με το εύρημα ότι ο χρόνος της δαπανάται σχεδόν εξ ολοκλήρου στον host.

Το map-reduce δεν επιδέχεται καταρχήν την ίδια σύγκριση, καθώς κάθε αρχιτεκτονική διατηρεί και συγχωνεύει τους τοπικούς σωρούς της με θεμελιωδώς διαφορετικό τρόπο (κεφάλαια 4 έως 6): το δεξί σχήμα δείχνει αν' αυτού πόσο διαφορετικά εκδιπλώνεται η ίδια αλγοριθμική ιδέα όταν υλοποιηθεί τρεις φορές. Η μονάδα γραφικών είναι η ταχύτερη των τριών σχεδόν σε ολόκληρο το εύρος, με τον επεξεργαστή να ακολουθεί σε περίπου σταθερή απόσταση, εκτός από τα μικρά μεγέθη όπου ισχύει η ίδια επιφύλαξη περί θορύβου μέτρησης όπως παραπάνω· στη μεγαλύτερη είσοδο η μονάδα γραφικών παραμένει η ταχύτερη, όπως και παραπάνω, χωρίς όμως την ενδιάμεση εναλλαγή θέσεων που εμφανίζει η διτονική ταξινόμηση. Η μονάδα νευρωνικής επεξεργασίας, σε έντονη αντίθεση με τη συμπεριφορά της στη διτονική ταξινόμηση, δεν βρίσκεται εδώ κοντά στον επεξεργαστή: παραμένει περίπου τάξη μεγέθους βραδύτερη και από τις δύο αρχιτεκτονικές σε κάθε μέγεθος, φτάνοντας τον ήδη αναφερθέντα χρόνο της στη μεγαλύτερη είσοδο. Ο λόγος προκύπτει από την ενότητα 6.6: ο ρόλος της διάταξης στο map-reduce είναι μόνο ένα φίλτρο ανά τμήμα και όχι κοινό χρονοδιάγραμμα δικτύου, οπότε καμία από την ομοιότητα δομής που κρατά την καμπύλη της διτονικής ταξινόμησης κοντά στον επεξεργαστή δεν μεταφέρεται σε αυτόν τον αλγόριθμο.

7.2.2 Εξάρτηση από την παράμετρο k

Η εξάρτηση από το k είναι το σημείο όπου η κατάταξη των αλγορίθμων ανατρέπεται, και αποτελεί ίσως το σημαντικότερο εύρημα της εργασίας.



Σχήμα 7.3: Χρόνος συναρτήσεως του μεγέθους εισόδου, με χωριστή καμπύλη ανά τιμή του k. Οι καμπύλες της διτονικής ταξινόμησης παραμένουν κοντά μεταξύ τους, ενώ εκείνες του map-reduce αποκλίνουν κατά τάξεις μεγέθους.

Η αντιπαράθεση του σχήματος 7.3 αποτυπώνει το φαινόμενο άμεσα. Για τη διτονική ταξινόμηση οι καμπύλες των τεσσάρων τιμών του k σχεδόν ταυτίζονται, καθώς το k επηρεάζει μόνο το μέγεθος των ταξινομημένων μπλοκ. Για το map-reduce στη μονάδα γραφικών οι ίδιες καμπύλες απέχουν μεταξύ τους τρεις τάξεις μεγέθους.

	k=8		k=131072	
Υλοποίηση	ms	θέση	ms	θέση
CPU διτονική	8,01	4	43,33	2
CPU map-reduce	1,23	2	60,37	5
GPU διτονική	1,34	3	8,22	1
GPU map-reduce	0,43	1	1191,37	6
NPU διτονική	8,17	5	56,70	3
NPU map-reduce	9,97	6	59,69	4


Πίνακας 7.1: Αλγοριθμικός χρόνος για τα δύο άκρα του k, σε είσοδο 2^{24} στοιχείων. Η κατάταξη αφορά τις έξι υλοποιήσεις της εργασίας και δεν περιλαμβάνει τις υλοποιήσεις αναφοράς.

Η ταχύτερη υλοποίηση για μικρό k γίνεται η βραδύτερη για μεγάλο, με διαφορά τριών τάξεων μεγέθους. Το map-reduce στη μονάδα γραφικών επιβραδύνεται κατά παράγοντα 2800 μεταξύ των δύο άκρων, ενώ η διτονική ταξινόμηση στην ίδια αρχιτεκτονική μόλις κατά έξι. Για μικρό k οι δύο υλοποιήσεις του επεξεργαστή κατατάσσονται πλέον υψηλότερα σε σχέση με τη θέση τους στο μεγάλο k, με το map-reduce να προσπερνά τη διτονική της μονάδας γραφικών και τη διτονική να προσπερνά εκείνη της μονάδας νευρωνικής επεξεργασίας, όμως η ίδια η ανατροπή παραμένει ανεπηρέαστη: η φθηνότερη υλοποίηση για k ίσο με 8 δεν είναι ποτέ η φθηνότερη για k ίσο με 131072.

Η ανατροπή αυτή δεν είναι ιδιαιτερότητα της παρούσας υλοποίησης. Ανεξάρτητες μελέτες σε μονάδες γραφικών δύο διαφορετικών κατασκευαστών καταγράφουν την ίδια

εξάρτηση από το k και την αντιμετωπίζουν με προσαρμοστική εναλλαγή αλγορίθμου [3, 15]: η αύξηση του χρόνου των μεθόδων μερικής ταξινόμησης με το k αποδίδεται εκεί ρητά στην πολυπλοκότητα $O(\log^2 k)$ του υποκείμενου διτονικού δικτύου.


Η αιτία δόθηκε στην ενότητα 5.3.1: ο σωρός φιλτράρει μόνο αφού γεμίσει, οπότε το πλήθος των νημάτων που συνεισφέρουν περιορίζεται στον λόγο n/k . Για τα μεγέθη του πίνακα 7.1 ο λόγος αυτός είναι 128, δηλαδή η συσκευή απασχολεί ουσιαστικά εκατόν είκοσι οκτώ νήματα από τα χιλιάδες που διαθέτει. Ο επεξεργαστής, με μόλις οκτώ νήματα, δεν προσκρούει ποτέ στο ίδιο όριο και για τον λόγο αυτό η επιβράδυνσή του είναι σαφώς ηπιότερη.




Σχήμα 7.4: Οι τρεις αλγόριθμοι στη μονάδα γραφικών για k ίσο με 131072.

Το πρακτικό συμπέρασμα είναι ότι δεν υπάρχει καθολικά προτιμότερος αλγόριθμος. Η επιλογή μεταξύ δικτύου ταξινόμησης και επιλογής με σωρό εξαρτάται από τον λόγο n/k και όχι από την αρχιτεκτονική.


7.3 Σύγκριση αρχιτεκτονικών




(α) CPU, k=8.




(β) CPU, k=131072.




(γ) GPU, k=8.



(δ) GPU, k=131072.



(ε) NPU, k=8.



(ς) NPU, k=131072.

Σχήμα 7.5: Επιτάχυνση έναντι της υλοποίησης αναφοράς της ίδιας αρχιτεκτονικής. Αριστερή στήλη k ίσο με 8, δεξιά στήλη k ίσο με 131072, μία γραμμή ανά αρχιτεκτονική. Τιμές πάνω από τη μονάδα σημαίνουν ότι η υλοποίηση της εργασίας είναι ταχύτερη από τη βιβλιοθήκη.

Η σύγκριση κάθε υλοποίησης με το μέτρο σύγκρισης της ίδιας αρχιτεκτονικής δίνει την πιο ειλικρινή εικόνα, διότι εξουδετερώνει τις διαφορές του υλικού.

Στον επεξεργαστή, το map-reduce είναι ταχύτερο της βιβλιοθήκης κατά παράγοντα τρία για μικρό k. Πρέπει όμως να υπενθυμιστεί ο περιορισμός της ενότητας 4.5: η βιβλιοθήκη είναι μονονηματική ενώ η υλοποίηση χρησιμοποιεί οκτώ νήματα, οπότε ο παράγοντας αυτός δεν είναι καθαρά αλγοριθμικός.

Η μεγαλύτερη επιτάχυνση ολόκληρου του σχήματος εμφανίζεται ωστόσο αλλού, και είναι συνέπεια της ανατροπής της ενότητας 7.2.2. Για το μεγάλο k, όπου η επιλογή


με σωρό καταρρέει, η διτονική ταξινόμηση στον επεξεργαστή φτάνει να είναι περίπου έξι φορές ταχύτερη από τη βιβλιοθήκη. Ο λόγος είναι ότι η βιβλιοθήκη στηρίζεται και αυτή σε σωρό μεγέθους k και υφίσταται την ίδια επιβάρυνση, ενώ το δίκτυο ταξινόμησης παραμένει εν πολλοίς ανεπηρέαστο. Το πλεονέκτημα εξασθενεί καθώς η είσοδος μεγαλώνει περαιτέρω και η κίνηση δεδομένων του δικτύου αρχίζει να κυριαρχεί, περιοριζόμενο σε λίγο πάνω από τη μονάδα στη μεγαλύτερη είσοδο.

Στη μονάδα γραφικών η σύγκριση είναι αυστηρή, καθώς η βιβλιοθήκη εκτελείται στην ίδια συσκευή με την ίδια παραλληλία. Εκεί το map-reduce υπερτερεί οριακά για k ίσο με 8, ενώ για μεγάλο k η βιβλιοθήκη είναι ταχύτερη κατά περισσότερο από χίλιες φορές. Η επιλογή με βάση την αναπαράσταση δεν έχει σημείο κατάρρευσης ως προς το k , όπως εξηγήθηκε στην ενότητα 5.5.1.


Στη μονάδα νευρωνικής επεξεργασίας, για τους ακέραιους τύπους στους οποίους αναφέρεται το σχήμα, καμία υλοποίηση δεν ξεπερνά τη βιβλιοθήκη σε καμία περιοχή παραμέτρων. Το αποτέλεσμα είναι αναμενόμενο και όχι απογοητευτικό: όπως δείχθηκε στην ενότητα 6.6, ο ίδιος επεξεργαστής που θα εκτελούσε τη βιβλιοθήκη καταναλώνεται ούτως ή άλλως στην προετοιμασία των δεδομένων για τη μονάδα.

Ο περιορισμός «για τους ακέραιους τύπους» δεν είναι διατύπωση ασφαλείας. Για τους τύπους κινητής υποδιαστολής, και ιδίως για τη μισή ακρίβεια, η εικόνα ανατρέπεται και η μονάδα νευρωνικής επεξεργασίας πράγματι ξεπερνά τη βιβλιοθήκη· η εξήγηση δίνεται στην ενότητα 7.6, αφού πρώτα παρουσιαστεί η συμπεριφορά των τύπων.

7.4 Ανάλυση με το μοντέλο roofline



(α') k ίσο με 8.



(β) k ίσο με 131072.

Σχήμα 7.6: Τοποθέτηση των εκτελέσεων απέναντι στα μετρημένα ταβάνια, για τη μεγαλύτερη είσοδο. Περιορίζεται στο μέγιστο μέγεθος, όπου το σύνολο εργασίας ξεπερνά την κρυφή μνήμη και το ταβάνι της κύριας μνήμης είναι το σχετικό.


Το διάγραμμα τοποθετεί κάθε εκτέλεση στο επίπεδο υπολογιστικής έντασης και επιτευχθέντος ρυθμού. Όλες οι υλοποιήσεις συγκεντρώνονται στο αριστερό τμήμα, δηλαδή σε πολύ χαμηλή υπολογιστική ένταση, και καμία δεν πλησιάζει το οριζόντιο τμήμα της στέγης. Καμία υλοποίηση της εργασίας, σε καμία αρχιτεκτονική, δεν περιορίζεται από την υπολογιστική ικανότητα. Το εύρημα συμφωνεί με ανεξάρτητη μέτρηση σε επιταχυντές κέντρου δεδομένων, όπου ο ταχύτερος γνωστός πυρήνας επιλογής αξιοποιεί πάνω από το ενενήντα τοις εκατό του διαθέσιμου εύρους ζώνης έναντι περίπου του μισού της

υπολογιστικής ικανότητας, και όπου ο χρόνος κλιμακώνεται με το εύρος ζώνης της κάθε συσκευής [3].

Η αντιπαράθεση των δύο τιμών του k προσθέτει δύο παρατηρήσεις. Και στις δύο περιπτώσεις η διτονική ταξινόμηση στη μονάδα γραφικών βρίσκεται πρακτικά πάνω στο κεκλιμένο τμήμα της δικής της στέγης, κάτι που επιβεβαιώνει οπτικά το εύρημα της ενότητας 5.6: η υλοποίηση αξιοποιεί το διαθέσιμο εύρος ζώνης σχεδόν πλήρως και περιορίζεται αποκλειστικά από τον όγκο που υποχρεούται να διακινήσει.

Η δεύτερη παρατήρηση αφορά το map-reduce της ίδιας αρχιτεκτονικής. Για k ίσο με 8 βρίσκεται κοντά στα υπόλοιπα σημεία, ενώ για τη μεγάλη τιμή καταρρέει κατά τρεις τάξεις μεγέθους και απομακρύνεται εξίσου από αμφότερα τα ταβάνια. Η θέση αυτή, μακριά τόσο από το κεκλιμένο όσο και από το οριζόντιο τμήμα, είναι η υπογραφή ενός περιορισμού που δεν είναι ούτε η μνήμη ούτε ο υπολογισμός, και αντιστοιχεί στην κατάρρευση της παραλληλίας της ενότητας 5.3.1.


Το εύρημα αυτό είναι δομικό και όχι συγκυριακό. Η επιλογή top- k εκτελεί ουσιαστικά μία σύγκριση ανά στοιχείο και δεν επαναχρησιμοποιεί σχεδόν τίποτα, οπότε η υπολογιστική της ένταση είναι χαμηλή εξ ορισμού.




Σχήμα 7.7: Μετρημένο εύρος ζώνης ανάγνωσης συναρτήσει του μεγέθους του συνόλου εργασίας, για τις τρεις αρχιτεκτονικές.

Το ταβάνι με το οποίο συγκρίνεται κάθε εκτέλεση δεν είναι σταθερό αλλά συνάρτηση του συνόλου εργασίας της, σύμφωνα με την ενότητα 3.4. Το σχήμα 7.7 δείχνει τη μετρημένη κλίμακα: τα σκαλοπάτια αντιστοιχούν στις βαθμίδες της ιεραρχίας μνήμης, και η πτώση προς το δεξιό άκρο σηματοδοτεί το σημείο όπου το σύνολο εργασίας παύει να χωρά στην τελευταία βαθμίδα.


7.4.1 Αξιοποίηση εύρους ζώνης μνήμης



(α) CPU.



(β) GPU.



(γ) NPU.


Σχήμα 7.8: Επιτευχθέν εύρος ζώνης συναρτήσεως του μεγέθους εισόδου, μία αρχιτεκτονική ανά σχήμα, με το μετρημένο ταβάνι της σχεδιασμένο με διακεκομμένη γραμμή. Η απόσταση κάθε καμπύλης από τη διακεκομμένη είναι το αναξιοποίητο περιθώριο.

Η αξιοποίηση του ταβανιού μνήμης αυξάνεται με το μέγεθος της εισόδου και σταθεροποιείται όταν το σύνολο εργασίας ξεπεράσει την κρυφή μνήμη. Στη μεγαλύτερη είσοδο, η διτονική ταξινόμηση στον επεξεργαστή φτάνει περίπου τα τέσσερα πέμπτα του ταβα-

νιού, αισθητά μπροστά από τα τρία πέμπτα της μονάδας γραφικών, ενώ η αξιοποίηση του υπολογιστικού ταβανιού παραμένει κάτω του πέντε τοις εκατό και στις δύο.

Η αντιπαράθεση της διτονικής ταξινόμησης με τη βιβλιοθήκη στη μονάδα γραφικών αξίζει ιδιαίτερη προσοχή, διότι δείχνει ότι η εγγύτητα στο ταβάνι δεν ισοδυναμεί με ταχύτητα. Η διτονική ταξινόμηση αξιοποιεί σαφώς μεγαλύτερο ποσοστό του διαθέσιμου εύρους ζώνης από τη βιβλιοθήκη, και παρ' όλα αυτά είναι βραδύτερη, επειδή διακινεί επταπλάσιο όγκο δεδομένων. Η αξιοποίηση μετρά την ποιότητα της υλοποίησης· ο συνολικός όγκος μετρά την ποιότητα του αλγορίθμου.

7.5 Ενεργειακή αποτίμηση



Σχήμα 7.9: Αλγοριθμικός και συνολικός χρόνος στη μονάδα γραφικών, για κ ίσο με 8. Η απόσταση των δύο καμπυλών κάθε αλγορίθμου είναι το κόστος των μεταφορών και της έναρξης των πυρήνων.


Πριν από την παρουσίαση των ενεργειακών μετρήσεων είναι χρήσιμο το σχήμα 7.9, το οποίο δείχνει γιατί τα δύο πεδία μέτρησης αποκλίνουν τόσο στη μονάδα γραφικών. Η καμπύλη του συνολικού χρόνου παραμένει σταθερή κοντά στα τρία δέκατα του χιλιοστού του δευτερολέπτου μέχρι περίπου 2^{16} στοιχεία: σε όλη αυτή την περιοχή ο πυρήνας είναι ουσιαστικά αόρατος και ο χρόνος αναλώνεται εξ ολοκλήρου σε μεταφορές και εκκινήσεις. Ακόμη και στη μεγαλύτερη είσοδο, ο συνολικός χρόνος παραμένει πολλαπλάσιος του αλγοριθμικού, από περίπου πέντε φορές για τη διτονική ταξινόμηση έως δεκατρείς για το map-reduce.

Η ενεργειακή εικόνα διαφέρει ουσιαστικά από την εικόνα των χρόνων, και η διαφορά οφείλεται στο συμμετρικό πεδίο μέτρησης της ενότητας 3.3.1: κάθε αρχιτεκτονική χρεώνεται το συνολικό κόστος επίλυσης, συμπεριλαμβανομένου του host.

Στη μεγαλύτερη είσοδο και για μικρό k, το map-reduce στον επεξεργαστή καταναλώνει περίπου 19 mJ ανά εκτέλεση και είναι η οικονομικότερη υλοποίηση. Οι αντίστοιχες

υλοποιήσεις στη μονάδα γραφικών καταναλώνουν από 108 mJ έως 128 mJ, δηλαδή έως επτά φορές περισσότερο, παρότι είναι ταχύτερες στο αλγοριθμικό πεδίο. Η ακριβότερη υλοποίηση όλων είναι η διτονική ταξινόμηση στη μονάδα γραφικών, ενώ η αντίστοιχη στον επεξεργαστή κοστίζει 118 mJ.

Η φαινομενική αντίφαση εξηγείται από την ενότητα 5.4. Το αλγοριθμικό πεδίο της μονάδας γραφικών περιλαμβάνει μόνο τον πυρήνα, ενώ το συνολικό περιλαμβάνει τις μεταφορές, οι οποίες καταναλώνουν χρόνο και ισχύ και από τις δύο πλευρές του διαύλου. Μια συσκευή που είναι τέσσερις φορές ταχύτερη στον πυρήνα, αλλά χρειάζεται δύο φορές τον χρόνο του πυρήνα μόνο για να λάβει τα δεδομένα, και καταναλώνει ταυτόχρονα ισχύ πλακέτας, δεν είναι οικονομικότερη.




Σχήμα 7.10: Καθαρή ενέργεια και ισχύς ανά αρχιτεκτονική και αλγόριθμο, για k ίσο με 8.

Η αντιπαράθεση των σχημάτων 7.10α' και 7.10β' αναδεικνύει μια διάκριση που είναι εύκολο να συγχέεται, και η οποία αφορά ιδιαίτερα τη μονάδα νευρωνικής επεξεργασίας. Η μονάδα αυτή έχει τη *χαμηλότερη* κατανάλωση ισχύος από όλες τις υλοποιήσεις, με το map-reduce να μετριέται στα 7.9 W έναντι 15.6 W του αντίστοιχου στον επεξεργαστή και 18.6 W της μονάδας γραφικών.

Παρ' όλα αυτά καταναλώνει πάνω από τετραπλάσια ενέργεια από το map-reduce του επεξεργαστή, 0.080 J έναντι 0.019 J. Ο λόγος είναι ότι η ενέργεια είναι το γινόμενο της ισχύος επί τον χρόνο, και η μονάδα χρειάζεται περίπου οκταπλάσιο χρόνο για την ίδια εργασία. Το πλεονέκτημα του σαράντα εννέα τοις εκατό στην ισχύ εξανεμίζεται από το μειονέκτημα του οκταπλασίου στη διάρκεια.

Η παρατήρηση αυτή γενικεύεται: χαμηλή ισχύς δεν συνεπάγεται χαμηλή ενέργεια. Η αρχή ότι η μετακίνηση των δεδομένων κοστίζει ενεργειακά περισσότερο από τον ίδιο τον υπολογισμό [10] ισχύει και εδώ· εκείνο που λείπει είναι η επαναχρησιμοποίηση που θα την απόσβενε. Μια αρχιτεκτονική χαμηλής κατανάλωσης αποδίδει ενεργειακά μόνο αν ολοκληρώνει την εργασία σε συγκρίσιμο χρόνο, και για το συγκεκριμένο πρόβλημα αυτό δεν συμβαίνει.



Σχήμα 7.11: Συνολικός χρόνος και συνολική ενέργεια κάθε μετρημένης περίπτωσης. Και τα δύο μεγέθη ελαχιστοποιούνται, οπότε οι προτιμότερες περιπτώσεις βρίσκονται προς την κάτω αριστερή γωνία.


Το σχήμα 7.11 τοποθετεί κάθε μετρημένη περίπτωση σε επίπεδο δύο κριτηρίων που ελαχιστοποιούνται ταυτόχρονα. Μια περίπτωση λέγεται ότι κυριαρχείται από μια άλλη όταν η δεύτερη δεν είναι χειρότερη σε κανένα από τα δύο μεγέθη και είναι καλύτερη σε τουλάχιστον ένα· μια τέτοια περίπτωση δεν υπάρχει λόγος να επιλεγεί ποτέ. Το σύνολο των περιπτώσεων που δεν κυριαρχούνται από καμία άλλη αποτελεί το μέτωπο Pareto, δηλαδή ακριβώς εκείνες τις επιλογές στις οποίες η βελτίωση του ενός κριτηρίου απαιτεί υποχώρηση στο άλλο.

Το αποτέλεσμα είναι διαφωτιστικό ακριβώς επειδή είναι αρνητικό. Οι μετρήσεις σχηματίζουν στενή διαγώνια ζώνη, με συντελεστή συσχέτισης των λογαρίθμων χρόνου και ενέργειας ίσο με 0,97. Από τις 209 περιπτώσεις μόνο δύο ανήκουν στο μέτωπο, και αμφότερες αφορούν την ίδια υλοποίηση, το map-reduce του επεξεργαστή, σε δύο γειτονικά μεγέθη εισόδου. Δεν υφίσταται δηλαδή ουσιαστικός συμβιβασμός μεταξύ ταχύτητας και ενέργειας για το πρόβλημα αυτό: η ταχύτερη διαμόρφωση είναι ταυτόχρονα και η οικονομικότερη.

Ο λόγος προκύπτει από τα δύο προηγούμενα σχήματα. Η ισχύς μεταβάλλεται μεταξύ των υλοποιήσεων μόλις κατά παράγοντα 2,3, ενώ ο χρόνος μεταβάλλεται κατά τέσσερις τάξεις μεγέθους. Όταν ο ένας παράγοντας του γινομένου είναι σχεδόν σταθερός, το γινόμενο ακολουθεί τον άλλον. Η δυνατότητα ανταλλαγής μεγαλύτερης διάρκειας με χαμηλότερη ισχύ, η οποία σε άλλα συστήματα αποτελεί πραγματικό σχεδιαστικό μοχλό, εδώ δεν υπάρχει.

Αξίζει τέλος να σημειωθεί ποιες περιπτώσεις συγκροτούν το μέτωπο: όλες εκτελούνται στον επεξεργαστή. Καμία διαμόρφωση της μονάδας γραφικών ή της μονάδας νευρωνικής επεξεργασίας δεν είναι βέλτιστη κατά Pareto σε κανένα σημείο του παραμετρικού χώρου που εξετάστηκε.

7.5.1 Γινόμενο ενέργειας-καθυστερήσης



Σχήμα 7.12: Γινόμενο ενέργειας-καθυστερήσης συναρτήσει του μεγέθους εισόδου.

Το γινόμενο ενέργειας-καθυστερήσης συνοψίζει τα δύο κριτήρια σε ένα και επιβραβεύει τις υλοποιήσεις που είναι ταυτόχρονα γρήγορες και οικονομικές. Η κατάταξη που προκύπτει είναι η σαφέστερη ολόκληρου του κεφαλαίου. Το map-reduce στον επεξεργαστή έχει το χαμηλότερο γινόμενο από κάθε άλλη υλοποίηση, με την αμέσως επόμενη, που είναι το map-reduce της μονάδας γραφικών, να υστερεί κατά παράγοντα είκοσι οκτώ και τη χειρότερη κατά παράγοντα σαράντα τρία.

Το map-reduce στον επεξεργαστή έχει το χαμηλότερο γινόμενο σχεδόν σε ολόκληρο το εύρος· η μοναδική εξαίρεση είναι το μικρότερο μέγεθος του σχήματος, όπου η καθαρή ενέργειά του μετριέται μηδενική, κάτω από την ανάλυση του μετρητή σε αυτή τη διάρκεια, αφήνοντας εκεί τη διτονική του επεξεργαστή ονομαστικά χαμηλότερη. Στα υπόλοιπα μεγέθη, το μέγεθος του χάσματος προς την επόμενη υλοποίηση δεν είναι μονότονο: κυμαίνεται μεταξύ περίπου μίας και δυόμισι τάξεων μεγέθους, καθώς η διτονική και το map-reduce του επεξεργαστή εναλλάσσονται στη δεύτερη θέση ανάλογα με το ακριβές μέγεθος εισόδου. Η κατάταξη αυτή καθαυτή δεν αμφισβητείται σοβαρά ποτέ· μόνο το περιθώριο είναι θορυβώδες.

Το αποτέλεσμα αυτό είναι το πιο αντίθετο στη διαίσθηση από όσα παρουσιάζονται εδώ. Για επιλογή top-k με μικρό k, η εκφόρτωση σε επιταχυντή δεν απλώς αποτυγχάνει να αποδώσει ενεργειακά· είναι σαφώς χειρότερη από το να μην γίνει καθόλου.

7.6 Επίδραση του τύπου δεδομένων

Υλοποίηση	half	int	uint	float	double
CPU διτονική	4,60	8,01	7,93	8,01	14,03
CPU map-reduce	0,39	1,23	1,22	1,22	2,35
CPU αναφορά	13,27	4,65	4,63	5,50	5,54
GPU διτονική	0,88	1,34	1,37	1,34	2,89
NPU διτονική	7,71	8,17	8,37	8,23	25,38

Πίνακας 7.2: Αλγοριθμικός χρόνος ανά τύπο δεδομένων, σε ms, για 2^{24} στοιχεία και κ ίσο με 8.

Οι υλοποιήσεις της εργασίας ακολουθούν το πλάτος του τύπου, όπως αναμένεται από αλγορίθμους περιορισμένους από τη μνήμη. Η μισή ακρίβεια είναι σταθερά η ταχύτερη, με τη διτονική ταξινόμηση στον επεξεργαστή να ολοκληρώνει σε λίγο πάνω από τον μισό χρόνο της απλής, ακριβώς επειδή διακινεί τα μισά bytes με τον ίδιο ρυθμό συγκρίσεων.


Η υλοποίηση αναφοράς συμπεριφέρεται αντίθετα: η μισή ακρίβεια είναι η βραδύτερη περίπτωση της. Η διαφορά αποκαλύπτει ότι η βιβλιοθήκη δεν περιορίζεται από τη μνήμη, αλλά από το κόστος της βαθμωτής σύγκρισης, το οποίο για τη μισή ακρίβεια περιλαμβάνει μετατροπή. Η κατάταξη μεταξύ τύπων δεν είναι επομένως ιδιότητα του υλικού, αλλά της υλοποίησης.

Η διπλή ακρίβεια στη μονάδα νευρωνικής επεξεργασίας ξεχωρίζει, με τριπλάσιο χρόνο από κάθε άλλον τύπο. Η επιβάρυνση οφείλεται εξ ολοκλήρου στο πρόσθετο πέρασμα διόρθωσης της ενότητας 6.4.3, το οποίο απαιτείται επειδή το κλειδί των 32 bit δεν αρκεί για να εκφράσει τιμές των 64.


Ο συνδυασμός των δύο αντίθετων συμπεριφορών παράγει το μοναδικό σημείο ολοκλήρωσης της εργασίας όπου η μονάδα νευρωνικής επεξεργασίας υπερτερεί της βιβλιοθήκης της. Για μισή ακρίβεια, η διτονική ταξινόμηση στη μονάδα είναι ταχύτερη από τη βιβλιοθήκη σε είκοσι εννέα από τις μετρούμενες περιπτώσεις, με τη μεγαλύτερη διαφορά να φτάνει τον παράγοντα δύομισι. Το φαινόμενο εμφανίζεται ασθενέστερα και στους δύο άλλους τύπους κινητής υποδιαστολής, ενώ για τους ακέραιους δεν εμφανίζεται ποτέ.

Η αιτία δεν είναι ότι η μονάδα χειρίζεται καλά τη μισή ακρίβεια, αλλά ότι η βιβλιοθήκη τη χειρίζεται άσχημα. Ο πυρήνας της διάταξης λειτουργεί σε ακεραίους των 32 bit ανεξαρτήτως τύπου, οπότε το κόστος του τύπου μετατοπίζεται στην κωδικοποίηση του host, η οποία για τη μισή ακρίβεια είναι διανυσματική σύμφωνα με την ενότητα 6.4.2. Η βιβλιοθήκη αντιθέτως εκτελεί βαθμωτές συγκρίσεις με ενδιαμέση μετατροπή. Η εκφόρτωση αποδεικνύεται δηλαδή συμφέρουσα ακριβώς εκεί όπου η καθιερωμένη λύση είναι ασθενέστερη, και όχι εκεί όπου η μονάδα είναι ισχυρότερη.

7.7 Ευαισθησία στην κατανομή της εισόδου



(α) k=8.



(β) k=131072.

Σχήμα 7.13: Ευαισθησία του χρόνου στην κατανομή της εισόδου, για απλή ακρίβεια και 2^{24} στοιχεία. Κάθε στήλη δίνει τον χρόνο μιας κατανομής ως προς τον χρόνο της ομοιόμορφης για την ίδια υλοποίηση· η μονάδα σημαίνει πλήρη ανεξαρτησία από τα δεδομένα.

Η κανονικοποίηση ως προς την ομοιόμορφη κατανομή επιτρέπει να συγκριθούν στο ίδιο σχήμα και οι εννέα συνδυασμοί, παρότι οι απόλυτοι χρόνοι τους διαφέρουν κατά τάξεις μεγέθους. Μια υλοποίηση ανεπηρέαστη από τα δεδομένα εμφανίζεται ως πέντε ίσες στήλες ύψους ένα, ενώ μια ευαίσθητη εμφανίζεται με στήλες που αποκλίνουν προς

τις δύο κατευθύνσεις.

Το σχήμα επιβεβαιώνει πρώτα το αναμενόμενο: η διτονική ταξινόμηση στον επεξεργαστή και στη μονάδα γραφικών είναι πρακτικά ανεπηρέαστη από την κατανομή και στις δύο τιμές του k , με συνολική διακύμανση κάτω του παράγοντα 1,12. Η ιδιότητα αυτή την καθιστά αξιόπιστο μάρτυρα: αν ο χρόνος της μεταβαλλόταν, η μεταβολή θα αποδιδόταν στη μέτρηση και όχι στον αλγόριθμο.

Οι υλοποιήσεις που βασίζονται σε σωρούς εμφανίζουν το αντίθετο άκρο, και μάλιστα ανεξάρτητα από το ποιος έγραψε τον κώδικα. Η βιβλιοθήκη αναφοράς μεταβάλλεται κατά παράγοντα εβδομήντα δύο μεταξύ αύξουσας και φθίνουσας εισόδου, αλλά και το δικό μας `map-reduce` στον επεξεργαστή μεταβάλλεται κατά παράγοντα είκοσι πέντε, για τον ίδιο μηχανισμό της ενότητας 4.3. Η ευαισθησία στα δεδομένα είναι επομένως ιδιότητα του αλγορίθμου και όχι της υλοποίησης: όποιος επιλέγει με σωρό την κληρονομεί.

Η βιβλιοθήκη αναφοράς της μονάδας γραφικών εμφανίζει τρίτο μοτίβο: επιβραδύνεται σχεδόν κατά τον ίδιο παράγοντα και προς τις δύο κατευθύνσεις, 4,95 για την αύξουσα έναντι 4,92 για τη φθίνουσα, αντί να ευνοεί τη μία όπως οι σωροί. Καθώς η ταξινόμηση δεν μεταβάλλει την κατανομή των τιμών (ενότητα 3.7.2), αυτό δεν είναι η κατανομή `radix-adversarial` ψηφίων της ενότητας 2.2.4, αλλά ζήτημα θέσης: οι υποψήφιοι που επιζούν του κρίσιμου κάδου καταλήγουν συγκεντρωμένοι στο ένα ή στο άλλο άκρο του πίνακα, κάτι που επιβαρύνει συμμετρικά το παράλληλο στάδιο συμπίκνωσης της βιβλιοθήκης ανεξάρτητα από το για ποιο άκρο πρόκειται.

Δύο παρατηρήσεις αξίζουν ιδιαίτερης προσοχής. Πρώτον, η διτονική ταξινόμηση στη μονάδα νευρωνικής επεξεργασίας *είναι* ευαίσθητη στην κατανομή, σε αντίθεση με τις δύο άλλες αρχιτεκτονικές, με διακύμανση παράγοντα πενήντα τρία. Η ευαισθησία δεν προέρχεται από τη διάταξη, η οποία εκτελεί σταθερό δίκτυο, αλλά από τη συγχώνευση με σωρό που εκτελεί ο `host` και η οποία, όπως δείχθηκε στην ενότητα 6.4.1, κυριαρχεί στον χρόνο.

Δεύτερον, η αντιπαράθεση των δύο τιμών του k απομονώνει την αιτία της ευαισθησίας. Το `map-reduce` στη μονάδα γραφικών είναι ευαίσθητο για k ίσο με 8, όπου η ταξινομημένη είσοδος το επιβραδύνει κατά παράγοντα 4,0, αλλά γίνεται σχεδόν ανεπηρέαστο για k ίσο με 131072, όπου η ίδια είσοδος το μεταβάλλει κατά μόλις 4%. Ο ίδιος κώδικας, με τα ίδια δεδομένα, αλλάζει συμπεριφορά επειδή αλλάζει ο περιοριστικός παράγοντας: στη δεύτερη περίπτωση δεν τον περιορίζει η απόρριψη, αλλά η έλλειψη παραλληλίας της ενότητας 5.3.1. Όταν ο περιοριστικός παράγοντας δεν είναι τα δεδομένα, η κατανομή τους παύει να έχει σημασία.

Οι μετρήσεις που παρουσιάστηκαν καλύπτουν ολόκληρο τον παραμετρικό χώρο της ενότητας 3.7 και συμφωνούν μεταξύ τους ως προς το ποιος παράγοντας περιορίζει κάθε υλοποίηση. Η ερμηνεία τους, τα όρια εντός των οποίων ισχύουν και οι κατευθύνσεις που ανοίγουν εξετάζονται στο κεφάλαιο 8.

Κεφάλαιο 8

Συμπεράσματα και μελλοντική εργασία

8.1 Συμπεράσματα

Η εργασία υλοποίησε δύο αλγορίθμους επιλογής top-k σε τρεις αρχιτεκτονικές και τους μέτρησε στον ίδιο παραμετρικό χώρο, με κοινή υποδομή και κοινό έλεγχο ορθότητας. Τα συμπεράσματα που ακολουθούν δεν επαναλαμβάνουν τις μετρήσεις του κεφαλαίου 7, αλλά όσα από αυτές γενικεύονται πέρα από το συγκεκριμένο υλικό.

Η επιλογή top-k είναι πρόβλημα κίνησης δεδομένων. Καμία από τις εννέα διαμορφώσεις που μετρήθηκαν δεν περιορίζεται από την υπολογιστική ικανότητα. Στην ανάλυση της ενότητας 7.4 κάθε πυρήνας τοποθετείται στο κεκλιμένο τμήμα της οροφής, δηλαδή στην περιοχή όπου η επίδοση καθορίζεται από το εύρος ζώνης και όχι από τον ρυθμό των συγκρίσεων. Η πρακτική συνέπεια είναι ότι η βελτιστοποίηση σημαίνει μείωση του όγκου που διακινείται και όχι επιτάχυνση του υπολογισμού. Η ίδια η εργασία το επιβεβαιώνει αρνητικά: η διτονική ταξινόμηση στη μονάδα γραφικών αξιοποιεί σαφώς μεγαλύτερο ποσοστό της οροφής της από τη βιβλιοθήκη αναφοράς και παρ' όλα αυτά χάνει, διότι διακινεί επταπλάσια δεδομένα.

Ο κατάλληλος αλγόριθμος καθορίζεται από τον λόγο n/k και όχι από την αρχιτεκτονική. Η ανατροπή της ενότητας 7.2.2 εμφανίζεται και στις τρεις αρχιτεκτονικές. Η ταχύτερη υλοποίηση για k ίσο με 8 είναι η βραδύτερη για k ίσο με 131072, με επιβράδυνση παράγοντα 2800, ενώ το δίκτυο ταξινόμησης στην ίδια συσκευή επιβαρύνεται μόλις κατά έξι. Η αιτία είναι δομική και όχι υλοποιησιακή: ο σωρός αρχίζει να φιλτράρει μόνο αφού γεμίσει, οπότε η διαθέσιμη παραλληλία φράσσεται από τον λόγο n/k . Το ότι ανεξάρτητη εργασία σε διαφορετικό υλικό καταλήγει στην ίδια διάκριση και την αντιμετωπίζει με προσαρμοστική εναλλαγή αλγορίθμου [15] ενισχύει το συμπέρασμα ότι πρόκειται για ιδιότητα των αλγορίθμων.

Το όριο της μέτρησης καθορίζει ποια αρχιτεκτονική «κερδίζει». Στο αλγοριθμικό πεδίο η μονάδα γραφικών είναι ταχύτερη μόνο στα δύο άκρα του εύρους μεγεθών: στο πεδίο end-to-end ο επεξεργαστής είναι ταχύτερος σε ολόκληρο το εύρος, συμπεριλαμβανομένων και αυτών των ίδιων άκρων. Η κατάταξη ανατρέπεται δηλαδή ακριβώς

εκεί όπου η μονάδα γραφικών φαινόταν να κερδίζει· η μόνη διαφορά μεταξύ των δύο απαντήσεων είναι το πού τοποθετείται το όριο της μέτρησης. Το εύρημα αυτό έχει μεθοδολογική σημασία που ξεπερνά το συγκεκριμένο πρόβλημα: κάθε ισχυρισμός επιτάχυνσης με εκφόρτωση σε επιταχυντή που αναφέρει μόνο τον χρόνο του πυρήνα δεν είναι ελέγξιμος, διότι αποκρύπτει ακριβώς το κόστος που καθορίζει αν η εκφόρτωση συμφέρει.

Χαμηλή ισχύς δεν συνεπάγεται χαμηλή ενέργεια. Η μονάδα νευρωνικής επεξεργασίας έχει τη χαμηλότερη κατανάλωση ισχύος από κάθε άλλη υλοποίηση, 7.9 W έναντι 15.6 W του επεξεργαστή και 18.6 W της μονάδας γραφικών, και ταυτόχρονα καταναλώνει πάνω από τετραπλάσια ενέργεια από τον επεξεργαστή. Το πλεονέκτημα του σαράντα εννέα τοις εκατό στην ισχύ εξανεμίζεται από το μειονέκτημα του οκταπλασίου στη διάρκεια. Επιπλέον, όπως δείχθηκε στην ενότητα 7.5, δεν υπάρχει ουσιαστικός συμβιβασμός μεταξύ χρόνου και ενέργειας για το πρόβλημα αυτό: η ισχύς μεταβάλλεται μεταξύ των υλοποιήσεων μόλις κατά παράγοντα 2,3 ενώ ο χρόνος κατά τέσσερις τάξεις μεγέθους, οπότε το γινόμενο ακολουθεί τον χρόνο. Από τις 209 μετρημένες περιπτώσεις δύο μόνο ανήκουν στο μέτωπο Pareto, και εκτελούνται στον επεξεργαστή.

Συνολικά, για επιλογή top-k με μικρό k η εκφόρτωση σε επιταχυντή δεν απλώς αποτυγχάνει να αποδώσει· είναι μετρήσιμα χειρότερη από το να μη γίνει καθόλου, με το γινόμενο ενέργειας-καθυστέρησης να υστερεί κατά παράγοντα από είκοσι οκτώ έως σαράντα τρία έναντι του map-reduce στον επεξεργαστή. Το συμπέρασμα δεν αφορά την ποιότητα των επιταχυντών αλλά την αντιστοίχιση φορτίου και αρχιτεκτονικής. Η αρχή σχεδίασης των μονάδων νευρωνικής επεξεργασίας, όπως διατυπώθηκε στην ενότητα 2.3.3, είναι η μεγιστοποίηση της τοπικής επαναχρησιμοποίησης των δεδομένων ώστε να αποσβεστεί το ενεργειακό κόστος της μετακίνησής τους. Η επιλογή top-k δεν προσφέρει καμία επαναχρησιμοποίηση προς εκμετάλλευση, οπότε η προϋπόθεση της σχεδίασης απλώς δεν ισχύει. Η μέτρηση της ενότητας 6.4.1, όπου το 61% του χρόνου δαπανάται σε προετοιμασία και αποστολή δεδομένων και μόλις το 7% σε αναμονή της συσκευής, είναι η ποσοτική έκφραση αυτής της αναντιστοιχίας.

Αξίζει τέλος να σχολιαστεί η μοναδική εξαίρεση. Για αριθμούς μισής ακρίβειας η διτονική ταξινόμηση στη μονάδα νευρωνικής επεξεργασίας ξεπερνά την υλοποίηση αναφοράς της σε είκοσι εννέα μετρημένες περιπτώσεις. Η ανάλυση της ενότητας 7.6 δείχνει όμως ότι η υπεροχή προκύπτει επειδή η βιβλιοθήκη χειρίζεται άσχημα τον συγκεκριμένο τύπο και όχι επειδή η συσκευή τον χειρίζεται καλά. Το παράδειγμα αυτό είναι διδακτικό ως προς τη μεθοδολογία: μια επιτάχυνση έναντι ενός μέτρου σύγκρισης τεκμηριώνει ισχυρισμό μόνο εφόσον εξηγηθεί ποιος από τους δύο όρους του λόγου την προκάλεσε.

8.2 Περιορισμοί

Τα παραπάνω συμπεράσματα ισχύουν εντός συγκεκριμένων ορίων, τα οποία δηλώνονται εδώ συγκεντρωτικά.

Η σημαντικότερη ασυμμετρία αφορά το μέτρο σύγκρισης του επεξεργαστή. Η std::partial_sort είναι αυστηρά μονονηματική, ενώ οι υλοποιήσεις της εργασίας χρησιμοποιούν έως οκτώ νήματα, οπότε κάθε λόγος χρόνων μεταξύ τους συγκεντρώνει δύο αιτίες, τη διαφορά του αλγορίθμου και τη διαφορά του πλήθους των πυρήνων,

όπως ήδη σημειώθηκε στην ενότητα 4.5. Μια σύγκριση νήμα προς νήμα θα ήταν αυστηρότερη και θα έδινε μικρότερες επιταχύνσεις. Η επιλογή δικαιολογείται από το ερώτημα της εργασίας, το οποίο αφορά τη σύγκριση με ό,τι έχει ήδη στη διάθεσή του ο προγραμματιστής, αλλά ο αναγνώστης πρέπει να την έχει υπόψη.

Η καταμετρούμενη κίνηση δεδομένων των υλοποιήσεων αναφοράς είναι κάτω φράγμα και όχι πραγματική μέτρηση, καθώς προσμετρώνται μόνο η είσοδος και η έξοδος ενώ τα εσωτερικά περάσματα των βιβλιοθηκών δεν είναι παρατηρήσιμα. Κάθε ποσοστό αξιοποίησης της οροφής που αναφέρεται για αυτές στην ενότητα 7.4.1 είναι συνεπώς υποεκτίμηση και δεν συγκρίνεται άμεσα με τα αντίστοιχα ποσοστά των δύο υλοποιήσεων της εργασίας.

Για τη μονάδα νευρωνικής επεξεργασίας δεν υπάρχει μέτρο σύγκρισης επί της συσκευής, διότι δεν υπάρχει βιβλιοθήκη επιλογής top-k για την αρχιτεκτονική αυτή. Η αναφορά εκτελείται στον host, οπότε οι σχετικές συγκρίσεις απαντούν στο ερώτημα «αξίζει η εκφόρτωση» και όχι στο ερώτημα «πόσο καλή είναι η υλοποίηση σε σχέση με την καλύτερη δυνατή στη συσκευή».

Ο πίνακας ανάλυσης φάσεων της ενότητας 6.4.1 προέρχεται από χειροκίνητη εκτέλεση με ξεχωριστή οργάνολογία και όχι από τη σάρωση που παράγει τα υπόλοιπα αποτελέσματα. Δεν αναπαράγεται επομένως από τη διαδικασία του παραρτήματος Γ' και πρέπει να διαβάζεται ως ενδεικτική κατανομή του χρόνου και όχι ως μέτρηση ισοδύναμης αυστηρότητας με τις υπόλοιπες.

Τέλος, όλες οι μετρήσεις προέρχονται από ένα μηχάνημα, με πέντε τύπους δεδομένων, τέσσερις τιμές του k και μεγέθη εισόδου έως 2^{24} στοιχεία. Τα ποιοτικά συμπεράσματα, και ιδίως η εξάρτηση από τον λόγο n/k και ο ρόλος του ορίου μέτρησης, αναμένεται να μεταφέρονται σε ανάλογα συστήματα· οι συγκεκριμένοι αριθμητικοί παράγοντες όμως δεν πρέπει να θεωρούνται μεταφέριμοι.

8.3 Μελλοντική εργασία

Η σαφέστερη κατεύθυνση προκύπτει άμεσα από τον περιοριστικό παράγοντα της μονάδας νευρωνικής επεξεργασίας. Εφόσον το μεγαλύτερο μέρος του χρόνου δαπανάται σε προετοιμασία και αποστολή δεδομένων ανά κλήση, ένα φορτίο που εκτελεί πολλά ερωτήματα top-k ταυτόχρονα θα απόσβενε ακριβώς αυτό το κόστος· η ομαδική επιλογή εμφανίζεται άλλωστε φυσικά στις εφαρμογές που αναφέρθηκαν στην ενότητα 2.1, όπου η επιλογή επαναλαμβάνεται σε κάθε βήμα ή σε κάθε ερώτημα. Η επέκταση αυτή θα έκρινε αν η μονάδα υστερεί λόγω της αρχιτεκτονικής της ή λόγω του τρόπου με τον οποίο τροφοδοτείται.

Στην ίδια κατεύθυνση, η μείωση της συμμετοχής του host στη διοχέτευση, με απευθείας πρόσβαση της συσκευής στα δεδομένα αντί για ρητή αντιγραφή ανά τμήμα, θα επιτίθετο στο ίδιο κόστος από την άλλη πλευρά. Η σχετική δυνατότητα εξαρτάται από τα εργαλεία και τις διεπαφές που εκθέτει η πλατφόρμα και αποτελεί το πλέον τεχνικά απαιτητικό από τα ανοικτά ζητήματα.

Δεύτερη κατεύθυνση είναι η προσαρμοστική επιλογή αλγορίθμου. Δεδομένου ότι η ανατροπή της ενότητας 7.2.2 είναι συστηματική και προβλέψιμη από τον λόγο n/k , μια υλοποίηση που επιλέγει δυναμικά μεταξύ σωρού και δικτύου ταξινόμησης θα κάλυπτε

ολόκληρο το εύρος των παραμέτρων χωρίς σημείο κατάρρευσης. Το σημείο μετάβασης μπορεί να προσδιοριστεί από τις ίδιες τις μετρήσεις της εργασίας.

Τρίτη κατεύθυνση είναι η επέκταση του παραμετρικού χώρου προς τα σημεία που η εργασία άγγιξε, αλλά δεν εξάντλησε: τιμές του k μεγαλύτερες από όσες εξετάστηκαν, όπου η επιλογή προσεγγίζει την ταξινόμηση, και είσοδοι που δεν χωρούν στη μνήμη μιας συσκευής, όπου η διαχείριση της ροής γίνεται μέρος του αλγορίθμου και όχι της υποδομής.

Τέλος, η υποδομή μέτρησης που αναπτύχθηκε είναι ανεξάρτητη από το συγκεκριμένο πρόβλημα. Ο διαχωρισμός των δύο πεδίων μέτρησης, η καταγραφή ενέργειας με κοινή σημασιολογία σε τρεις αρχιτεκτονικές και η τοποθέτηση των πυρήνων σε μετρημένη οροφή αποτελούν εργαλεία που μπορούν να εφαρμοστούν σε οποιοδήποτε φορτίο εξετάζεται για εκφόρτωση. Η επαναχρησιμοποίησή τους σε πρόβλημα με ουσιαστική επαναχρησιμοποίηση δεδομένων θα έδινε το φυσικό αντίπαλο δέος των αποτελεσμάτων που παρουσιάστηκαν εδώ.

Παράρτημα Α΄

Ακρωνύμια

AIE AI Engine

API Application Programming Interface

AVX Advanced Vector Extensions

CPU Central Processing Unit

CUDA Compute Unified Device Architecture

D2H Device to Host

DRAM Dynamic Random Access Memory

EDP Energy Delay Product

FIFO First In First Out

GPU Graphics Processing Unit

H2D Host to Device

MLIR Multi-Level Intermediate Representation

NPU Neural Processing Unit

NVML NVIDIA Management Library

RAPL Running Average Power Limit

SIMD Single Instruction Multiple Data

SIMT Single Instruction Multiple Threads

SM Streaming Multiprocessor

TOPS Tera Operations Per Second

XRT Xilinx Runtime

Παράρτημα Β΄

Γλωσσάρι όρων

Ελληνικός όρος	Αγγλικός όρος
διτονική ακολουθία	bitonic sequence
διτονική ταξινόμηση	bitonic sort
περικομμένη διτονική ταξινόμηση	truncated bitonic sort
χρονοδιάγραμμα επιπέδων	layer schedule
συγχώνευση επιπέδων	layer fusion
δίκτυο ταξινόμησης	sorting network
σύγκριση-ανταλλαγή	compare-exchange
σωρός	heap
επιλογή με βάση την αναπαράσταση	radix selection
ψηφίδα	die
πλακίδιο	tile
πλακίδιο διασύνδεσης	shim tile
κοινή μνήμη	shared memory
απομονωτής	buffer
διπλή ενταμίευση	double buffering
άμεση προσπέλαση μνήμης	direct memory access (DMA)
νήμα	thread
διανυσματοποίηση	vectorization
βαθμωτός	scalar
ροή δεδομένων	dataflow
διοχέτευση	pipelining
υποδομή μετρήσεων	measurement harness
ταβάνι	(roofline) ceiling
υπολογιστική ένταση	operational intensity
υλοποίηση αναφοράς	reference implementation
υλοποίηση επαλήθευσης	ground truth
κίνηση δεδομένων	data traffic
εύρος ζώνης μνήμης	memory bandwidth
γινόμενο ενέργειας-καθυστερήσης	energy-delay product
κατανομή εισόδου	input distribution

Πίνακας Β΄.1: Αντιστοίχιση ελληνικών και αγγλικών όρων.

Παράρτημα Γ΄

Αναπαραγωγή των μετρήσεων

Το παράρτημα αυτό περιγράφει τα βήματα που απαιτούνται για την αναπαραγωγή των μετρήσεων της εργασίας, από την εγκατάσταση των εργαλείων έως την παραγωγή των διαγραμμάτων. Οι εντολές δίνονται για το σύστημα της ενότητας 3.1 και εκτελούνται από τη ρίζα του αποθετηρίου.

Γ΄.1 Απαιτήσεις λογισμικού

Και οι τρεις υλοποιήσεις απαιτούν μεταγλωττιστή C++ που υποστηρίζει το πρότυπο C++20, καθώς και `cmake` έκδοσης 3.18 ή νεότερης. Οι διανυσματικές εντολές δεν αποτελούν απαίτηση μεταγλώττισης: η επιλογή ανάμεσα σε `AVX-512`, `AVX2` και βαθμωτή εκτέλεση γίνεται κατά τον χρόνο εκτέλεσης, με βάση τις δυνατότητες που αναφέρει ο επεξεργαστής. Οι μετρήσεις της εργασίας προέκυψαν σε επεξεργαστή με `AVX-512`, οπότε σε μηχάνημα χωρίς αυτό η μονάδα κεντρικής επεξεργασίας ακολουθεί διαφορετική διαδρομή κώδικα και τα αποτελέσματά της δεν είναι άμεσα συγκρίσιμα. Πέραν αυτών, κάθε αρχιτεκτονική έχει τις δικές της απαιτήσεις.

Για τη μονάδα γραφικών απαιτείται η εργαλειοθήκη `CUDA` με τον μεταγλωττιστή `nvc` και τη βιβλιοθήκη `CUB`, η οποία διανέμεται μαζί της. Για τις μετρήσεις ισχύος απαιτείται επιπλέον η βιβλιοθήκη `NVML`, που συνοδεύει τον οδηγό.

Για τη μονάδα νευρωνικής επεξεργασίας απαιτείται η στοίβα εκτέλεσης `XRT` μαζί με το πρόσθετο για τη συσκευή `XDNA`, και για τη μεταγλώττιση των πυρήνων το `MLIR-AIE` σε περιβάλλον `Python`. Το περιβάλλον αυτό πρέπει να βρίσκεται στη ρίζα του αποθετηρίου με το όνομα `hru_venv`, καθώς εκεί το αναζητούν τόσο η μεταγλώττιση των πυρήνων όσο και η αυτοματοποιημένη εκτέλεση των μετρήσεων. Ο χρήστης πρέπει να ανήκει στις ομάδες που έχουν πρόσβαση στη συσκευή και το όριο κλειδωμένης μνήμης πρέπει να είναι επαρκές· διαφορετικά η συσκευή δεν είναι ορατή στη στοίβα εκτέλεσης. Η μεταβλητή `XILINX_XRT` πρέπει να δείχνει στη θέση εγκατάστασης της `XRT`.

Η μέτρηση ενέργειας διαβάζει τους μετρητές `RAPL` μέσω του `/sys/class/powercap`, κάτι που απαιτεί αυξημένα δικαιώματα. Σε μια μεμονωμένη εκτέλεση, χωρίς αυτά η μέτρηση δηλώνεται ρητά ως μη διαθέσιμη αντί να αναφερθούν μηδενικές τιμές, όπως περιγράφεται στην ενότητα 3.3.3· η αντίστοιχη σάρωση, αντιθέτως, δεν ξεκινά καν και τερματίζει με σφάλμα, ώστε να μην παραχθεί κενό σύνολο δεδομένων. Τέλος, η υποδομή ανάλυσης απαιτεί `Python` με τις βιβλιοθήκες που δηλώνονται στο αποθετήριο· το

αντίστοιχο περιβάλλον δημιουργείται αυτόματα την πρώτη φορά που εκτελείται.

Γ'.2 Μεταγλώττιση

Η μεταγλώττιση όλων των υλοποιήσεων γίνεται με μία εντολή :

```
make build-all
```

Κάθε αρχιτεκτονική μπορεί να μεταγλωττιστεί και ξεχωριστά, με τους στόχους `build-cpu`, `build-gpu` και `build-npu`, κάτι που είναι χρήσιμο σε σύστημα που δεν διαθέτει και τις τρεις μονάδες. Τα παραγόμενα εκτελέσιμα τοποθετούνται στον κατάλογο `build`, δύο ανά αρχιτεκτονική: ένα για τις μετρήσεις `top-k` και ένα για τις μετρήσεις των ταβανιών της ενότητας 3.4.

Η μεταγλώττιση για τη μονάδα νευρωνικής επεξεργασίας παράγει επιπλέον τα αρχεία διαμόρφωσης του υλικού. Επειδή η απουσία τους οδηγεί σε σιωπηλή παράλειψη των αντίστοιχων μετρήσεων, η παρουσία τους ελέγχεται ρητά :

```
make verify-artifacts
```

Ο έλεγχος καλύπτει τα δύο αρχεία διαμόρφωσης και τα τρία εκτελέσιμα των μετρήσεων `top-k`, οπότε προϋποθέτει πλήρη μεταγλώττιση και των τριών υλοποιήσεων· ύστερα από μεταγλώττιση μίας μόνο αρχιτεκτονικής αποτυγχάνει εξ ορισμού.

Γ'.3 Εκτέλεση των πειραμάτων

Ο συνιστώμενος τρόπος αναπαραγωγής δεν είναι η εκτέλεση των επιμέρους βημάτων, αλλά μία και μόνη εντολή που εκτελεί ολόκληρη τη διαδικασία :

```
make benchmark GPU_W=50
```

Ο λόγος που αυτή είναι η προτιμότερη οδός δεν είναι η ευκολία, αλλά η συνέπεια. Η σειρά των βημάτων έχει σημασία: αν οι συνθήκες καθηλωθούν μετά την έναρξη των μετρήσεων, ή αν μια σάρωση εκτελεστεί με εκτελέσιμα από παλαιότερη μεταγλώττιση, τα αποτελέσματα δεν είναι συγκρίσιμα μεταξύ τους. Η εντολή επιβάλλει τη σωστή σειρά και δεν αφήνει περιθώριο παράλειψης.

Η ακολουθία που εκτελείται αποτελείται από έξι στάδια. Πρώτα διαγράφονται τα προηγούμενα αποτελέσματα και τα παλαιά εκτελέσιμα, ώστε να μην επιβιώσει τίποτα από προγενέστερη εκτέλεση. Έπειτα μεταγλωττίζονται και οι τρεις υλοποιήσεις και ελέγχεται η παρουσία των παραγόμενων αρχείων, με τον έλεγχο της ενότητας Γ'.2. Στο τρίτο στάδιο καθηλώνονται οι συνθήκες του συστήματος και δίνεται πρόσβαση ανάγνωσης στους μετρητές ενέργειας. Στο τέταρτο εκτελούνται διαδοχικά οι τέσσερις σαρώσεις, στο πέμπτο παράγονται τα διαγράμματα κάθε μιας, και στο έκτο αποκαθίστανται οι αρχικές συνθήκες του συστήματος.

Δύο προϋποθέσεις ελέγχονται πριν από οτιδήποτε άλλο: η διαθεσιμότητα του `sudo` και η ύπαρξη του περιβάλλοντος `npu_venv` της ενότητας Γ'.1. Αν λείπει κάποια από τις δύο, η εντολή τερματίζει αμέσως, χωρίς να μεταβάλει το σύστημα ή τα υπάρχοντα αποτελέσματα.

Τρεις ιδιότητες της εντολής αξίζει να σημειωθούν. Τα δικαιώματα διαχειριστή ζητούνται μία μόνο φορά στην αρχή και διατηρούνται ενεργά για όλη τη διάρκεια, οπότε η εκτέλεση δεν απαιτεί καμία παρέμβαση στη συνέχεια. Οι συνθήκες αποκαθίστανται σε κάθε περίπτωση, ακόμη και αν η εκτέλεση διακοπεί από τον χρήστη ή τερματίσει με σφάλμα, ώστε το σύστημα να μη μένει καθηλωμένο. Τέλος, αποτυχία μιας σάρωσης δεν ακυρώνει τις υπόλοιπες: καταγράφεται ως προειδοποίηση και η διαδικασία συνεχίζει, ώστε μια μερική εκτέλεση να παράγει παρ' όλα αυτά τα δεδομένα που κατέστη δυνατό να μετρηθούν.

Το όρισμα GPU_W καθορίζει το όριο ισχύος της μονάδας γραφικών, το οποίο σύμφωνα με την ενότητα 3.8 πρέπει να παραμένει σταθερό σε όλη τη σάρωση. Πρέπει επίσης να τονιστεί ότι η εντολή διαγράφει τα υπάρχοντα αποτελέσματα ως πρώτο της βήμα, οπότε τυχόν προηγούμενες μετρήσεις που πρέπει να διατηρηθούν οφείλουν να αντιγραφούν πρώτα σε άλλη θέση.

Γ'.3.1 Εκτέλεση επιμέρους βημάτων

Για μερική ή επαναληπτική εκτέλεση, κάθε στάδιο είναι διαθέσιμο και ξεχωριστά. Οι συνθήκες του συστήματος ελέγχονται με:

```
make pin ARGS=50      # governor, boost off, GPU cap 50 W
make pin-show          # report the current state
make unpin             # restore governor, boost, GPU cap
```

Οι μετρήσεις χωρίζονται σε τέσσερις ανεξάρτητες σαρώσεις, καθεμία από τις οποίες γράφει τα ακατέργαστα αποτελέσματά της σε ξεχωριστό αρχείο:

```
make measure-cases      # timing over the parameter space
make measure-energy      # energy, requires RAPL access
make measure-dists      # input-distribution sensitivity
make measure-roofline   # bandwidth, compare-exchange roofs
```

Κάθε στόχος δέχεται πρόσθετα ορίσματα μέσω της μεταβλητής ARGS, τα οποία προωθούνται στον οδηγό των σαρώσεων και επιτρέπουν τον περιορισμό του παραμετρικού χώρου σε υποσύνολό του. Η δυνατότητα αυτή είναι χρήσιμη για γρήγορο έλεγχο της εγκατάστασης, όπου η πλήρης σάρωση θα ήταν υπερβολικά χρονοβόρα. Εκτελώνοντας τα στάδια χωριστά, η ευθύνη για τη σωστή σειρά και για τη σταθερότητα των συνθηκών μεταξύ των σαρώσεων ανήκει στον χρήστη.

Γ'.3.2 Παράμετροι εκτέλεσης

Ο πίνακας Γ'.1 δίνει το σύνολο των παραμέτρων που δέχεται κάθε εκτελέσιμο, τις επιτρεπτές τιμές τους, τις προεπιλογές τους και τις τιμές με τις οποίες εκτελέστηκαν οι σαρώσεις της εργασίας.

Οι προεπιλογές είναι εκείνες του εκτελέσιμου και σε αρκετές περιπτώσεις δεν ταυτίζονται με τις τιμές των σαρώσεων. Το εύρος τιμών εκτείνεται έως 10^9 αντί για την προεπιλογή, και ο λόγος είναι ουσιώδης: με εύρος λίγων χιλιάδων τιμών και είσοδο εκατομμυρίων στοιχείων, οι επαναλήψεις τιμών θα ήταν τόσο πυκνές ώστε το πρόβλημα να μετατρέποταν σε επιλογή μεταξύ ισοβαθμιών, κάτι που θα ευνοούσε τεχνητά τους αλγορίθμους που απορρίπτουν γρήγορα.

Το εύρος αυτό ισχύει για τους τέσσερις από τους πέντε τύπους. Για τον half το εκτελέσιμο περικόπτει τα άκρα στο ± 65504 , τη μεγαλύτερη πεπερασμένη τιμή που αναπαρίσταται, οπότε η δειγματοληψία γίνεται στην πραγματικότητα στο $[0, 65504]$. Στον τύπο αυτό οι ισοβαθμίες δεν αποφεύγονται, τόσο λόγω του στενότερου εύρους όσο και επειδή πάνω από το 2048 ο half δεν αναπαριστά όλους τους ακεραίους. Πρόκειται για εγγενή ιδιότητα του τύπου και όχι για επιλογή της μεθοδολογίας, οφείλει όμως να συνυπολογίζεται στην ερμηνεία των αποτελεσμάτων του.

Ο σπόρος δεν είναι σταθερός, αλλά παράγεται ντετερμινιστικά από τα q και k της κάθε περίπτωσης, ώστε δύο διαφορετικές περιπτώσεις να μη λαμβάνουν ποτέ την ίδια είσοδο και ταυτόχρονα κάθε περίπτωση να είναι επαναλήψιμη.

Οι τιμές της τέταρτης στήλης αφορούν την κύρια σάρωση. Οι δύο ειδικές σαρώσεις περιορίζουν ορισμένες παραμέτρους: η σάρωση κατανομών εξετάζει q από 20 έως 24, μόνο τους τύπους float και half και τα άκρα k 8 και 131072, με δύο σπόρους ανά περίπτωση, ενώ η σάρωση ενέργειας εξετάζει q από 16 έως 24 με τρεις επαναλήψεις και χωρίς έλεγχο ορθότητας, ώστε ο έλεγχος να μην προσμετρηθεί στην κατανάλωση.

Παράμετρος	Τιμές	Προεπιλογή	Στις σαρώσεις	Σημασία
q	ακέрайος 0–63	—	3–24	Μέγεθος εισόδου $n = 2^q$ · είναι η μόνη υποχρεωτική
k	θετικός ακέрайος	n	8, 256, 4096, 131072	Πλήθος ζητούμενων στοιχείων· περιορίζεται στο n
mode	min max	max	max	Επιλογή μικρότερων ή μεγαλύτερων
dtype	int uint float double half	int	και οι πέντε	Τύπος στοιχείου
algo	bitonic map_reduce gt	bitonic	και οι τρεις	Αλγόριθμος προς εκτέλεση
run	full trunc both	trunc	trunc	Παραλλαγή του διτονικού δικτύου
seed	μη αρνητικός ακέрайος	42	παράγεται από τα q, k	Σπόρος της γεννήτριας τυχαίων αριθμών
dist	uniform normal trimodal sorted reverse adversarial	uniform	uniform· πέντε στη σάρωση κατανομών	Κατανομή της εισόδου
min / max	ακέрайοι	0 / 1000	0 / 10^9	Εύρος τιμών· απαιτείται $\max \geq \min$ · περικόπτεται στο εύρος του τύπου
threads	θετικός ακέрайος	0 (αυτόματο)	8	Πλήθος νημάτων· η NPU το αγνοεί
verify	true false	false	true	Έλεγχος ως προς την υλοποίηση επαλήθευσης
debug	true false	true	false	Αναλυτική έξοδος διαγνωστικών

Πίνακας Γ.1: Οι παράμετροι εκτέλεσης και οι προεπιλογές τους.

Γ'.4 Παραγωγή των διαγραμμάτων

Η υποδομή ανάλυσης διαβάζει τα ακατέργαστα αποτελέσματα των σαρώσεων, τα μετατρέπει σε πίνακες σε μορφή CSV και παράγει τα διαγράμματα:

```
make plot ARGS="--plot all"
```

Το όρισμα `-plot` επιλέγει ποια διαγράμματα θα παραχθούν, ενώ το `-input` καθορίζει ποια σάρωση θα διαβαστεί· η προεπιλογή είναι η σάρωση χρόνου. Τα διαγράμματα ενέργειας, κατανομών και `roofline` διαβάζουν τα δικά τους αρχεία, οπότε συνήθως είναι προτιμότερο να χρησιμοποιηθούν οι συνδυαστικοί στόχοι, που εκτελούν τη μέτρηση και την αντίστοιχη παραγωγή διαγραμμάτων μαζί:

```
make benchmark-cases  
make benchmark-energy  
make benchmark-dists  
make benchmark-roofline
```

Τα παραγόμενα αρχεία οργανώνονται ανά τύπο δεδομένων και ανά κατηγορία μέτρησης, μαζί με τους πίνακες από τους οποίους προέκυψαν. Τα διαγράμματα που αφορούν το ίδιο το μηχάνημα, όπως η κλίμακα εύρους ζώνης της ενότητας 3.4, τοποθετούνται σε ξεχωριστό κατάλογο, καθώς δεν εξαρτώνται από τον τύπο δεδομένων.

Δύο επιλογές επηρεάζουν την ερμηνεία των διαγραμμάτων και αξίζει να αναφερθούν. Η `-energy-metric` επιλέγει μεταξύ μεικτής ενέργειας, καθαρής, ή και των δύο μαζί, που είναι και η προεπιλογή του εκτελέσιμου· οι σαρώσεις της εργασίας ζητούν ρητά την καθαρή, για τους λόγους της ενότητας 3.3.3. Η `-error-bars` επιλέγει το είδος της ζώνης διασποράς γύρω από τις τιμές, ανάμεσα σε τυπική απόκλιση, δεκατημόρια, ή καμία ζώνη, με προεπιλογή την τυπική απόκλιση. Ζώνη σχεδιάζεται μόνο όπου υπάρχουν τουλάχιστον δύο δείγματα ανά σημείο, δηλαδή στη σάρωση κατανομών, που χρησιμοποιεί δύο σπόρους ανά περίπτωση, και στη σάρωση ενέργειας, που επαναλαμβάνει κάθε περίπτωση τρεις φορές. Στην αυτοματοποιημένη εκτέλεση οι ζώνες είναι απενεργοποιημένες και στις τέσσερις σαρώσεις, οπότε τα διαγράμματα που παράγει δεν τις περιλαμβάνουν.

Bibliography

- [1] D. E. Knuth, *The Art of Computer Programming, Volume 3: Sorting and Searching*, 2nd ed. Addison-Wesley, 1998.
- [2] N. Sismanis, N. Pitsianis, and X. Sun, “Parallel search of k-nearest neighbors with synchronous operations,” in *2012 IEEE Conference on High Performance Extreme Computing (HPEC)*, Waltham, MA, USA, 2012, pp. 1–6.
- [3] J. Zhang, A. Naruse, X. Li, and Y. Wang, “Parallel top-K algorithms on GPU: A comprehensive study and new methods,” in *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis (SC ’23)*, Denver, CO, USA, 2023.
- [4] K. E. Batcher, “Sorting networks and their applications,” in *Proceedings of the AFIPS Spring Joint Computer Conference*, 1968, pp. 307–314.
- [5] A. Shanbhag, H. Pirk, and S. Madden, “Efficient top-K query processing on massively parallel hardware,” in *Proceedings of the 2018 International Conference on Management of Data (SIGMOD)*, Houston, TX, USA, 2018, pp. 1557–1570.
- [6] D. A. Palmer and M. Florea, “Neural processing unit,” U.S. Patent US8655815B2, assigned to the University of California, San Diego, 2014, application US13/011,727, filed 21 January 2011; granted 18 February 2014.
- [7] H. Esmailzadeh, A. Sampson, L. Ceze, and D. Burger, “Neural acceleration for general-purpose approximate programs,” in *45th Annual IEEE/ACM International Symposium on Microarchitecture (MICRO)*, 2012, pp. 449–460.
- [8] T. Chen, Z. Du, N. Sun, J. Wang, C. Wu, Y. Chen, and O. Temam, “DianNao: A small-footprint high-throughput accelerator for ubiquitous machine-learning,” in *19th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*, 2014, pp. 269–284.
- [9] N. P. Jouppi, C. Young, N. Patil, D. Patterson *et al.*, “In-datacenter performance analysis of a tensor processing unit,” in *44th International Symposium on Computer Architecture (ISCA)*, 2017, pp. 1–12.
- [10] Y.-H. Chen, J. Emer, and V. Sze, “Eyeriss: A spatial architecture for energy-efficient dataflow for convolutional neural networks,” in *43rd International Symposium on Computer Architecture (ISCA)*, 2016, pp. 367–379.
- [11] AMD, “Versal adaptive SoC: The industry’s first adaptive compute acceleration platform,” AMD, White Paper, 2021, <https://www.amd.com/>

content/dam/amd/en/documents/products/adaptive-socs-and-fpgas/versal/adaptive-soc-paper.pdf.

- [12] A. Rico, S. Pareek, J. Cabezas, J. Noguera *et al.*, “AMD XDNA NPU in Ryzen AI processors,” *IEEE Micro*, vol. 44, no. 6, 2024.
- [13] AMD/Xilinx, “MLIR-AIE: An MLIR-based toolchain for AMD AI engine-enabled devices,” <https://github.com/Xilinx/mlir-aie>, 2024.
- [14] NVIDIA, “CCCL: CUDA core compute libraries,” <https://github.com/NVIDIA/cccl>, 2024.
- [15] C. Lin, M. Yang, C. Wang, and C. Huang, “Adaptive top-K selection: Eliminating performance cliffs across all K values on AMD GPUs,” AMD ROCm Blogs, Feb. 2026, <https://rocm.blogs.amd.com/software-tools-optimization/adaptive-topk/README.html>.
- [16] Y. Samaga, V. Yerram, S. R. Babbula, P. Jain, and P. Netrapalli, “A faster generalized two-stage approximate top-K,” *Transactions on Machine Learning Research*, 2026, <https://openreview.net/forum?id=izqZ1Crpjz>.
- [17] AMD, “Bitonic SIMD sorting on AI engine for float datatypes,” Vitis Tutorials: AI Engine Development, 2024.1, 2024, <https://docs.amd.com/r/2024.1-English/Vitis-Tutorials-AI-Engine-Development/Bitonic-SIMD-Sorting-on-AI-Engine-for-float-Datatypes>.
- [18] S. Williams, A. Waterman, and D. Patterson, “Roofline: An insightful visual performance model for multicore architectures,” *Communications of the ACM*, vol. 52, no. 4, pp. 65–76, 2009.
- [19] Intel, “Intel intrinsics guide,” <https://www.intel.com/content/www/us/en/docs/intrinsics-guide/index.html>, 2024.
- [20] AMD, “IRON: A close-to-metal programming framework for AMD NPUs,” <https://github.com/amd/IRON>, 2024.
- [21] —, “AI engine kernel and graph programming guide (UG1079): Casting and datatype conversion,” 2024, <https://docs.amd.com/r/en-US/ug1079-ai-engine-kernel-coding/>.